Tópicos de optimización convexa

DRAFT

Guillermo Villa Martínez[1], Mag.
Autor[1], Mag.
Autor[1].



[1] Facultad de Ciencias Básicas
Universidad Tecnológica de Pereira
2026

Villa Martínez, Guillermo INTRODUCCIÓN A LOS MÉTODOS NUMÉRICOS Y SUS APLICACIONES EN INGENIERÍA / autores Guillermo Villa Martínez, , 2027.

203 páginas: gráficos.
ISBN: XXX-XXX-XXXX-XX-X (papel) ISBN: XXX-XXX-XXXX-XX-X (digital)

1. Métodos numéricos 2. Sistemas de ecuaciones 3. Análisis del error 4. Ecuaciones diferenciales 5. Aproximaciones sucesivas 6. Optimización con restricciones I. Villa Martínez, Guillermo, II. Autor, III. Autor.
333.7932
M798
CDD23

Convexa, 2027

Autores
Guillermo Villa Martínez
Autor
Autor

ISBN: XXX-XXX-XXXX-XX-X (papel) **ISBN:** XXX-XXX-XXXX-XX-X (digital)

DRAFT

La reproducción parcial o total de esta obra por distintos medios queda prohibida, salvo autorización de los editores de la presente versión.

Contenido

1 Preliminares **1**

1.1 Introducción a la optimización convexa . . . 1
1.2 Problema de optimización . . . 2
1.2.1 Planteamiento del problema . . . 2
1.2.2 Descripción geométrica . . . 3
1.2.3 Solución mediante cálculo diferencial . . . 3
1.2.4 Interpretación mediante la primera variación . . . 5
1.2.5 Relación con la ley de Snell . . . 5
1.2.6 Ejercicio propuesto . . . 6
1.2.7 Conclusión . . . 7
1.3 Conceptos fundamentales . . . 7
1.3.1 Optimización convexa . . . 7
1.3.2 Conjuntos convexos . . . 7
1.3.3 Funciones convexas . . . 8
1.3.4 Epígrafo de una función . . . 9
1.3.5 Problemas de optimización convexa . . . 9
1.4 Importancia de la optimización convexa . . . 9
1.5 Clases de problemas de optimización convexa . . . 10
1.6 Ejemplos de optimización lineal . . . 11
1.6.1 Problema nutricional . . . 11
1.6.2 Problema de flujo máximo . . . 12
1.7 Programación Lineal . . . 18
1.7.1 Metodología para hallar el punto óptimo de un problema de optimización. . . . 19
1.7.2 Método simplex . . . 20
1.7.2.1 Formulación del Problema . . . 20
1.7.2.2 Pivotaje . . . 21
1.7.3 Ejercicios . . . 26

2 Estructuras convexas, dualidad y condiciones de optimalidad **28**

2.1 Conjuntos convexos y poliedros . . . 28
2.1.1 Poliedros . . . 31
2.1.2 Bolas unitarias de normas . . . 33
2.1.3 Polinomios no negativos . . . 41
2.1.4 Caso especial: Matrices PSD . . . 44

DRAFT

2.2 Optimización de portafolios 53
2.2.1 Modelo de Markowitz 54
2.2.2 Problema de portafolio óptimo 57
2.2.3 Matriz de covarianza 60
2.2.4 ¿Por qué se calcula la matriz de covarianza? 62
2.2.5 Matriz semidefinida positiva 63
2.2.6 Factorización de Cholesky 65
2.2.7 Factorización de Cholesky para matrices semidefinidas positivas . 67
2.3 Condiciones de Karush–Kuhn–Tucker (KKT) 72
2.3.1 La función Lagrangiana 73
2.3.2 Formulación del problema primal 73
2.3.3 Función Lagrangiana y variables duales 75
2.3.4 Interpretación de la función Lagrangiana y función dual 75
2.3.5 Factibilidad primal y dual 77
2.3.6 Relación entre las formulaciones primal y dual 80

3 Optimización de segundo orden **87**
3.1 Optimización de segundo orden sin restricciones y con restricciones . . . 87
3.2 Método de Newton sin restricciones 91
3.3 Método de Newton con restricciones de igualdad 96
3.4 Método de Newton con restricciones de desigualdad: métodos de punto interior y de barrera 103
3.5 Métodos cuasi-Newton 111

DRAFT

Lista de figuras

1.1 Trayectoria del socorrista y punto de entrada al agua. 2
1.2 Trayectoria del socorrista desde A hasta B, entrando al agua en P. 6
1.3 Red de transferencia de datos 13
1.4 13
1.5 18
1.6 Método Simplex maximizado. 23
1.7 Método Simplex minimizado. 25

2.1 Comparativa gráfica de la dualidad débil y fuerte para problemas de minimización y maximización. 79

DRAFT

Lista de tablas

1.1 Contenido nutricional y precio de los ingredientes. 11

DRAFT

1 Preliminares

1.1 Introducción a la optimización convexa

Esquema de evaluación

La evaluación del curso se distribuye de la siguiente manera:

- **Proyecto computacional: 60 %.**
  El proyecto consiste en la formulación e implementación de un problema de optimización mediante herramientas computacionales, como MOSEK o GUROBI, python. Su desarrollo se divide en las siguientes entregas:
  - Primera entrega: 20 %.
  - Segunda entrega: 20 %.
  - Entrega final: 20 %.

  Las fechas correspondientes se publicarán oportunamente en la plataforma del curso.
- **Evaluaciones: 40 %.**
  Se realizarán dos talleres, distribuidas así:
  - Taller 1: 10 %.
  - Taller 2: 10 %.
  - Taller 3: 10 %.
  - Taller 4: 10 %.

  Además, durante las sesiones de clase se propondrán ejercicios orientados a consolidar los conceptos estudiados.

DRAFT

1.2 Problema de optimización

El problema del socorrista de playa constituye una aplicación de la optimización. Su análisis permite determinar la trayectoria que minimiza el tiempo necesario para desplazarse desde un punto de la playa hasta una persona ubicada en el mar.

El resultado obtenido no es únicamente cualitativo. La condición de optimalidad coincide con la ley de Snell de la refracción. En este documento se deduce dicha condición mediante cálculo diferencial y se interpreta también en términos de la primera variación.

1.2.1 Planteamiento del problema

Un socorrista situado en la playa (punto A) observa a una persona en apuros dentro del mar (punto B). La separación perpendicular entre ambos puntos se divide en dos distancias:

$$y = y_1 + y_2,$$

donde y_1 es la distancia perpendicular desde la posición inicial del socorrista hasta la línea costera, mientras que y_2 es la distancia perpendicular desde la costa hasta la persona.

Se supone que el socorrista corre sobre la playa con velocidad constante v_1 y nada con velocidad constante v_2. Habitualmente,

$$v_2 < v_1,$$

pues la velocidad al nadar es menor que la velocidad al correr.

El socorrista debe elegir el punto de entrada al agua de manera que el tiempo total de desplazamiento sea mínimo.

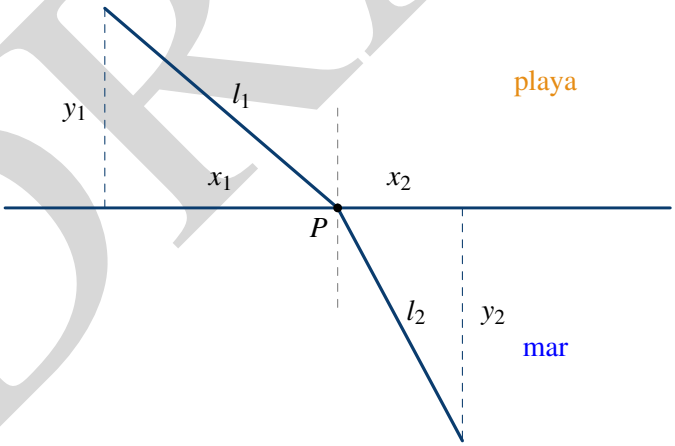


Figura 1.1: Trayectoria del socorrista y punto de entrada al agua.

DRAFT

1.2.2 Descripción geométrica

Sea s la separación horizontal total entre la posición inicial del socorrista y la persona. Si x_1 es la distancia horizontal recorrida en la playa y x_2 la distancia horizontal correspondiente al trayecto en el agua, entonces

$$x_1 + x_2 = s.$$

Por tanto,

$$x_2 = s - x_1.$$

Las longitudes de los dos segmentos de la trayectoria son

$$l_1 = \sqrt{x_1^2 + y_1^2}$$

y

$$l_2 = \sqrt{x_2^2 + y_2^2} = \sqrt{(s-x_1)^2 + y_2^2}.$$

El tiempo empleado en la playa es

$$t_1 = \frac{l_1}{v_1} = \frac{1}{v_1}\sqrt{x_1^2 + y_1^2},$$

mientras que el tiempo empleado en el agua es

$$t_2 = \frac{l_2}{v_2} = \frac{1}{v_2}\sqrt{(s-x_1)^2 + y_2^2}.$$

En consecuencia, el tiempo total depende únicamente de x_1:

$$T(x_1) = \frac{1}{v_1}\sqrt{x_1^2 + y_1^2} + \frac{1}{v_2}\sqrt{(x-x_1)^2 + y_2^2}, \qquad 0 \le x_1 \le s.$$

El problema consiste en encontrar el valor de x_1 que minimiza $T(x_1)$.

1.2.3 Solución mediante cálculo diferencial

Queremos obtener el valor mínimo de x_1 para que el recorrido sea lo antes posible, esto es, ir desde el punto A hasta el punto B en el menor tiempo posible. Derivando el tiempo total con respecto a x_1, se obtiene

$$T'(x_1) = \frac{x_1}{v_1\sqrt{x_1^2 + y_1^2}} - \frac{x - x_1}{v_2\sqrt{(x-x_1)^2 + y_2^2}}.$$

Una condición necesaria para que x_1^* sea un punto interior de mínimo es

$$T'(x_1^*) = 0.$$

Por tanto,

DRAFT

$$\frac{x_1^*}{v_1\sqrt{(x_1^*)^2+y_1^2}} = \frac{x-x_1^*}{v_2\sqrt{(x-x_1^*)^2+y_2^2}}.$$

Si definimos

$$x_2^* = x - x_1^*,$$

la condición anterior toma la forma

$$\frac{x_1^*}{v_1\sqrt{(x_1^*)^2+y_1^2}} = \frac{x_2^*}{v_2\sqrt{(x_2^*)^2+y_2^2}}.$$

Como

$$l_1 = \sqrt{(x_1^*)^2+y_1^2}, \qquad l_2 = \sqrt{(x_2^*)^2+y_2^2},$$

se obtiene

$$\frac{x_1^*}{v_1 l_1} = \frac{x_2^*}{v_2 l_2}.$$

Comprobación de que el punto crítico es un mínimo

La segunda derivada de T es

$$T''(x_1) = \frac{y_1^2}{v_1\left(x_1^2+y_1^2\right)^{3/2}} + \frac{y_2^2}{v_2\left((x-x_1)^2+y_2^2\right)^{3/2}}.$$

Como

$$v_1 > 0, \qquad v_2 > 0, \qquad y_1 > 0, \qquad y_2 > 0,$$

se cumple

$$T''(x_1) > 0 \qquad \text{para todo } x_1 \in [0,x].$$

Por consiguiente, T es estrictamente convexa. Esto garantiza que el punto crítico x_1^*, cuando satisface $T'(x_1^*) = 0$, es el único mínimo global del tiempo total.

Además,

$$T'(0) = -\frac{x}{v_2\sqrt{x^2+y_2^2}} < 0$$

y

$$T'(x) = \frac{x}{v_1\sqrt{x^2+y_1^2}} > 0.$$

DRAFT

Por continuidad de T', existe un único punto

$$x_1^* \in (0, x)$$

en el cual $T'(x_1^*) = 0$.

1.2.4 Interpretación mediante la primera variación

La misma condición puede obtenerse perturbando ligeramente el punto de entrada al agua. Consideremos una variación de la forma

$$x_1(\varepsilon) = x_1^* + \varepsilon\eta,$$

donde $\eta \in \mathbb{R}$ representa una dirección de perturbación y ε es un parámetro pequeño. La primera variación del tiempo se define como

$$\delta T(x_1^*; \eta) = \frac{d}{d\varepsilon} T(x_1^* + \varepsilon\eta)\Big|_{\varepsilon=0}.$$

Aplicando la regla de la cadena,

$$\delta T(x_1^*; \eta) = T'(x_1^*)\eta.$$

Para que x_1^* sea óptimo, la primera variación debe anularse para toda perturbación admisible η:

$$\delta T(x_1^*; \eta) = 0 \qquad \text{para todo } \eta.$$

Esto implica

$$T'(x_1^*) = 0,$$

que es precisamente la condición obtenida mediante cálculo diferencial.

1.2.5 Relación con la ley de Snell

Los ángulos θ_1 y θ_2 se miden respecto de la dirección normal a la línea costera. De la geometría de los triángulos rectángulos,

$$\sin\theta_1 = \frac{x_1^*}{l_1}, \qquad \sin\theta_2 = \frac{x_2^*}{l_2}.$$

Por tanto, la condición de optimalidad

$$\frac{x_1^*}{v_1 l_1} = \frac{x_2^*}{v_2 l_2}$$

puede escribirse como

$$\boxed{\frac{\sin\theta_1}{v_1} = \frac{\sin\theta_2}{v_2}}.$$

DRAFT

Esta igualdad expresa que la razón entre el seno del ángulo de la trayectoria y la velocidad de desplazamiento permanece constante al atravesar la frontera entre los dos medios.

En óptica, el índice de refracción de un medio se define mediante

$$n_i = \frac{c}{v_i},$$

donde c es la velocidad de la luz en el vacío y v_i es la velocidad de propagación de la luz en el medio n_i.

Multiplicando la condición anterior por c, resulta

$$\frac{c}{v_1}\sin\theta_1 = \frac{c}{v_2}\sin\theta_2.$$

En consecuencia,

$$\boxed{n_1 \sin\theta_1 = n_2 \sin\theta_2},$$

que corresponde a la ley de Snell de la refracción.

Nota: Este mismo ejercicio se puede resolver utilizando multiplicadores de Lagrange.

1.2.6 Ejercicio propuesto

Un hombre se encuentra en el punto A y desea llegar, en el menor tiempo posible, al punto B. Puede caminar por la playa a una velocidad de $5\,\mathrm{km/h}$ y nadar a una velocidad de $3\,\mathrm{km/h}$.

¿A qué distancia de A, medida a lo largo de la orilla, debe ingresar al agua para minimizar el tiempo total de recorrido?

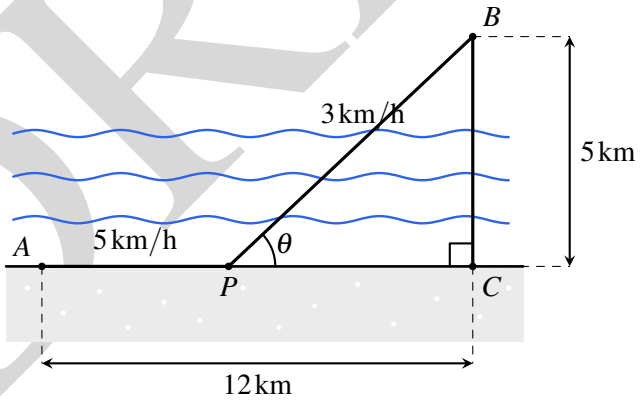


Figura 1.2: Trayectoria del socorrista desde A hasta B, entrando al agua en P.

1. Calcular el valor mínimo usando cálculo diferencial.
2. Determinar si la función objetivo es convexa.

DRAFT

3. Determinar la región factible de solución. ¿Es un conjunto convexo?.
4. Usar multiplicadores de Lagrange y comparar los resultados anteriores.
5. Implementar cálculo de variaciones para obtener el valor mínimo.
6. Comparar con la ley de Snell.

1.2.7 Conclusión

El punto óptimo de entrada al agua se obtiene minimizando el tiempo total de desplazamiento y no la distancia recorrida. El cálculo diferencial muestra que dicho punto es único, debido a la convexidad estricta de la función de tiempo.

La condición de primera variación nula conduce a

$$\frac{\sin\theta_1}{v_1} = \frac{\sin\theta_2}{v_2},$$

que es la versión mecánica de la ley de Snell. Por tanto, la trayectoria seguida por el socorrista obedece el mismo principio de tiempo mínimo que rige la refracción de la luz.

1.3 Conceptos fundamentales

1.3.1 Optimización convexa

La optimización convexa es una rama de la optimización matemática dedicada al estudio de problemas en los que se minimiza una función convexa sobre un conjunto convexo.

Sea V un espacio vectorial real de dimensión finita. Si

$$\dim(V) = n,$$

entonces V es isomorfo a $\mathbb{R}^n$, es decir,

$$V \cong \mathbb{R}^n.$$

1.3.2 Conjuntos convexos

Definición. Un subconjunto $C \subseteq V$ se denomina *convexo* si, para cualesquiera $x, y \in C$ y todo $\lambda \in [0,1]$, se cumple

$$\lambda x + (1-\lambda)y \in C.$$

La combinación convexa anterior también puede escribirse como

$$\lambda x + (1-\lambda)y = y + \lambda(x-y).$$

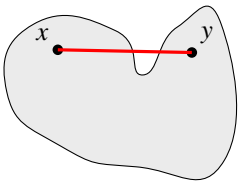
Cuando λ recorre el intervalo $[0,1]$, el punto

$$y + \lambda(x-y)$$

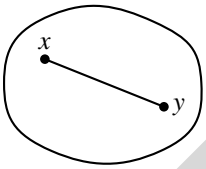
describe el segmento de recta que une a y con x.

Por consiguiente, un conjunto $C \subseteq V$ es convexo si y solo si el segmento de recta que une dos puntos cualesquiera de C está contenido completamente en C.

DRAFT



Conjunto no convexo



Conjunto convexo

1.3.3 Funciones convexas

Definición. Sea

$$f : V \longrightarrow \mathbb{R} \cup \{+\infty\}.$$

La función f se denomina *convexa* si satisface las siguientes condiciones:

1. Su dominio,
$$\mathrm{dom}(f) := \{v \in V : f(v) < +\infty\},$$
es un conjunto convexo.
2. Para cualesquiera $x, y \in \mathrm{dom}(f)$ y todo $\lambda \in [0,1]$, se cumple la desigualdad
$$f\big(\lambda x + (1-\lambda)y\big) \leq \lambda f(x) + (1-\lambda) f(y).$$

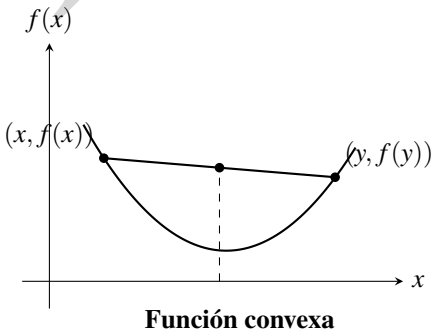
Geométricamente, el segmento que une los puntos $(x, f(x))$ y $(y, f(y))$ está parametrizado por

$$\lambda\,(x, f(x)) + (1-\lambda)\,(y, f(y)), \qquad \lambda \in [0,1].$$

Esta expresión puede escribirse como

$$(\lambda x + (1-\lambda)y,\, \lambda f(x) + (1-\lambda) f(y))\,.$$

Por tanto, una función es convexa cuando el segmento de recta que une dos puntos cualesquiera de su gráfica se encuentra por encima de la gráfica de la función.



Función convexa

DRAFT

1.3.4 Epígrafo de una función

Definición. Sea

$$f : V \longrightarrow \mathbb{R} \cup \{+\infty\}.$$

El *epígrafo* de f es el conjunto

$$\operatorname{epi}(f) = \{(v, \alpha) \in V \times \mathbb{R} : v \in \operatorname{dom}(f) \text{ y } \alpha \geq f(v)\}.$$

En términos geométricos, el epígrafo está constituido por todos los puntos situados sobre la gráfica de f, incluyendo la propia gráfica.

Ejercicio. Demuestre que

$$f \text{ es convexa} \quad \Longleftrightarrow \quad \operatorname{epi}(f) \text{ es un conjunto convexo.}$$

1.3.5 Problemas de optimización convexa

Sean $C \subseteq V$ un conjunto convexo y

$$f : V \longrightarrow \mathbb{R} \cup \{+\infty\}$$

una función convexa. Un problema de optimización convexa puede formularse como

$$\inf_{x \in C} f(x).$$

El valor óptimo del problema se define mediante

$$\alpha^* = \inf\{f(x) : x \in C\}.$$

El conjunto de soluciones óptimas o minimizadores está dado por

$$\arg\min_{x \in C} f(x) = \{x^* \in C : f(x^*) = \alpha^*\}.$$

Es importante distinguir entre el valor óptimo α^* y los puntos óptimos x^*. El valor óptimo es un número real extendido, mientras que los minimizadores son elementos del conjunto factible C.

El uso del ínfimo permite formular el problema incluso cuando el valor óptimo no es alcanzado. Cuando existe $x^* \in C$ tal que

$$f(x^*) = \alpha^*,$$

se dice que el problema admite una solución óptima.

1.4 Importancia de la optimización convexa

El estudio de la optimización convexa se fundamenta principalmente en tres aspectos: su amplia presencia en aplicaciones, la posibilidad de resolver eficientemente numerosos problemas y la existencia de una teoría matemática unificada.

DRAFT

1. **Amplio campo de aplicación.**

   Los problemas convexos aparecen en áreas como la ingeniería, el control, el procesamiento de señales, la estadística, el análisis de datos, la economía y el aprendizaje automático.

   Uno de los objetivos centrales consiste en aprender a identificar y formular problemas que posean una estructura convexa.

   Entre las principales clases de problemas se tiene la inclusión

   $$\text{optimización lineal} \subseteq \text{optimización semidefinida} \subseteq \text{optimización convexa}.$$

2. **Tratabilidad computacional.**

   Una amplia variedad de problemas convexos puede resolverse de manera eficiente mediante algoritmos numéricos especializados.

   - Desde el punto de vista teórico, existen algoritmos de tiempo polinomial para importantes familias de problemas convexos.
   - Desde el punto de vista computacional, pueden emplearse herramientas como GUROBI, MOSEK y otros solucionadores especializados.

3. **Teoría matemática unificada.**

   La optimización convexa cuenta con una estructura teórica sólida, basada principalmente en la geometría convexa, las condiciones de optimalidad y la teoría de dualidad.

   Estas herramientas permiten:

   (a) formular un mismo problema mediante representaciones equivalentes;

   (b) establecer cotas para el valor óptimo;

   (c) estudiar la existencia y caracterización de soluciones;

   (d) construir aproximaciones convexas de problemas no convexos.

1.5 Clases de problemas de optimización convexa

Las principales familias de problemas de optimización convexa pueden organizarse de acuerdo con la estructura geométrica de sus conjuntos factibles. En términos de capacidad de representación, se tiene la jerarquía

$$\text{poliedros} \subseteq \text{conjuntos representables mediante conos de segundo orden} \subseteq \text{espectraedros} \subseteq \text{conjuntos convexos}.$$

Esta jerarquía da lugar a las siguientes clases de problemas:

$$\text{optimización lineal} \subseteq \text{optimización cónica de segundo orden} \subseteq \text{optimización semidefinida} \subseteq \text{optimización convexa}.$$

Estas inclusiones deben interpretarse en términos de capacidad de modelado: todo problema lineal puede formularse como un problema cónico de segundo orden; todo

DRAFT

problema cónico de segundo orden admite una formulación semidefinida, y todo problema semidefinido pertenece a la clase general de problemas convexos.

Una formulación típica consiste en minimizar una función lineal sobre un conjunto convexo perteneciente a alguna de las familias anteriores.

Ejercicio. Demuestre que todo problema de optimización convexa puede reformularse como un problema de minimización de una funcional lineal sobre un conjunto convexo.

Pregunta de reflexión. ¿Qué situaciones reales pueden modelarse mediante programación lineal, optimización cónica de segundo orden y programación semidefinida?

1.6 Ejemplos de optimización lineal

1.6.1 Problema nutricional

El siguiente ejemplo corresponde a un problema clásico de programación lineal, basado en el texto de Matoušek y Gärtner, *Understanding and Using Linear Programming*.

Un inspector determina que los alimentos ofrecidos en un establecimiento no satisfacen los requerimientos mínimos de vitamina A, vitamina B y fibra. Para corregir esta situación, el propietario decide ofrecer un plato complementario elaborado con una mezcla de zanahoria, coliflor y pepinillo.

El problema consiste en determinar las cantidades de cada ingrediente que permiten satisfacer los requerimientos nutricionales al menor costo posible.

Componente	Zanahoria	Coliflor	Pepinillo	Requerimiento mínimo
Vitamina A (mg/kg)	35	0,5	0,5	$\geq 0{,}5$ mg
Vitamina B (mg/kg)	60	300	10	≥ 15 mg
Fibra (g/kg)	30	20	10	≥ 4 g
Precio (€/kg)	0,75	0,50	0,15	No aplica

Tabla 1.1: Contenido nutricional y precio de los ingredientes.

Variables de decisión

Se definen las siguientes variables:

$$x_1 = \text{cantidad de zanahoria utilizada, en kilogramos,}$$
$$x_2 = \text{cantidad de coliflor utilizada, en kilogramos,}$$
$$x_3 = \text{cantidad de pepinillo utilizada, en kilogramos.}$$

Debido a que estas variables representan cantidades físicas, deben satisfacer las restricciones de no negatividad

$$x_1, x_2, x_3 \geq 0.$$

DRAFT

Restricciones nutricionales

El requerimiento mínimo de vitamina A se expresa mediante

$$35x_1 + 0{,}5x_2 + 0{,}5x_3 \geq 0{,}5.$$

El requerimiento mínimo de vitamina B está dado por

$$60x_1 + 300x_2 + 10x_3 \geq 15.$$

Por su parte, el requerimiento mínimo de fibra conduce a la restricción

$$30x_1 + 20x_2 + 10x_3 \geq 4.$$

En consecuencia, el conjunto factible está definido por

$$\mathscr{R} = \left\{ (x_1, x_2, x_3) \in \mathbb{R}^3 : \begin{array}{l} x_1, x_2, x_3 \geq 0, \\ 35x_1 + 0{,}5x_2 + 0{,}5x_3 \geq 0{,}5, \\ 60x_1 + 300x_2 + 10x_3 \geq 15, \\ 30x_1 + 20x_2 + 10x_3 \geq 4 \end{array} \right\}.$$

Función objetivo

El costo total del plato, expresado en euros, está dado por

$$f_0(x_1, x_2, x_3) = 0{,}75x_1 + 0{,}50x_2 + 0{,}15x_3.$$

Por tanto, el problema de programación lineal se formula como

$$\boxed{\begin{array}{ll} \underset{x_1, x_2, x_3}{\text{minimizar}} & 0{,}75x_1 + 0{,}50x_2 + 0{,}15x_3 \\ \text{sujeto a} & 35x_1 + 0{,}5x_2 + 0{,}5x_3 \geq 0{,}5, \\ & 60x_1 + 300x_2 + 10x_3 \geq 15, \\ & 30x_1 + 20x_2 + 10x_3 \geq 4, \\ & x_1, x_2, x_3 \geq 0. \end{array}}$$

De forma equivalente, puede escribirse como

$$\min_{(x_1, x_2, x_3) \in \mathscr{R}} f_0(x_1, x_2, x_3).$$

1.6.2 Problema de flujo máximo

Considérese una red dirigida en la que el nodo o representa la fuente y el nodo n representa el destino. Cada arista tiene asociada una capacidad, la cual determina la cantidad máxima de flujo que puede circular a través de ella.

DRAFT

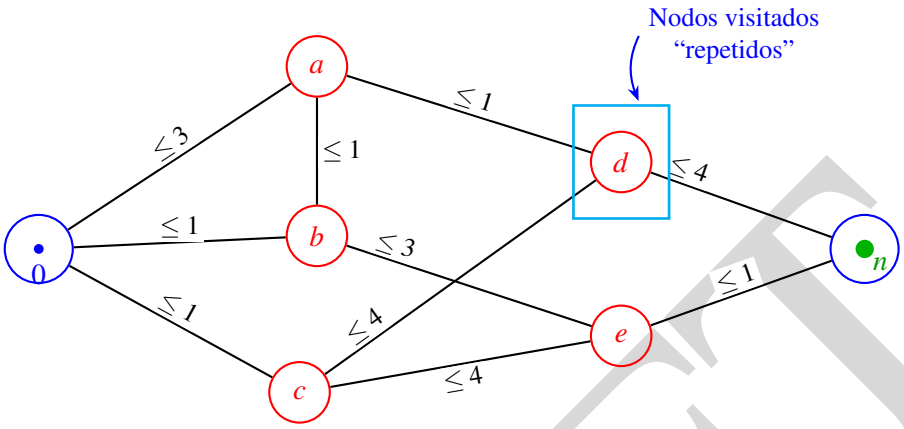


Figura 1.3: Red de transferencia de datos

El objetivo consiste en determinar la mayor cantidad de flujo que puede enviarse desde la fuente o hasta el destino n, sin superar las capacidades de las aristas.

Además de las restricciones de capacidad, debe cumplirse la condición de conservación del flujo: en cada nodo intermedio, el flujo total que ingresa debe ser igual al flujo total que sale.

Construcción de un flujo factible

En la siguiente figura, cada etiqueta de la forma f/c indica el flujo asignado f y la capacidad c de la arista correspondiente.

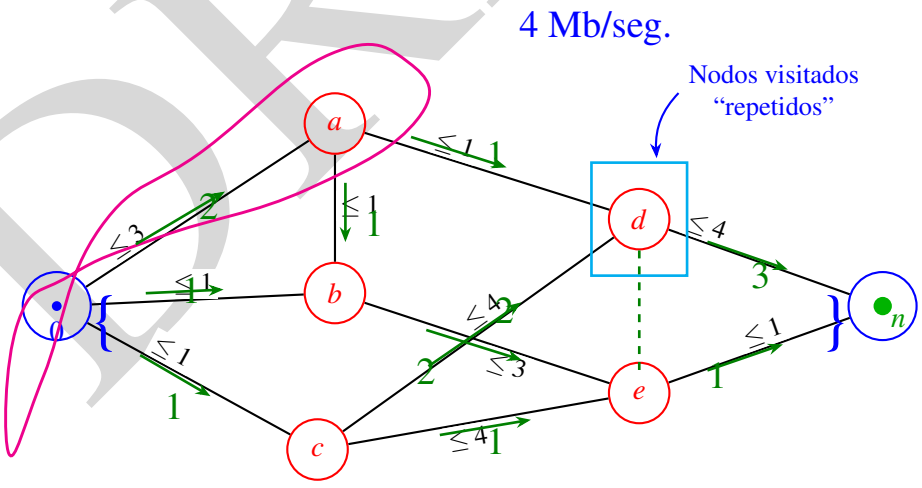


Figura 1.4

DRAFT

El valor de un flujo se calcula sumando las cantidades que salen de la fuente. Para la asignación mostrada se obtiene

$$2+1+1=4.$$

La misma cantidad llega al nodo de destino. Asimismo, la asignación respeta las capacidades de todas las aristas y satisface la conservación del flujo en cada nodo intermedio. En consecuencia, se trata de un flujo factible de valor 4.

La existencia de este flujo demuestra que el valor óptimo del problema es, al menos,

$$f^* \geq 4.$$

Para demostrar que el flujo es máximo, es necesario encontrar una cota superior con el mismo valor. Esta cota puede obtenerse mediante un corte de la red, lo cual conduce al teorema de flujo máximo y corte mínimo.

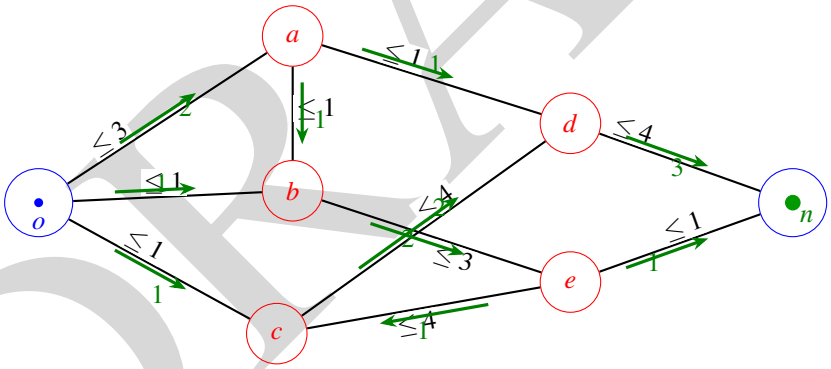
amsmath,amssymb tikz

Ejemplo: problema de flujo máximo

Sea el grafo

$$G=(V,E), \qquad V=\{o,a,b,c,d,e,n\},$$

donde o es el nodo de origen y n es el nodo de destino.



La solución representada en verde es un flujo factible con valor

$$\text{val}(f)=4 \text{ Mb/s}.$$

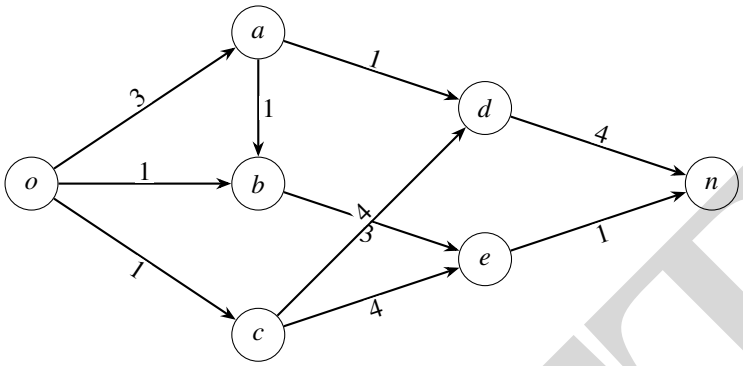
Problema de flujo máximo

Consideremos una red definida mediante el grafo

$$G=(V,E), \qquad V=\{o,a,b,c,d,e,n\},$$

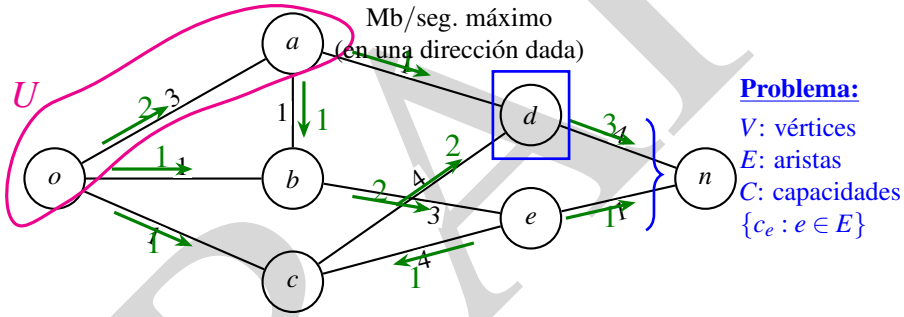
donde o es el nodo de origen y n es el nodo de destino.

DRAFT



El objetivo es maximizar la tasa de transferencia desde o hasta n. Para esta red se presenta un flujo factible de valor

4 Mb/s.



Definición de corte

Un corte de un grafo es una partición de los vértices de la forma

$$V = U \dot{\cup} U^c,$$

donde

$$o \in U, \qquad n \in U^c.$$

La capacidad del corte (U, U^c) se define como

$$C(U,U^c) = \sum_{\substack{(i,j)\in E \\ i\in U,\ j\in U^c}} c_{ij},$$

donde c_{ij} representa la capacidad de la arista (i,j).
El problema de corte mínimo es

DRAFT

$$\text{MinCut} = \min_{\substack{U \cup U^c = V \\ o \in U,\, n \in U^c}} C(U, U^c).$$

Todo flujo factible f satisface

$$\text{val}(f) \leq C(U, U^c).$$

Cuando se alcanza la igualdad, se obtiene la dualidad

$$\boxed{\text{MaxFlow} = \text{MinCut}}.$$

Variables de flujo

Se fija una orientación arbitraria para cada arista $e \in E$. El flujo se representa mediante el vector

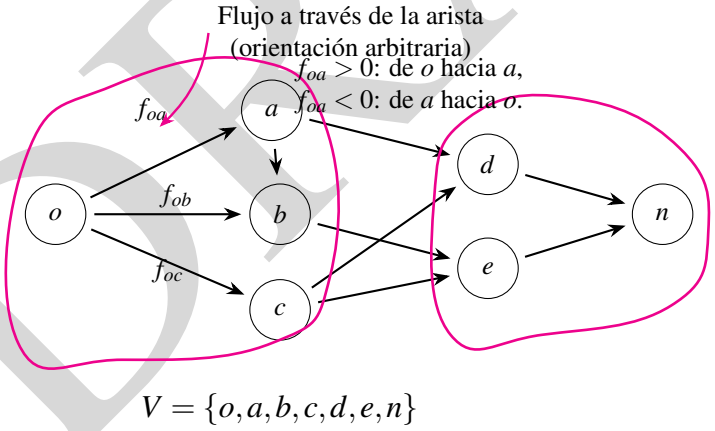
$$f = (f_e)_{e \in E} \in \mathbb{R}^{|E|}.$$

El signo de f_e depende de la orientación seleccionada:

$$f_e > 0 \iff \text{el flujo sigue la orientación de } e,$$

$$f_e < 0 \iff \text{el flujo va en sentido contrario.}$$

Es un problema de optimización lineal



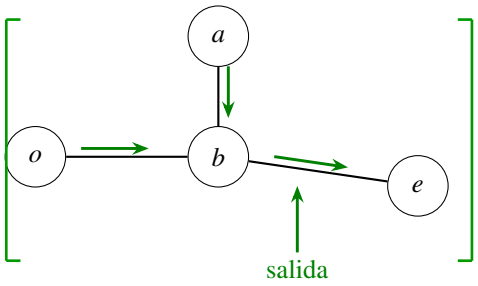
$f_e, \quad e \in E,$

$f_e > 0$ si el flujo sigue la orientación de e,

$f_e < 0$ si va en sentido contrario.

$$V = \{o, a, b, c, d, e, n\}$$

DRAFT



Restricción: $f_{ob}, f_{ab}, f_{be} \in \mathbb{R}$

$$f_{ob} + f_{ab} - f_{be} = 0$$

Conservación del flujo

En cada nodo intermedio, la suma de los flujos que entran debe ser igual a la suma de los flujos que salen.

Por ejemplo, para el nodo b,

$$f_{ob} + f_{ab} - f_{be} = 0.$$

En general,

$$\sum_{\substack{e \in E \\ e \text{ entra a } v}} f_e - \sum_{\substack{e \in E \\ e \text{ sale de } v}} f_e = 0, \qquad v \in V \setminus \{o, n\}.$$

Matriz de incidencia

Sea

$$A \in \mathbb{R}^{|V| \times |E|}$$

la matriz de incidencia del grafo, definida mediante

$$A_{ve} = \begin{cases} -1, & \text{si } e \text{ sale del vértice } v, \\ 1, & \text{si } e \text{ entra al vértice } v, \\ 0, & \text{en otro caso.} \end{cases}$$

Por ejemplo, para las aristas

$$E_0 = \{(o,b), (a,b), (b,e)\},$$

la matriz de incidencia correspondiente es

$$A_0 = \begin{pmatrix} -1 & 0 & 0 \\ 0 & -1 & 0 \\ 1 & 1 & -1 \\ 0 & 0 & 1 \end{pmatrix},$$

donde las filas corresponden a los nodos o, a, b, e.

DRAFT

$$[A\vec{f}]_v = 0, \qquad v \in V \setminus \{o,n\}.$$

Conservación del flujo en el vértice v

Ejemplo:

	ob	ab	be
o	-1	0	0
a	0	-1	0
b	1	1	-1
e	0	0	1

$$\vec{f} = \begin{pmatrix} f_{ob} \\ f_{ab} \\ f_{be} \end{pmatrix}$$

Restricción de conservación del flujo en el vértice b:

Figura 1.5

La conservación del flujo se expresa mediante

$$[Af]_v = 0, \qquad v \in V \setminus \{o,n\}.$$

El flujo neto que llega al nodo n es

$$[Af]_n = \sum_{\substack{a \in V \\ (a,n) \in E}} f_{an}.$$

Restricciones de capacidad

Para cada arista $e \in E$, se exige

$$-c_e \leq f_e \leq c_e.$$

Formulación como optimización lineal

El problema de flujo máximo se formula como

$$\begin{aligned} \max_{f \in \mathbb{R}^{|E|}} \quad & [Af]_n \\ \text{sujeto a} \quad & [Af]_v = 0, \qquad v \in V \setminus \{o,n\}, \\ & -c_e \leq f_e \leq c_e, \quad e \in E. \end{aligned}$$

1.7 Programación Lineal

La *programación lineal* es una técnica de optimización que permite maximizar o minimizar una función objetivo sujeta a un conjunto de restricciones lineales. Su formulación general

DRAFT

se expresa como:

$$f(\bar{x}) = c_1x_1 + c_2x_2 + c_3x_3 + \ldots + c_nx_n \tag{1.1}$$

La Ecuación (1.1) es la función a minimizar, los coeficientes de costo son $c_1, c_2, c_3, \ldots + c_n$ y las variables de decisión son $\bar{x} = x_1, x_2, x_3, \ldots, x_n$ (variables que minimizan o maximizan la función objetivo.)

Con restricciones de tipo lineal, en cualquier de los casos donde la función objetivo no sea lineal o alguna de las restricciones no sea de tipo lineal, entonces no es posible aplicar los métodos para resolver problemas de programación lineal.

1.7.1 Metodología para hallar el punto óptimo de un problema de optimización.

Suponga un problema como el que plantea por medio de la Ecuación (**??**). El problema se plantea para mazimizar una función objetivo por medio de restricciones de desigualdad de tipo $\leq$.

- Dibujar las rectricciones de tipo $\leq$. Las rectas que resultan son el espacio de solución.
- En cada punto (cruce) se dibujan los gradientes de las restricciones y de la función objetivo.
- El punto óptimo se encuentra donde el gradiente de FO esté contenido por el cono formado por las restricciones activas.
- En la solución óptima, el gradiente de la función objetivo se encuentra dentro del cono formado por los gradientes de las restricciones activas en ese punto.
- La solución cumple la condición de KKT (Karush Kunt Tucker).
- El punto óptimo cumple la condición de KKT. Si las restricciones son de tipo lineal y FO es lineal, y además las variables son continuas y cumplen la condición de positividad, el punto KKT es un óptimo global del problema (solución).

Ejemplo 1.1. Se considera el siguiente problema:

$$\max z = 3x_1 + 4x_2$$

Sujeto a:

$$\begin{aligned} -x_1 + x_2 &\leq 2 \\ x_1 + x_2 &\leq 2 \\ x_1, x_2 &\geq 0 \end{aligned}$$

Los gradientes se calculan de la siguiente manera:

DRAFT

$$\nabla z = [3,4]$$
$$\nabla r_1 = [-1,1]$$
$$\nabla r_2 = [1,1]$$
$$\nabla r_3 = [-1,0]$$
$$\nabla r_4 = [0,-1]$$

Los valores óptimos corresponden a los puntos de intersecciòn de las restricciones:

$$x_{KKT1} = (0,2)$$
$$x_{KKT2} = (0,0)$$
$$x_{KKT3} = (0.5,2.5)$$
$$x_{KKT4} = (3,0)$$

La solución óptima se obtiene evaluando la función objetivo en los puntos factibles y verificando las condiciones de optimalidad.

1.7.2 Método simplex

El *método simplex* es un algoritmo que resuelve problemas de programación lineal, donde tanto la función objetivo como las restricciones son lineales. El método opera sobre los vértices de la región factible hasta encontrar la solución óptima.

1.7.2.1 Formulación del Problema

Función Objetivo:

$$\min(f(\bar{x})) = z = c_1x_1 + c_2x_2 + \cdots + c_nx_n = 0 \tag{1.2}$$

Transformación de Restricciones:

De la forma desigualdad:

$$\begin{gathered} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + \ldots + a_{1n}x_n \leq b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{13}x_3 + \ldots + a_{2n}x_n \leq b_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 + \ldots + a_{3n}x_n \leq b_3 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + a_{n3}x_3 + \ldots + a_{nn}x_n \leq b_n \end{gathered}$$

$$\begin{gathered} a_{11}x_1 + a_{12}x_2 + a_{13}x_3 + \ldots + a_{1n}x_n + s_1 = b_1 \\ a_{21}x_1 + a_{22}x_2 + a_{13}x_3 + \ldots + a_{2n}x_n + s_2 = b_2 \\ a_{31}x_1 + a_{32}x_2 + a_{33}x_3 + \ldots + a_{3n}x_n + s_3 = b_3 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + a_{n3}x_3 + \ldots + a_{nn}x_n + s_n = b_n \end{gathered}$$

DRAFT

1.7.2.2 Pivotaje

El *pivotaje* transforma un cuadro simplex en otro con una nueva base, siguiendo estos pasos:

Actualización de Base:

- Variable entrante: x_k
- Variable saliente: xB_r

Procedimiento:

1. Actualizar las variables básicas y sus valores.
2. Actualizar los costos relativos $(z_j - c_j)$ de las nuevas variables no básicas. (Pivotaje realiza todas estas operaciones simultáneamente). Sea x_k la variable que entra a la base y xB_r la variable que sale de la base, entonces la operación de pivotaje sigue la siguiente secuencia:
   (a) Divide la fila b_i entre cp_i.
   (b) Para ls filas $i = 1,2,3,\cdots m$ e $i \neq r$ se debe actualizar cada fila i adicionada a esa fila $-cp_i$ veces la nueva fila r. En otras palabras, realizar eliminación de Gauss a esa columna.
   (c) Actualizar la fila cero adicionada -$(z_j - c_j)$ veces la nueva fila r.

   Resultados:

   - Variables básicas: valores en columna derecha
   - Variables no básicas: valor cero
   - Función objetivo: valor actualizado en columna derecha

   Ejemplo 1.2. Maximizar $f(x) = 300x_1 + 100x_2$

$$
\begin{gathered}
s.a. \\
40x_1 + 8x_2 \leq 800 \\
10x_1 + 5x_2 \leq 320 \\
x_2 \leq 60 \\
x_1, x_2 \geq 0
\end{gathered}
$$

   Reescribir el problema de maximización: se debe igualar la función objetivo z a cero y convertir las restricciones de desigualdad en restricciones de igualdad.

$$
\begin{gathered}
z - 300x_1 - 100x_2 = 0 \\
40x_1 + 8x_2 + s_1 = 800 \\
10x_1 + 5x_2 + s_2 = 320 \\
x_2 + s_3 = 60
\end{gathered}
$$

DRAFT

En forma matricial:

$$\left(\begin{array}{c|cccccc} z & x_1 & x_2 & s_1 & s_2 & s_3 & b \\ \hline 1 & -300 & -100 & 0 & 0 & 0 & 0 \\ 0 & 40 & 8 & 1 & 0 & 0 & 800 \\ 0 & 10 & 5 & 0 & 1 & 0 & 320 \\ 0 & 0 & 1 & 0 & 0 & 1 & 60 \end{array}\right)$$

En la fila de la función objetivo, se selecciona el valor más negativo (en este caso, el valor de -300 en la columna 2). Esta columna se denomina *columna pivote*. Luego, se realiza la división de los términos de la columna b entre los términos de la columna pivote, es decir, $\frac{b_i}{cp_i}$. El valor más pequeño y positivo de estos cocientes determina la fila pivote.

A continuación, se muestra la matriz con los cálculos realizados para $\frac{b_i}{cp_i}$:

$$\begin{pmatrix} 40 & 800 & 20 \\ 10 & 320 & 32 \\ 0 & 60 & m \end{pmatrix}$$

En este caso, m es para indicar que no se realiza la división entre 0.

El siguiente paso es generar la matriz 1 pero cambiando la columna cp por una eliminación de Gauss.

$$\left(\begin{array}{c|cccccc} z & x_1 & x_2 & s_1 & s_2 & s_3 & b \\ \hline 1 & 0 & -40 & \frac{15}{2} & 0 & 0 & 6000 \\ 0 & 1 & \frac{1}{5} & \frac{1}{40} & 0 & 0 & 20 \\ 0 & 0 & 3 & \frac{-1}{4} & 1 & 0 & 120 \\ 0 & 0 & 1 & 0 & 0 & 1 & 60 \end{array}\right)$$

$$\left(\begin{array}{c|cccccc} z & x_1 & x_2 & s_1 & s_2 & s_3 & b \\ \hline 1 & 0 & 0 & \frac{25}{6} & \frac{40}{3} & 0 & 7600 \\ 0 & 1 & 0 & \frac{1}{24} & \frac{-1}{5} & 0 & 12 \\ 0 & 0 & 1 & \frac{-1}{12} & \frac{1}{3} & 0 & 40 \\ 0 & 0 & 0 & \frac{1}{12} & \frac{-1}{3} & 1 & 20 \end{array}\right)$$

La solución óptima global es $\overline{x} = [12;40]$, con $x_1 = 12$, $x_2 = 40$ y un valor máximo de $f(x) = 7600$ dentro de la región factible. Para verificar la actualización correcta del

DRAFT

método simplex, se observa el incremento de $f(x)$: $0 \to 6600 \to 7600$, asegurando además que $x_n \geq 0$.

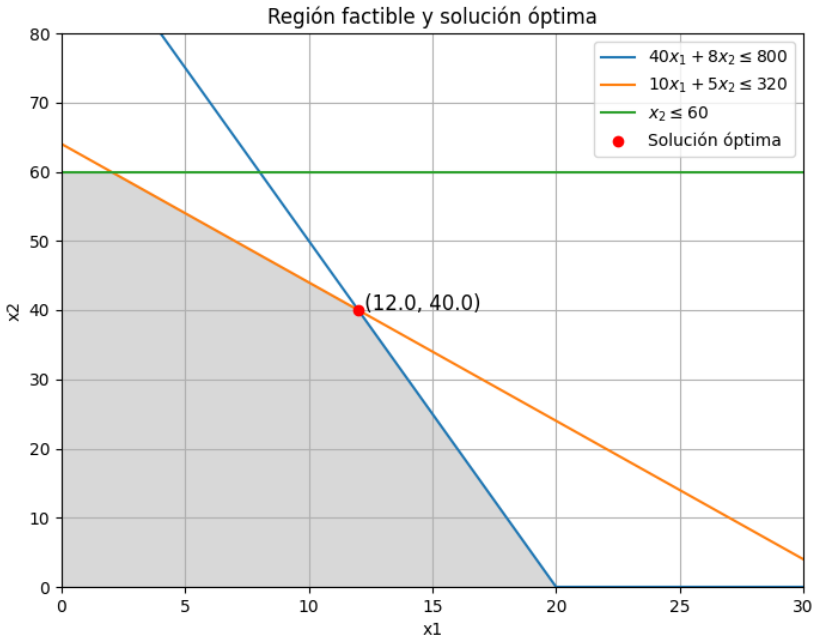


Figura 1.6: Método Simplex maximizado.

Ejemplo 1.3. Minimizar $f(x) = x_1 - 2x_2$

Sujeto a:

$$\begin{aligned} -x_1 + x_2 &\leq 2 \\ -x_1 + x_2 &\leq 6 \\ x_1, x_2 &\geq 0 \end{aligned}$$

Para aplicar el método simplex, se deben modificar los coeficientes de la función objetivo con signo contrario y convertir las restricciones de desigualdad en ecuaciones de igualdad introduciendo variables de holgura.

$$\begin{aligned} -x_1 + x_2 + s_1 &= 2 \\ -x_1 + x_2 + s_2 &= 6 \end{aligned}$$

En forma matricial:

$$\left(\begin{array}{c|cccccc} z & x_1 & x_2 & s_1 & s_2 & b \\ \hline 1 & -1 & 2 & 0 & 0 & 0 \\ 0 & -1 & 1 & 1 & 0 & 2 \\ 0 & -1 & 2 & 0 & 1 & 6 \end{array}\right)$$

$$\left(\begin{array}{c|cccccc} z & x_1 & x_2 & s_1 & s_2 & b \\ \hline 1 & 1 & 0 & -2 & 0 & -4 \\ 0 & -1 & 1 & 1 & 0 & 2 \\ 0 & 1 & 0 & -2 & 1 & 2 \end{array}\right)$$

$$\left(\begin{array}{c|cccccc} z & x_1 & x_2 & s_1 & s_2 & b \\ \hline 1 & 0 & 0 & 0 & -1 & -6 \\ 0 & 0 & 1 & -1 & 1 & 4 \\ 0 & 1 & 0 & -2 & 1 & 2 \end{array}\right)$$

La solución del problema de minimización es $\overline{x} = [2;4]$. $x_1 = 2$; $x_2 = 4$ con un valor minimo de $f = -6$. En el tipo de problemas de minimización, el cuadro simplex (matriz) se actualiza de manera correcta si la función objetivo dismimuye su valor y si las variables $x_n \geq 0$. El proceso iterativo termina cuando los costos de las variables del problema se hacen cero en la primera fila o cuando se pasa de un pivote a otro y se obtienen los resultados de cuadros anteriores.

DRAFT

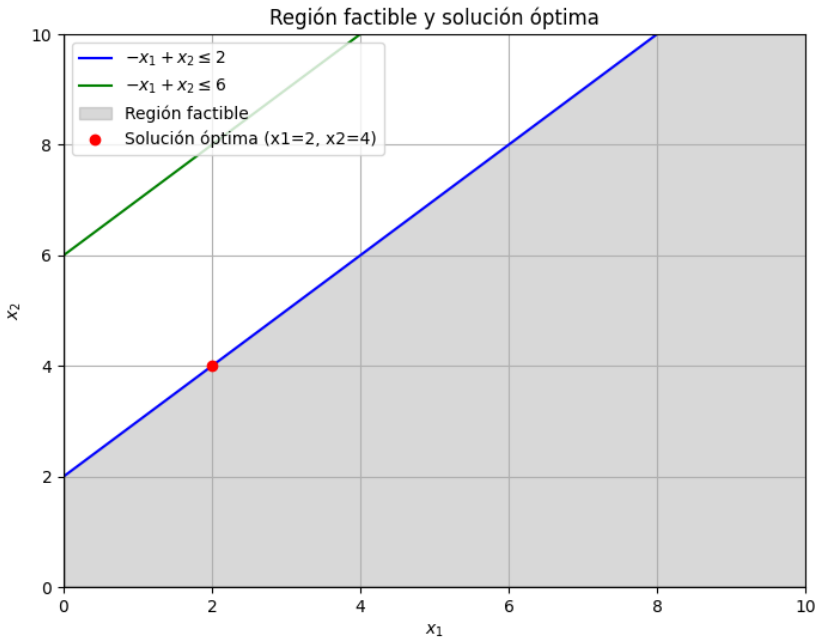


Figura 1.7: Método Simplex minimizado.

En este capítulo se han explorado diversos métodos de optimización numérica, tanto con como sin restricciones, abordando técnicas fundamentales como los multiplicadores de Lagrange, la penalización, los métodos de gradiente y cuasi-Newton, así como la programación lineal mediante el método simplex. Se ha analizado cómo los métodos sin restricciones permiten optimizar funciones sin condiciones adicionales, mientras que los métodos con restricciones incorporan limitaciones a través de enfoques como la penalización y los multiplicadores. Asimismo, se ha destacado la eficiencia de los algoritmos basados en gradientes y las aproximaciones cuasi-Newton para problemas más complejos. Finalmente, la programación lineal y el método simplex han proporcionado herramientas esenciales para resolver problemas en los que la función objetivo y las restricciones son lineales. Cada uno de estos enfoques posee aplicaciones específicas, y su elección depende de la naturaleza del problema a resolver. Con esta base teórica, en los siguientes capítulos se explorarán aplicaciones prácticas que demuestran la relevancia de la optimización en diversas disciplinas científicas e industriales.

BORRADOR

1.7.3 Ejercicios

1 Usando el método simplex resuelva los siguientes problemas de optimización de programación lineal.

i.
$$\begin{aligned} \min \quad & x_1 - 2x_2 - x_3 \\ \text{s.a.} \quad & \\ & x_1 + 2x_2 + x_3 \leq 12, \\ & 2x_1 + x_2 - x_3 \leq 5, \\ & -x_1 + 3x_2 \leq 9, \\ & x_1, x_2, x_3 \geq 0. \end{aligned}$$

ii.
$$\begin{aligned} \min \quad & -100x_1 - 10x_2 - x_3 \\ \text{s.a.} \quad & \\ & x_1 \leq 1, \\ & 20x_1 + x_2 \leq 100, \\ & 200x_1 + 20x_2 + x_3 \leq 10000, \\ & x_1, x_2, x_3 \geq 0. \end{aligned}$$

iii.
$$\begin{aligned} \min \quad & 4x_1 - 6x_2 \\ \text{s.a.} \quad & \\ & 5x_1 + x_2 \leq 6, \\ & x_1, x_2 \geq 0. \end{aligned}$$

2 Para cada uno de los siguientes problemas dibuje la región de solución y clasique de acuerdo a los visto en clase (regiones factibles, infactibles, limitadas, ilimitadas).

i.
$$\begin{aligned} \min \quad & -3x_1 - 5x_2 \\ \text{s.a.} \quad & \\ & x_1 + x_2 \leq 5, \\ & -2x_1 + x_2 \leq 2, \\ & x_1, x_2 \geq 0. \end{aligned}$$

ii.
$$\begin{aligned} \min \quad & 3x_1 - 5x_2 \\ \text{s.a.} \quad & \\ & x_1 + x_2 \leq 5, \\ & -2x_1 + x_2 \leq 2, \\ & x_1, x_2 \geq 0. \end{aligned}$$

DRAFT

iii.

$$\begin{aligned} \min \quad & -2x_1 - 4x_2 \\ \text{s.a.} \quad & \\ & 3x_1 + 4x_2 \leq 12, \\ & 2x_1 - x_2 \leq 4, \\ & x_1, x_2 \geq 0. \end{aligned}$$

iv.

$$\begin{aligned} \min \quad & 4x_1 - 6x_2 \\ \text{s.a.} \quad & \\ & 2x_1 + x_2 \leq 1, \\ & 5x_1 + x_2 \leq 6, \\ & x_1, x_2 \geq 0. \end{aligned}$$

v.

$$\begin{aligned} \min \quad & 4x_1 - 6x_2 \\ \text{s.a.} \quad & \\ & 2x_1 + x_2 \leq 1, \\ & 3x_1 + x_2 \geq 3, \\ & 5x_1 + x_2 \leq 6, \\ & 7x_1 + x_2 \geq 4, \\ & 9x_1 + x_2 \geq 5, \\ & x_1, x_2 \geq 0. \end{aligned}$$

DRAFT

2 Estructuras convexas, dualidad y condiciones de optimalidad

La optimización convexa permite formular problemas a partir de la geometría de sus regiones factibles. En este capítulo se estudian distintas clases de conjuntos convexos que aparecen en optimización: poliedros, conos de segundo orden, matrices positivas semidefinidas y espectraedros. Estas estructuras permiten representar, de manera progresivamente más general, problemas de programación lineal, de segundo orden y semidefinida.

La relación entre estas clases se resume en la jerarquía

$$\text{Poliedros} \subseteq \text{Convexos de segundo orden} \subseteq \text{Espectraedros} \subseteq \text{Convexos}.$$

El objetivo es presentar sus propiedades fundamentales y las relaciones que existen entre ellas, como base para el estudio posterior de problemas de optimización.

2.1 Conjuntos convexos y poliedros

Si V es un espacio vectorial, definimos

$$\mathscr{C}(V) = \{A \subseteq V : A \text{ es convexo}\}.$$

Teorema 1. *(Operaciones que preservan convexidad)*

DRAFT

(a) **Intersección**
Si

$$\{A_i : i \in I\} \subseteq \mathscr{C}(V),$$

entonces

$$\bigcap_{i\in I} A_i \in \mathscr{C}(V).$$

(b) **Suma de Minkowski**
Si

$$A, B \in \mathscr{C}(V),$$

entonces

$$A + B \in \mathscr{C}(V),$$

donde

$$A + B = \{a + b : a \in A,\ b \in B\}.$$

(c) **Productos cartesianos**
Si

$$A \in \mathscr{C}(U), \qquad B \in \mathscr{C}(V),$$

entonces

$$A \times B \in \mathscr{C}(U \times V).$$

(d) **Imagen directa e inversa bajo mapas afines**
Si

$$f : U \longrightarrow V$$

es afín, entonces

$$A \in \mathscr{C}(U) \implies f(A) \in \mathscr{C}(V),$$

y

$$B \in \mathscr{C}(V) \implies f^{-1}(B) \in \mathscr{C}(U).$$

Ejercicio 1. Demuestre el teorema anterior.

Solución 1. Sea $t \in [0,1]$.

(a) **Intersección.**
Sean

$$x, y \in \bigcap_{i\in I} A_i.$$

Entonces $x, y \in A_i$ para todo $i \in I$. Como cada A_i es convexo,

$$tx + (1-t)y \in A_i, \qquad \forall i \in I.$$

Por tanto,

$$tx + (1-t)y \in \bigcap_{i\in I} A_i.$$

DRAFT

Luego,

$$\bigcap_{i\in I} A_i$$

es convexo.

(b) **Suma de Minkowski.**
Sean $x, y \in A+B$. Entonces existen $a_1, a_2 \in A$ y $b_1, b_2 \in B$ tales que

$$x = a_1 + b_1, \qquad y = a_2 + b_2.$$

Por lo tanto,

$$\begin{aligned} tx+(1-t)y &= t(a_1+b_1)+(1-t)(a_2+b_2) \\ &= \big(ta_1+(1-t)a_2\big)+\big(tb_1+(1-t)b_2\big). \end{aligned}$$

Como A y B son convexos,

$$ta_1+(1-t)a_2 \in A, \qquad tb_1+(1-t)b_2 \in B.$$

Así,

$$tx+(1-t)y \in A+B.$$

Por consiguiente, $A+B$ es convexo.

(c) **Producto cartesiano.**
Sean

$$(x_1,y_1),(x_2,y_2) \in A\times B.$$

Entonces $x_1, x_2 \in A$ y $y_1, y_2 \in B$. Como ambos conjuntos son convexos,

$$tx_1+(1-t)x_2 \in A$$

y

$$ty_1+(1-t)y_2 \in B.$$

Luego,

$$t(x_1,y_1)+(1-t)(x_2,y_2) = \big(tx_1+(1-t)x_2,\, ty_1+(1-t)y_2\big) \in A\times B.$$

Por tanto, $A\times B$ es convexo.

(d) **Imagen directa e inversa bajo mapas afines.**
Sea $f : U \to V$ afín.
Primero, sea $A \subseteq U$ convexo y sean

$$u, v \in f(A).$$

Existen $x, y \in A$ tales que $u = f(x)$ y $v = f(y)$. Entonces

$$\begin{aligned} tu+(1-t)v &= tf(x)+(1-t)f(y) \\ &= f\big(tx+(1-t)y\big). \end{aligned}$$

DRAFT

Como A es convexo,

$$tx+(1-t)y \in A,$$

de donde

$$tu+(1-t)v \in f(A).$$

Así, $f(A)$ es convexo.
Ahora sea $B \subseteq V$ convexo y sean

$$x,y \in f^{-1}(B).$$

Entonces

$$f(x), f(y) \in B.$$

Por convexidad de B,

$$tf(x)+(1-t)f(y) \in B.$$

Como f es afín,

$$f\big(tx+(1-t)y\big) = tf(x)+(1-t)f(y) \in B.$$

Por tanto,

$$tx+(1-t)y \in f^{-1}(B),$$

y $f^{-1}(B)$ es convexo.

Ejemplo 1. Ejemplos de conjuntos convexos. Sea

$$f : V \longrightarrow \mathbb{R}$$

una aplicación afín.
Definimos el semiespacio abierto

$$H_- := f^{-1}\big((-\infty,0)\big) = \{v \in V : f(v) < 0\}.$$

Análogamente, el semiespacio cerrado es

$$\overline{H}_- := f^{-1}\big((-\infty,0]\big) = H_- \cup H.$$

2.1.1 Poliedros

Definición 1. Un conjunto $P \subseteq V$ se denomina *poliedro* si puede expresarse como la intersección de un número finito de semiespacios cerrados. Equivalentemente, existen funciones afines

$$f_1, \ldots, f_m : V \longrightarrow \mathbb{R}$$

tales que

$$P = \{x \in V : f_i(x) \leq 0, \quad i = 1, \ldots, m\}.$$

DRAFT

Ejercicio 2. Para $m \in \mathbb{N}$, definamos el ortante positivo

$$O_m = \{x \in \mathbb{R}^m : x_1 \geq 0, \ldots, x_m \geq 0\}.$$

Equivalentemente,

$$O_m = \underbrace{O_1 \times \cdots \times O_1}_{m \text{ veces}}.$$

Demuestre que $P \subseteq \mathbb{R}^n$ es un poliedro si y sólo si existen

$$m = m(P) \in \mathbb{N}$$

y una aplicación afín

$$f : \mathbb{R}^n \longrightarrow \mathbb{R}^m$$

tales que

$$\boxed{P = f^{-1}(O_m)}.$$

Solución 2. Recordemos que

$$O_m = \{y = (y_1, \ldots, y_m) \in \mathbb{R}^m : y_i \geq 0, \quad i = 1, \ldots, m\}.$$

Demostraremos ambas implicaciones.

($\Rightarrow$) Supongamos que $P \subseteq \mathbb{R}^n$ es un poliedro. Por definición, existen funciones afines

$$g_1, \ldots, g_m : \mathbb{R}^n \longrightarrow \mathbb{R}$$

tales que

$$P = \{x \in \mathbb{R}^n : g_i(x) \leq 0, \quad i = 1, \ldots, m\}.$$

Definamos

$$f : \mathbb{R}^n \longrightarrow \mathbb{R}^m$$

mediante

$$f(x) = \big(-g_1(x), \ldots, -g_m(x)\big).$$

Como cada g_i es afín, la aplicación f también es afín. Además,

$$\begin{aligned} x \in P &\iff g_i(x) \leq 0 \quad \forall i \\ &\iff -g_i(x) \geq 0 \quad \forall i \\ &\iff f(x) \in O_m. \end{aligned}$$

Por tanto,

$$P = f^{-1}(O_m).$$

DRAFT

($\Leftarrow$) Supongamos ahora que existe una aplicación afín

$$f : \mathbb{R}^n \longrightarrow \mathbb{R}^m$$

tal que

$$P = f^{-1}(O_m).$$

Escribamos f en términos de sus funciones coordenadas:

$$f(x) = \big(f_1(x), \ldots, f_m(x)\big),$$

donde cada

$$f_i : \mathbb{R}^n \longrightarrow \mathbb{R}$$

es afín.

Entonces

$$\begin{aligned} x \in P &\Longleftrightarrow f(x) \in O_m \\ &\Longleftrightarrow f_i(x) \geq 0, \qquad i = 1, \ldots, m. \end{aligned}$$

En consecuencia,

$$P = \bigcap_{i=1}^{m} \{x \in \mathbb{R}^n : f_i(x) \geq 0\}.$$

Cada conjunto

$$\{x \in \mathbb{R}^n : f_i(x) \geq 0\}$$

es un semiespacio cerrado. Por tanto, P es una intersección finita de semiespacios cerrados y, en consecuencia, es un poliedro.

Así,

$$\boxed{P \text{ es un poliedro } \Longleftrightarrow \exists m \in \mathbb{N},\ \exists f : \mathbb{R}^n \to \mathbb{R}^m \text{ afín tal que } P = f^{-1}(O_m).}$$

2.1.2 Bolas unitarias de normas

Supongamos que

$$\dim(V) < \infty.$$

Una función

$$\|\cdot\| : V \longrightarrow \mathbb{R}$$

es una norma si satisface:

(a)

$$\|v\| \geq 0 \qquad \text{y} \qquad \|v\| = 0 \Longleftrightarrow v = 0.$$

(positiva definida)

DRAFT

(b)

$$\|u+v\| \leq \|u\| + \|v\|.$$

(desigualdad triangular)

(c)

$$\|\lambda u\| = |\lambda| \, \|u\|.$$

(positivamente homogénea)

Observe que

$$\|\cdot\|$$

es una función convexa.
La bola unitaria de la norma es

$$B_{\|\cdot\|} = \{v \in V : \|v\| \leq 1\},$$

y es un conjunto convexo.

Ejemplo 2. Para la norma euclídea en $\mathbb{R}^n$,

$$\|\mathbf{x}\|_2 = \sqrt{\mathbf{x} \cdot \mathbf{x}}.$$

Su bola unitaria es

$$B_2 = \{\mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\|_2 \leq 1\}.$$

Ejercicio 3. Suponga que $n \geq 2$. Pruebe que la bola unitaria

$$B_2 = \{x \in \mathbb{R}^n : \|x\|_2 \leq 1\}$$

no es un poliedro.

Solución 3. Supongamos, por contradicción, que B_2 es un poliedro. Entonces existen $m \in \mathbb{N}$, vectores $a_1, \ldots, a_m \in \mathbb{R}^n$ y escalares $b_1, \ldots, b_m \in \mathbb{R}$ tales que

$$B_2 = \bigcap_{i=1}^{m} \left\{x \in \mathbb{R}^n : a_i^T x \leq b_i\right\}.$$

Como cada uno de estos semiespacios contiene a B_2, para todo $y \in B_2$ se cumple

$$a_i^T y \leq b_i.$$

En particular,

$$\max_{\|y\|_2 \leq 1} a_i^T y = \|a_i\|_2,$$

por lo que

$$b_i \geq \|a_i\|_2.$$

DRAFT

Sea ahora $x \in \partial B_2$, es decir,

$$\|x\|_2 = 1.$$

Como x pertenece a la frontera del poliedro, al menos una de las restricciones debe ser activa. Por tanto, para algún i,

$$a_i^T x = b_i.$$

Por la desigualdad de Cauchy–Schwarz,

$$b_i = a_i^T x \leq \|a_i\|_2 \|x\|_2 = \|a_i\|_2.$$

Junto con $b_i \geq \|a_i\|_2$, obtenemos

$$b_i = \|a_i\|_2.$$

En consecuencia, se alcanza la igualdad en Cauchy–Schwarz, lo cual implica

$$x = \frac{a_i}{\|a_i\|_2}.$$

Por tanto, cada desigualdad que define al poliedro puede determinar a lo sumo un punto de la esfera unitaria. Como existen solamente m desigualdades, la frontera tendría a lo sumo m puntos de este tipo.

Sin embargo, para $n \geq 2$ la esfera

$$S^{n-1} = \{x \in \mathbb{R}^n : \|x\|_2 = 1\}$$

contiene infinitos puntos. Esto es una contradicción.

Por consiguiente,

$$\boxed{B_2 \text{ no es un poliedro para } n \geq 2.}$$

Teorema 2. Hay una correspondencia entre

$$\{\|\cdot\| : V \longrightarrow \mathbb{R} : \|\cdot\| \text{ es una norma}\}$$

y

$$\left\{ K \subseteq V : \begin{array}{l} K \text{ compacto}, \\ K \text{ convexo}, \\ K = -K, \\ 0 \in \operatorname{Int}(K) \end{array} \right\}.$$

La correspondencia está dada por

$$\|\cdot\| \longmapsto \{v \in V : \|v\| \leq 1\}.$$

Ejercicio 4. Demuestre el teorema anterior.

DRAFT

Solución 4. Demostraremos las dos direcciones de la correspondencia.

1. De una norma a un conjunto convexo.

Sea $\|\cdot\|$ una norma sobre V y definamos su bola unitaria por

$$K = \{x \in V : \|x\| \leq 1\}.$$

Veamos que K satisface las propiedades del enunciado.

Sean $x, y \in K$ y $\lambda \in [0,1]$. Por la desigualdad triangular y la homogeneidad de la norma,

$$\begin{aligned}\|\lambda x + (1-\lambda)y\| &\leq \lambda\|x\| + (1-\lambda)\|y\| \\ &\leq \lambda + (1-\lambda) = 1.\end{aligned}$$

Por tanto,

$$\lambda x + (1-\lambda)y \in K,$$

y K es convexo.

Además,

$$\|-x\| = \|x\|,$$

por lo que

$$x \in K \quad \Longleftrightarrow \quad -x \in K.$$

En consecuencia,

$$K = -K.$$

Por otra parte,

$$\{x \in V : \|x\| < 1\} \subseteq K,$$

de donde

$$0 \in \mathrm{Int}(K).$$

Finalmente, K es cerrado y acotado. Como V tiene dimensión finita, se concluye que K es compacto.

Así, la bola unitaria de toda norma satisface

$$K \text{ compacto}, \qquad K \text{ convexo}, \qquad K = -K, \qquad 0 \in \mathrm{Int}(K).$$

DRAFT

2. De un conjunto convexo a una norma.

Supongamos ahora que $K \subseteq V$ es compacto y convexo, que

$$K = -K$$

y que

$$0 \in \text{Int}(K).$$

Definimos el funcional de Minkowski de K mediante

$$p_K(x) = \inf\{t > 0 : x \in tK\}.$$

Como $0 \in \text{Int}(K)$, el conjunto K es absorbente: para todo $x \in V$ existe $t > 0$ tal que $x \in tK$. Por tanto, $p_K(x)$ está bien definido y es finito.

Claramente,

$$p_K(x) \geq 0$$

y

$$p_K(0) = 0.$$

Supongamos que $p_K(x) = 0$. Entonces existen $t_j > 0$, con $t_j \to 0$, y $y_j \in K$ tales que

$$x = t_j y_j.$$

Como K es compacto, es acotado. Por tanto, existe $M > 0$ tal que

$$\|y_j\| \leq M$$

para alguna norma auxiliar sobre V. Así,

$$\|x\| = t_j \|y_j\| \leq t_j M \longrightarrow 0.$$

Luego,

$$x = 0.$$

Por consiguiente,

$$p_K(x) = 0 \quad \Longleftrightarrow \quad x = 0.$$

Sea ahora $\alpha > 0$. Entonces

DRAFT

$$\begin{aligned} p_K(\alpha x) &= \inf\{t > 0 : \alpha x \in tK\} \\ &= \alpha \inf\{s > 0 : x \in sK\} \\ &= \alpha p_K(x). \end{aligned}$$

Como $K = -K$,

$$p_K(-x) = p_K(x).$$

Por tanto, para todo $\alpha \in \mathbb{R}$,

$$p_K(\alpha x) = |\alpha| p_K(x).$$

Finalmente, sean $a > p_K(x)$ y $b > p_K(y)$ tales que

$$x \in aK, \qquad y \in bK.$$

Existen $u, v \in K$ tales que

$$x = au, \qquad y = bv.$$

Entonces

$$\frac{x+y}{a+b} = \frac{a}{a+b}u + \frac{b}{a+b}v.$$

Como K es convexo,

$$\frac{x+y}{a+b} \in K.$$

Por tanto,

$$x + y \in (a+b)K,$$

de donde

$$p_K(x+y) \leq a+b.$$

Haciendo

$$a \downarrow p_K(x), \qquad b \downarrow p_K(y),$$

obtenemos

$$p_K(x+y) \leq p_K(x) + p_K(y).$$

Así, p_K es una norma sobre V.

DRAFT

3. Identificación de la bola unitaria.
Si $x \in K$, entonces $x \in 1K$, y por tanto

$$p_K(x) \leq 1.$$

Recíprocamente, si $p_K(x) \leq 1$, existen $t_j \to p_K(x)$ tales que

$$x \in t_j K.$$

Como K es cerrado, pasando al límite se obtiene

$$x \in K.$$

Por consiguiente,

$$K = \{x \in V : p_K(x) \leq 1\}.$$

Finalmente, si partimos de una norma $\|\cdot\|$ y tomamos

$$K = \{x \in V : \|x\| \leq 1\},$$

entonces

$$x \in tK \quad \Longleftrightarrow \quad \|x\| \leq t.$$

De aquí,

$$p_K(x) = \inf\{t > 0 : \|x\| \leq t\} = \|x\|.$$

Por tanto, ambas construcciones son inversas entre sí y se establece la correspondencia afirmada.

Definición 2. Para $k \in \mathbb{N}$, sea

$$V_k := \mathbb{R}^k.$$

El conjunto

$$E_k = \{(v, \alpha) \in V_k \times \mathbb{R} : \|v\|_2 \leq \alpha\}$$

se denomina *cono de segundo orden* o *cono de Lorentz*.

Como la función

$$v \longmapsto \|v\|_2$$

es convexa, E_k es un conjunto convexo, pues corresponde al epígrafo de dicha función.

DRAFT

Definición 3. Un conjunto $P \subseteq \mathbb{R}^n$ se denomina *representable mediante conos de segundo orden* si existen

$$m \in \mathbb{N}, \qquad k_1, \ldots, k_m \in \mathbb{N},$$

y una aplicación afín

$$f : \mathbb{R}^n \longrightarrow (V_{k_1} \times \mathbb{R}) \times \cdots \times (V_{k_m} \times \mathbb{R})$$

tales que

$$P = f^{-1}\left(E_{k_1} \times \cdots \times E_{k_m}\right).$$

Ejercicio 5. Demuestre que todo poliedro es representable mediante conos de segundo orden.

Solución 5. Sea $P \subseteq \mathbb{R}^n$ un poliedro. Por definición, existen funciones afines

$$g_1, \ldots, g_m : \mathbb{R}^n \longrightarrow \mathbb{R}$$

tales que

$$P = \{x \in \mathbb{R}^n : g_i(x) \leq 0, \quad i = 1, \ldots, m\}.$$

Recordemos que

$$E_1 = \{(v, \alpha) \in \mathbb{R} \times \mathbb{R} : |v| \leq \alpha\}.$$

En particular,

$$(0, \alpha) \in E_1 \quad \Longleftrightarrow \quad \alpha \geq 0.$$

Definamos la aplicación

$$F : \mathbb{R}^n \longrightarrow (\mathbb{R} \times \mathbb{R})^m$$

mediante

$$F(x) = \big((0, -g_1(x)), \ldots, (0, -g_m(x))\big).$$

Como cada g_i es afín, F también es una aplicación afín.
Para cada i,

$$\begin{aligned}(0, -g_i(x)) \in E_1 &\Longleftrightarrow |0| \leq -g_i(x) \\ &\Longleftrightarrow g_i(x) \leq 0.\end{aligned}$$

Por tanto,

DRAFT

$$\begin{aligned} x \in P &\iff g_i(x) \leq 0, \qquad i = 1, \ldots, m, \\ &\iff (0, -g_i(x)) \in E_1, \qquad i = 1, \ldots, m, \\ &\iff F(x) \in E_1 \times \cdots \times E_1. \end{aligned}$$

En consecuencia,

$$\boxed{P = F^{-1}(E_1 \times \cdots \times E_1).}$$

Así, P es representable mediante conos de segundo orden.

Ejemplo 3. Considere la aplicación afín

$$f : \mathbb{R}^2 \longrightarrow \mathbb{R}^2 \times \mathbb{R}$$

definida por

$$f(x,y) = ((x,y),5).$$

Entonces

$$f^{-1}(E_2) = \left\{(x,y) \in \mathbb{R}^2 : \|(x,y)\|_2 \leq 5\right\}.$$

Por tanto, el disco euclídeo de radio 5 es un convexo de segundo orden.

Ejemplo 4. Considere la aplicación afín

$$f_0 : \mathbb{R}^3 \longrightarrow (\mathbb{R}^2 \times \mathbb{R}) \times (\mathbb{R}^2 \times \mathbb{R})$$

dada por

$$f_0(x,y,z) = \big(((x,y),1), ((x,z),1)\big).$$

Entonces

$$P = f_0^{-1}(E_2 \times E_2),$$

es decir,

$$P = \left\{ (x,y,z) \in \mathbb{R}^3 : \begin{array}{l} \|(x,y)\|_2 \leq 1, \\ \|(x,z)\|_2 \leq 1 \end{array} \right\}.$$

2.1.3 Polinomios no negativos

Fijamos enteros n y d y definimos. Sea

$\mathbb{R}[\mathbf{x}]_d = \mathbb{R}[x_1, \ldots, x_n]_d = \{\text{polinomios homogéneos de grado } d \text{ en las variables } x_1, \ldots, x_n\}$.

Definimos

$$P_d^n = \{f \in \mathbb{R}[x_1, \ldots, x_n]_d : f(u) \geq 0 \quad \forall u \in \mathbb{R}^n\}.$$

DRAFT

Definición 4. El *coeficiente binomial*

$$\binom{n}{k}$$

representa el número de formas de seleccionar k elementos de un conjunto de n elementos, sin tener en cuenta el orden.

Se define por

$$\boxed{\binom{n}{k} = \frac{n!}{k!(n-k)!}}$$

para $0 \leq k \leq n$.

Por ejemplo,

$$\binom{5}{2} = \frac{5!}{2!3!} = 10.$$

Por tanto, existen 10 formas distintas de seleccionar 2 elementos de un conjunto de 5 elementos.

Ejercicio 6. (a) Demuestre que $\mathbb{R}[\mathbf{x}]_d$ es un espacio vectorial de dimensión

$$\binom{n-1+d}{d}.$$

(b) Demuestre que

$$P_d^n \subseteq \mathbb{R}[\mathbf{x}]_d$$

es convexo y cerrado.

Solución 6. (a) Todo polinomio homogéneo de grado d en n variables puede escribirse de manera única como

$$f(x_1,\ldots,x_n) = \sum_{|\alpha|=d} c_\alpha x^\alpha,$$

donde

$$\alpha = (\alpha_1,\ldots,\alpha_n) \in \mathbb{N}_0^n, \qquad |\alpha| = \alpha_1 + \cdots + \alpha_n,$$

y

$$x^\alpha = x_1^{\alpha_1} \cdots x_n^{\alpha_n}.$$

Por tanto, una base de $\mathbb{R}[\mathbf{x}]_d$ está formada por los monomios

$$x_1^{\alpha_1} \cdots x_n^{\alpha_n}$$

tales que

$$\alpha_1 + \cdots + \alpha_n = d, \qquad \alpha_i \geq 0.$$

DRAFT

En consecuencia, la dimensión de $\mathbb{R}[\mathbf{x}]_d$ es igual al número de soluciones enteras no negativas de

$$\alpha_1 + \cdots + \alpha_n = d.$$

Por el principio combinatorio de estrellas y barras, dicho número es

$$\binom{d+n-1}{n-1} = \binom{d+n-1}{d}.$$

Por tanto,

$$\boxed{\dim \mathbb{R}[\mathbf{x}]_d = \binom{n-1+d}{d}.}$$

(b) Recordemos que

$$P_d^n = \{f \in \mathbb{R}[\mathbf{x}]_d : f(u) \geq 0 \quad \forall u \in \mathbb{R}^n\}.$$

Convexidad. Sean $f, g \in P_d^n$ y sea $\lambda \in [0,1]$. Para todo $u \in \mathbb{R}^n$,

$$\begin{aligned}\big(\lambda f + (1-\lambda)g\big)(u) &= \lambda f(u) + (1-\lambda)g(u) \\ &\geq 0.\end{aligned}$$

Además, $\lambda f + (1-\lambda)g$ es homogéneo de grado d. Por consiguiente,

$$\lambda f + (1-\lambda)g \in P_d^n.$$

Así,

$$P_d^n$$

es convexo.

Cerradura. Para cada $u \in \mathbb{R}^n$, definamos la aplicación de evaluación

$$L_u : \mathbb{R}[\mathbf{x}]_d \longrightarrow \mathbb{R}, \qquad L_u(f) = f(u).$$

La aplicación L_u es lineal y continua. Por tanto,

$$H_u := \{f \in \mathbb{R}[\mathbf{x}]_d : f(u) \geq 0\} = L_u^{-1}\big([0,\infty)\big)$$

es un conjunto cerrado.
Ahora bien,

$$P_d^n = \bigcap_{u \in \mathbb{R}^n} H_u.$$

Como una intersección arbitraria de conjuntos cerrados es cerrada, se concluye que

$$P_d^n$$

es cerrado.
Por tanto,

$$\boxed{P_d^n \text{ es convexo y cerrado en } \mathbb{R}[\mathbf{x}]_d.}$$

DRAFT

Este conjunto convexo es **muy importante** porque nos permite modelar muchísimos problemas, pero tiene una estructura muy compleja, en el sentido de que, dado un polinomio

$$f \in \mathbb{R}[x_1, \ldots, x_n]_d,$$

no es fácil saber si

$$f \in P_d^n.$$

2.1.4 Caso especial: Matrices PSD

Definición 5. Sea $A \in \mathbb{R}^{n \times n}$ una matriz simétrica. Se dice que A es *positiva semidefinida* (PSD) si

$$\mathbf{x}^T A \mathbf{x} \geq 0 \qquad \forall \mathbf{x} \in \mathbb{R}^n.$$

En este caso escribimos

$$A \succeq 0.$$

Equivalentemente, la forma cuadrática

$$q_A(\mathbf{x}) = \mathbf{x}^T A \mathbf{x}$$

pertenece al cono P_2^n de formas cuadráticas no negativas.

$$P_2^n = \{\text{formas cuadráticas no negativas en } \mathbb{R}^n\}.$$

Ejemplo 5. Consideremos la forma cuadrática

$$(x-y)^2.$$

Desarrollando,

$$(x-y)^2 = x^2 - 2xy + y^2.$$

Esta expresión puede escribirse matricialmente como

$$(x-y)^2 = \begin{pmatrix} x & y \end{pmatrix} \begin{pmatrix} 1 & -1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} x \\ y \end{pmatrix}.$$

DRAFT

En general, toda forma cuadrática en $\mathbb{R}^n$ se puede escribir de manera única como

$$\boxed{\mathbf{x}^T A\mathbf{x}}$$

donde A es una matriz simétrica.

Definición 6. Una matriz simétrica A de $n \times n$ se dice *positiva semidefinida* (PSD) si

$$\mathbf{x}^T A\mathbf{x} \in P_2^n.$$

Usaremos la notación

$$A \succeq 0.$$

Es decir,

$$\boxed{\mathbf{x}^T A\mathbf{x} \geq 0 \qquad \forall \mathbf{x} \in \mathbb{R}^n.}$$

Teorema 3 (Caracterizaciones de matrices PSD)**.** Las siguientes afirmaciones son equivalentes para una matriz simétrica A de $n \times n$:

(a)
$$A \succeq 0,$$
es decir, A es PSD.

(b) Los valores propios de A son reales y no negativos.

(c) Existe una matriz
$$B \in \mathbb{R}^{k \times n}$$
tal que
$$\boxed{A = B^T B.}$$

Ejercicio 7. (a) Demuestre el teorema anterior. **Sugerencia:** recuerde que toda matriz simétrica real es ortogonalmente diagonalizable.

(b) Demuestre que una forma cuadrática es PSD si y sólo si es una suma de cuadrados de formas lineales.

Solución 7. (a) Demostraremos las implicaciones

$$(1) \Longrightarrow (2) \Longrightarrow (3) \Longrightarrow (1).$$

$(1) \Rightarrow (2)$**.** Supongamos que
$$A \succeq 0.$$
Sea λ un valor propio de A y sea $v \neq 0$ un vector propio asociado. Entonces
$$Av = \lambda v.$$

DRAFT

Por tanto,

$$v^T Av = v^T(\lambda v) = \lambda v^T v = \lambda \|v\|_2^2.$$

Como $A \succeq 0$,

$$v^T Av \geq 0.$$

Luego,

$$\lambda \|v\|_2^2 \geq 0.$$

Como $v \neq 0$, se tiene $\|v\|_2^2 > 0$, y por tanto

$$\lambda \geq 0.$$

Así, todos los valores propios de A son no negativos.

$(2) \Rightarrow (3)$**.** Supongamos que todos los valores propios de A son no negativos. Como A es simétrica, por el teorema espectral existe una matriz ortogonal Q y una matriz diagonal

$$D = \text{diag}(\lambda_1, \ldots, \lambda_n)$$

tales que

$$A = QDQ^T,$$

donde

$$\lambda_i \geq 0, \qquad i = 1, \ldots, n.$$

Definimos

$$D^{1/2} = \text{diag}\left(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_n}\right).$$

Sea

$$B = D^{1/2} Q^T.$$

Entonces

$$B^T = QD^{1/2},$$

y por tanto

$$\begin{aligned} B^T B &= QD^{1/2} D^{1/2} Q^T \\ &= QDQ^T \\ &= A. \end{aligned}$$

Por consiguiente,

$$A = B^T B.$$

$(3) \Rightarrow (1)$**.** Supongamos que existe una matriz

$$B \in \mathbb{R}^{k \times n}$$

tal que

$$A = B^T B.$$

DRAFT

Para cualquier $x \in \mathbb{R}^n$,

$$\begin{aligned} x^T Ax &= x^T B^T Bx \\ &= (Bx)^T (Bx) \\ &= \|Bx\|_2^2 \\ &\geq 0. \end{aligned}$$

Por tanto,

$$A \succeq 0.$$

Así,

$$\boxed{A \succeq 0 \iff \lambda_i(A) \geq 0 \iff A = B^T B.}$$

(b) Sea

$$q(x) = x^T Ax$$

una forma cuadrática.
Supongamos primero que q es positiva semidefinida. Entonces

$$A \succeq 0.$$

Por la parte anterior, existe

$$B \in \mathbb{R}^{k \times n}$$

tal que

$$A = B^T B.$$

Por tanto,

$$q(x) = x^T Ax = x^T B^T Bx = \|Bx\|_2^2.$$

Si las filas de B son

$$b_1^T, \ldots, b_k^T,$$

entonces

$$Bx = \begin{pmatrix} b_1^T x \\ \vdots \\ b_k^T x \end{pmatrix},$$

y por consiguiente

$$q(x) = (b_1^T x)^2 + \cdots + (b_k^T x)^2.$$

Así, q es una suma de cuadrados de formas lineales.
Recíprocamente, supongamos que

$$q(x) = \ell_1(x)^2 + \cdots + \ell_k(x)^2,$$

donde cada ℓ_i es una forma lineal.

DRAFT

Entonces, para todo $x \in \mathbb{R}^n$,

$$q(x) = \sum_{i=1}^{k} \ell_i(x)^2 \geq 0.$$

Por tanto, q es positiva semidefinida.
En consecuencia,

$$\boxed{q \text{ es PSD} \iff q \text{ es una suma de cuadrados de formas lineales.}}$$

Definición 7. Para $m \in \mathbb{N}$, definimos

$$S^2(V_m) = \left\{A \in \mathbb{R}^{m\times m} : A = A^T\right\},$$

el espacio vectorial de matrices simétricas de orden m.
Su dimensión es

$$\dim S^2(V_m) = \frac{m(m+1)}{2}.$$

El cono de matrices positivas semidefinidas se define como

$$S^+(V_m) = \left\{A \in S^2(V_m) : A \succeq 0\right\}.$$

Definición 8. Un conjunto $P \subseteq \mathbb{R}^n$ se denomina *espectraedro* si existen matrices simétricas

$$A_0, A_1, \ldots, A_n \in S^2(V_m)$$

para algún $m \in \mathbb{N}$, tales que

$$P = \{x = (x_1, \ldots, x_n) \in \mathbb{R}^n : A_0 + x_1A_1 + \cdots + x_nA_n \succeq 0\}.$$

Los espectraedros constituyen las regiones factibles naturales de los problemas de optimización semidefinida.

Ejercicio 8. (a) Demuestre que, para $\mathbf{w} \in \mathbb{R}^n$ y $R \in \mathbb{R}$,

$$\begin{pmatrix} RI_{n\times n} & \mathbf{w} \\ \mathbf{w}^T & R \end{pmatrix} \succeq 0$$

si y sólo si

$$\|\mathbf{w}\|_2 \leq R.$$

(b) Demuestre que todo convexo de segundo orden es un espectraedro.

DRAFT

Solución 8. (a) Definamos

$$M = \begin{pmatrix} RI_n & \mathbf{w} \\ \mathbf{w}^T & R \end{pmatrix}.$$

Demostraremos que

$$M \succeq 0 \quad \Longleftrightarrow \quad \|\mathbf{w}\|_2 \leq R.$$

($\Rightarrow$)**.** Supongamos que $M \succeq 0$. Entonces, para todo $x \in \mathbb{R}^n$ y $t \in \mathbb{R}$,

$$\begin{pmatrix} x \\ t \end{pmatrix}^T M \begin{pmatrix} x \\ t \end{pmatrix} = R\|x\|_2^2 + 2t\,\mathbf{w}^T x + Rt^2 \geq 0.$$

Tomando $t = 0$ y $x \neq 0$, obtenemos $R \geq 0$.
Si $\mathbf{w} = 0$, entonces

$$\|\mathbf{w}\|_2 = 0 \leq R.$$

Supongamos ahora que $\mathbf{w} \neq 0$ y tomemos

$$x = -\frac{\mathbf{w}}{\|\mathbf{w}\|_2}, \qquad t = 1.$$

Entonces

$$\|x\|_2 = 1, \qquad \mathbf{w}^T x = -\|\mathbf{w}\|_2.$$

Por tanto,

$$2R - 2\|\mathbf{w}\|_2 \geq 0,$$

de donde

$$\|\mathbf{w}\|_2 \leq R.$$

($\Leftarrow$)**.** Supongamos que

$$\|\mathbf{w}\|_2 \leq R.$$

Para cualquier $x \in \mathbb{R}^n$ y $t \in \mathbb{R}$,

$$\begin{pmatrix} x \\ t \end{pmatrix}^T M \begin{pmatrix} x \\ t \end{pmatrix} = R\|x\|_2^2 + 2t\,\mathbf{w}^T x + Rt^2.$$

Por la desigualdad de Cauchy–Schwarz,

$$2t\,\mathbf{w}^T x \geq -2|t|\,\|\mathbf{w}\|_2\|x\|_2.$$

Como $\|\mathbf{w}\|_2 \leq R$,

$$\begin{aligned} R\|x\|_2^2 + 2t\,\mathbf{w}^T x + Rt^2 &\geq R\|x\|_2^2 - 2R|t|\|x\|_2 + Rt^2 \\ &= R\big(\|x\|_2 - |t|\big)^2 \\ &\geq 0. \end{aligned}$$

DRAFT

Por tanto,

$$M \succeq 0.$$

En consecuencia,

$$\boxed{\begin{pmatrix} RI_n & \mathbf{w} \\ \mathbf{w}^T & R \end{pmatrix} \succeq 0 \iff \|\mathbf{w}\|_2 \leq R.}$$

(b) Sea $P \subseteq \mathbb{R}^n$ un conjunto representable mediante conos de segundo orden. Entonces existen $k_1, \ldots, k_m \in \mathbb{N}$ y una aplicación afín

$$f : \mathbb{R}^n \longrightarrow (V_{k_1} \times \mathbb{R}) \times \cdots \times (V_{k_m} \times \mathbb{R})$$

tales que

$$P = f^{-1}\left(E_{k_1} \times \cdots \times E_{k_m}\right).$$

Escribamos

$$f(x) = \big((w_1(x), R_1(x)), \ldots, (w_m(x), R_m(x))\big).$$

Entonces

$$x \in P$$

si y sólo si

$$\|w_i(x)\|_2 \leq R_i(x), \qquad i = 1, \ldots, m.$$

Por la parte (a), esto equivale a

$$M_i(x) := \begin{pmatrix} R_i(x) I_{k_i} & w_i(x) \\ w_i(x)^T & R_i(x) \end{pmatrix} \succeq 0, \qquad i = 1, \ldots, m.$$

Definamos la matriz bloque diagonal

$$M(x) = \operatorname{diag}\left(M_1(x), \ldots, M_m(x)\right).$$

Entonces

$$x \in P \quad \iff \quad M(x) \succeq 0.$$

Como f es afín, $M(x)$ también depende afínmente de x. Por tanto, existen matrices simétricas $A_0, A_1, \ldots, A_n$ tales que

$$M(x) = A_0 + x_1 A_1 + \cdots + x_n A_n.$$

Así,

$$P = \left\{x \in \mathbb{R}^n : A_0 + x_1 A_1 + \cdots + x_n A_n \succeq 0\right\}.$$

DRAFT

Por definición, P es un espectraedro.
Por consiguiente,

Todo conjunto representable mediante conos de segundo orden es un espectraedro.

Definición 9. Un conjunto $P \subseteq \mathbb{R}^n$ se denomina *espectraedro* si existen $r \in \mathbb{N}$, $k_1, \ldots, k_r \in \mathbb{N}$ y una aplicación afín

$$f : \mathbb{R}^n \longrightarrow S^2(V_{k_1}) \times \cdots \times S^2(V_{k_r})$$

tales que

$$P = f^{-1}\left(S^+(V_{k_1}) \times \cdots \times S^+(V_{k_r})\right).$$

Ejercicio 9. Pruebe que $P \subseteq \mathbb{R}^n$ es un espectraedro si y sólo si existen $m \in \mathbb{N}$ y matrices

$$A_0, A_1, \ldots, A_n \in S^2(V_m)$$

tales que

$$P = \{(x_1, \ldots, x_n) \in \mathbb{R}^n : A_0 + x_1 A_1 + \cdots + x_n A_n \succeq 0\}.$$

Solución 9. Demostraremos ambas implicaciones.

($\Rightarrow$)**.** Supongamos que P es un espectraedro. Entonces existen $r \in \mathbb{N}$, $k_1, \ldots, k_r \in \mathbb{N}$ y una aplicación afín

$$f : \mathbb{R}^n \longrightarrow S^2(V_{k_1}) \times \cdots \times S^2(V_{k_r})$$

tales que

$$P = f^{-1}\left(S^+(V_{k_1}) \times \cdots \times S^+(V_{k_r})\right).$$

Escribamos f mediante sus componentes:

$$f(x) = \big(f_1(x), \ldots, f_r(x)\big).$$

Como cada f_j es afín, existen matrices

$$A_{j0}, A_{j1}, \ldots, A_{jn} \in S^2(V_{k_j})$$

tales que

$$f_j(x) = A_{j0} + x_1 A_{j1} + \cdots + x_n A_{jn}.$$

DRAFT

Definamos, para $i = 0, \ldots, n$,

$$A_i = \operatorname{diag}(A_{1i}, A_{2i}, \ldots, A_{ri}).$$

Si

$$m = k_1 + \cdots + k_r,$$

entonces

$$A_i \in S^2(V_m).$$

Además,

$$A_0 + x_1 A_1 + \cdots + x_n A_n = \operatorname{diag}(f_1(x), \ldots, f_r(x)).$$

Una matriz bloque diagonal es positiva semidefinida si y sólo si cada uno de sus bloques es positivo semidefinido. Por tanto,

$$\begin{aligned} x \in P &\iff f_j(x) \succeq 0, \qquad j = 1, \ldots, r, \\ &\iff A_0 + x_1 A_1 + \cdots + x_n A_n \succeq 0. \end{aligned}$$

Así,

$$P = \{x \in \mathbb{R}^n : A_0 + x_1 A_1 + \cdots + x_n A_n \succeq 0\}.$$

($\Leftarrow$)**.** Supongamos ahora que existen $m \in \mathbb{N}$ y matrices

$$A_0, A_1, \ldots, A_n \in S^2(V_m)$$

tales que

$$P = \{x \in \mathbb{R}^n : A_0 + x_1 A_1 + \cdots + x_n A_n \succeq 0\}.$$

Definamos la aplicación afín

$$f : \mathbb{R}^n \longrightarrow S^2(V_m)$$

mediante

$$f(x) = A_0 + x_1 A_1 + \cdots + x_n A_n.$$

Entonces

DRAFT

$$\begin{aligned} x \in P &\iff f(x) \succeq 0 \\ &\iff f(x) \in S^+(V_m). \end{aligned}$$

Por consiguiente,

$$P = f^{-1}\big(S^+(V_m)\big).$$

Por definición, P es un espectraedro.

En conclusión,

$$\boxed{P \text{ es un espectraedro } \iff P = \left\{ x \in \mathbb{R}^n : A_0 + \sum_{i=1}^{n} x_i A_i \succeq 0 \right\}.}$$

$$\boxed{\text{Poliedros} \subseteq \text{Convexos de segundo orden} \subseteq \text{Espectraedros} \subseteq \text{Convexos}}$$

Esta cadena de inclusiones puede interpretarse en el contexto de optimización como

$$\underbrace{\text{Poliedros}}_{\text{Optimización lineal}} \subseteq \underbrace{\text{Convexos de segundo orden}}_{\text{Optimización de segundo orden}} \subseteq \underbrace{\text{Espectraedros}}_{\text{Optimización semidefinida}} \subseteq \underbrace{\text{Convexos}}_{\text{Optimización convexa}}.$$

2.2 Optimización de portafolios

La **optimización de portafolios** consiste en determinar cómo distribuir un capital entre varios activos financieros de manera que se alcance un objetivo de inversión, usualmente minimizar el riesgo para un nivel mínimo de rentabilidad esperada.

Si x_i representa la cantidad invertida en el activo i, un modelo típico puede escribirse como

$$\begin{aligned} \min_{x} \quad & x^T V x \\ \text{s.a.} \quad & \sum_{i=1}^{N} x_i = K, \\ & x_i \geq 0, \qquad i = 1, \ldots, N, \\ & x^T \bar{r} \geq \mu, \end{aligned}$$

donde V es la matriz de covarianzas de los retornos, K es el capital disponible, $\bar{r}$ es el vector de retornos esperados y μ es el retorno mínimo requerido.

Consideremos N activos con retornos aleatorios

DRAFT

$$r_1, \ldots, r_N.$$

Un portafolio se representa mediante el vector

$$x = (x_1, \ldots, x_N),$$

donde

$$x_i \geq 0, \qquad \sum_{i=1}^{N} x_i = K,$$

siendo K el capital disponible.
El retorno del portafolio está dado por

$$x_1 r_1 + \cdots + x_N r_N.$$

2.2.1 Modelo de Markowitz

El modelo de Markowitz considera dos cantidades fundamentales.

(a) **Retorno medio del portafolio**
Si

$$\bar{r}_i = \mathbb{E}[r_i],$$

entonces

$$\mathbb{E}\left[\sum_{i=1}^{N} x_i r_i\right] = \sum_{i=1}^{N} x_i \bar{r}_i = x^T \bar{r},$$

donde

$$\bar{r} = \begin{bmatrix} \bar{r}_1 \\ \vdots \\ \bar{r}_N \end{bmatrix}.$$

(b) **Riesgo del portafolio**
Definimos

$$f(x_1, \ldots, x_N) = \mathbb{E}\left[(x_1(r_1 - \bar{r}_1) + \cdots + x_N(r_N - \bar{r}_N))^2\right].$$

Esta expresión puede escribirse como

DRAFT

$$f(x) = x^T V x,$$

donde la matriz de covarianza

$$V = (V_{ij})_{i,j=1}^N$$

tiene entradas

$$V_{ij} = \mathbb{E}\left[(r_i - \bar{r}_i)(r_j - \bar{r}_j)\right].$$

La matriz V es simétrica y positiva semidefinida, pues

$$V \succeq 0$$

y, para todo $z \in \mathbb{R}^N$,

$$z^T V z = \mathbb{E}\left[\left(\sum_{i=1}^N z_i(r_i - \bar{r}_i)\right)^2\right] \geq 0.$$

Ejercicio 10. Demuestre que la función

$$f(x) = x^T V x$$

es convexa si

$$V \succeq 0.$$

En particular, para $x, p \in \mathbb{R}^N$ se debe verificar que

$$f\left(\frac{1}{2}x + \frac{1}{2}p\right) \leq \frac{1}{2}f(x) + \frac{1}{2}f(p).$$

Proof. Para verificar la convexidad, consideremos $x, p \in \mathbb{R}^N$. Debemos demostrar que

$$f\left(\frac{x+p}{2}\right) \leq \frac{1}{2}f(x) + \frac{1}{2}f(p).$$

En efecto,

$$\begin{aligned} f\left(\frac{x+p}{2}\right) &= \left(\frac{x+p}{2}\right)^T V \left(\frac{x+p}{2}\right) \\ &= \frac{1}{4}(x+p)^T V (x+p) \\ &= \frac{1}{4}\left(x^T V x + x^T V p + p^T V x + p^T V p\right). \end{aligned}$$

DRAFT

Como V es simétrica,

$$x^T V p = p^T V x,$$

por lo tanto,

$$f\left(\frac{x+p}{2}\right) = \frac{1}{4}x^T V x + \frac{1}{2}x^T V p + \frac{1}{4}p^T V p.$$

Ahora,

$$\begin{aligned}\frac{1}{2}f(x) + \frac{1}{2}f(p) - f\left(\frac{x+p}{2}\right) &= \frac{1}{2}x^T V x + \frac{1}{2}p^T V p \\ &\quad - \left(\frac{1}{4}x^T V x + \frac{1}{2}x^T V p + \frac{1}{4}p^T V p\right) \\ &= \frac{1}{4}\left(x^T V x - 2x^T V p + p^T V p\right) \\ &= \frac{1}{4}(x-p)^T V (x-p).\end{aligned}$$

Como

$$V \succeq 0,$$

se tiene que

$$(x-p)^T V (x-p) \geq 0.$$

Luego,

$$\frac{1}{2}f(x) + \frac{1}{2}f(p) - f\left(\frac{x+p}{2}\right) \geq 0,$$

y por tanto,

$$\boxed{f\left(\frac{x+p}{2}\right) \leq \frac{1}{2}f(x) + \frac{1}{2}f(p)}.$$

En general, para todo $\lambda \in [0,1]$,

$$\lambda f(x) + (1-\lambda)f(p) - f\big(\lambda x + (1-\lambda)p\big) = \lambda(1-\lambda)(x-p)^T V (x-p).$$

Como $V \succeq 0$,

$$\lambda(1-\lambda)(x-p)^T V (x-p) \geq 0,$$

DRAFT

de donde

$$f\big(\lambda x+(1-\lambda)p\big) \leq \lambda f(x)+(1-\lambda)f(p).$$

Por consiguiente,

$$\boxed{f(x)=x^TVx \text{ es convexa.}}$$

□

2.2.2 Problema de portafolio óptimo

Un modelo de optimización consiste en minimizar el riesgo garantizando un retorno medio mínimo μ:

$$\begin{aligned} \min_{x\in\mathbb{R}^N} \quad & x^TVx \\ \text{s.a.} \quad & \sum_{i=1}^{N} x_i = K, \\ & x_i \geq 0, \qquad i=1,\ldots,N, \\ & \sum_{i=1}^{N} x_i\bar{r}_i \geq \mu. \end{aligned}$$

Este problema puede reformularse como un problema de cono de segundo orden (*Second-Order Cone Program*, SOCP).

Como $V \succeq 0$, puede factorizarse como

$$V = C^TC.$$

Por tanto,

$$x^TVx = x^TC^TCx = (Cx)^T(Cx) = \|Cx\|_2^2.$$

Así, el problema

$$\begin{aligned} \min_{x\in\mathbb{R}^N} \quad & x^TVx \\ \text{s.a.} \quad & \sum_{i=1}^{N} x_i = K, \\ & x_i \geq 0, \qquad i=1,\ldots,N, \\ & \sum_{i=1}^{N} x_i\bar{r}_i \geq \mu \end{aligned}$$

DRAFT

puede escribirse como

$$\begin{aligned} \min_{x} \quad & \|Cx\|_2^2 \\ \text{s.a.} \quad & \mathbf{1}^T x = K, \\ & x \geq 0, \\ & \bar{r}^T x \geq \mu. \end{aligned}$$

Como la función $s \mapsto s^2$ es creciente para $s \geq 0$, minimizar $\|Cx\|_2^2$ es equivalente a minimizar $\|Cx\|_2$.

Introduciendo una variable auxiliar t, obtenemos

$$\boxed{\begin{aligned} \min_{x,t} \quad & t \\ \text{s.a.} \quad & \|Cx\|_2 \leq t, \\ & \mathbf{1}^T x = K, \\ & x \geq 0, \\ & \bar{r}^T x \geq \mu. \end{aligned}}$$

La restricción

$$\|Cx\|_2 \leq t$$

es una restricción de cono de segundo orden, pues equivale a

$$(t, Cx) \in \mathcal{Q}^{m+1},$$

donde

$$\mathcal{Q}^{m+1} = \{(t,y) \in \mathbb{R} \times \mathbb{R}^m : \|y\|_2 \leq t\}.$$

Por consiguiente, el problema de optimización de portafolios puede formularse como un problema de cono de segundo orden (*Second-Order Cone Program*, SOCP).

Ejemplo 6. Considere el problema

$$\begin{aligned} \max_{x \in \mathbb{R}^3} \quad & x_1 + x_2 + x_3 \\ \text{s.a.} \quad & \|x\|_2 \leq 1. \end{aligned}$$

Recordemos que el cono de segundo orden en $\mathbb{R}^{n+1}$ se define como

$$\mathcal{Q}^{n+1} = \{(t,y) \in \mathbb{R} \times \mathbb{R}^n : \|y\|_2 \leq t\}.$$

En este caso,

DRAFT

$$(1, x_1, x_2, x_3) \in \mathscr{Q}^4$$

si y solo si

$$\sqrt{x_1^2 + x_2^2 + x_3^2} \leq 1.$$

Por tanto, el conjunto factible es

$$\left\{ x \in \mathbb{R}^3 : \|x\|_2 \leq 1 \right\},$$

es decir, la bola unitaria de $\mathbb{R}^3$.

La función objetivo puede escribirse como

$$f(x) = c^T x,$$

donde

$$c = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

Así, el problema consiste en maximizar una función lineal sobre un conjunto convexo definido mediante una restricción de cono de segundo orden.

Por la desigualdad de Cauchy–Schwarz,

$$c^T x \leq \|c\|_2 \|x\|_2.$$

Como

$$\|x\|_2 \leq 1,$$

se tiene

$$c^T x \leq \|c\|_2.$$

Ahora,

$$\|c\|_2 = \sqrt{1^2 + 1^2 + 1^2} = \sqrt{3}.$$

Por tanto,

$$x_1 + x_2 + x_3 \leq \sqrt{3}.$$

DRAFT

La igualdad en la desigualdad de Cauchy–Schwarz se alcanza cuando x tiene la misma dirección que c. Por esta razón,

$$x^* = \frac{c}{\|c\|_2}.$$

Entonces,

$$x^* = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

En consecuencia,

$$\boxed{x_1^* = x_2^* = x_3^* = \frac{1}{\sqrt{3}}}$$

y el valor óptimo es

$$\boxed{f(x^*) = \sqrt{3}.}$$

Por tanto, el problema puede escribirse en forma de cono de segundo orden como

$$\boxed{\begin{array}{ll} \max\limits_{x \in \mathbb{R}^3} & c^T x \\ \text{s.a.} & (1,x) \in \mathcal{Q}^4, \end{array}}$$

con

$$c = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

Este es un problema SOCP porque la función objetivo es lineal y la restricción pertenece a un cono de segundo orden.

2.2.3 Matriz de covarianza

La **matriz de covarianza** es una matriz que describe cómo varían conjuntamente varias variables aleatorias.

Si se consideran los retornos

$$R_1, R_2, \ldots, R_N,$$

la matriz de covarianza se define como

DRAFT

$$V = \begin{bmatrix} \mathrm{Cov}(R_1,R_1) & \mathrm{Cov}(R_1,R_2) & \cdots & \mathrm{Cov}(R_1,R_N) \\ \mathrm{Cov}(R_2,R_1) & \mathrm{Cov}(R_2,R_2) & \cdots & \mathrm{Cov}(R_2,R_N) \\ \vdots & \vdots & \ddots & \vdots \\ \mathrm{Cov}(R_N,R_1) & \mathrm{Cov}(R_N,R_2) & \cdots & \mathrm{Cov}(R_N,R_N) \end{bmatrix}.$$

La covarianza entre dos variables aleatorias R_i y R_j se define como

$$\mathrm{Cov}(R_i,R_j) = \mathbb{E}\left[(R_i - \mathbb{E}[R_i])\,(R_j - \mathbb{E}[R_j])\right].$$

Como

$$\mathrm{Cov}(R_i,R_i) = \mathrm{Var}(R_i),$$

los elementos de la diagonal de V corresponden a las varianzas:

$$V_{ii} = \mathrm{Var}(R_i).$$

Los elementos fuera de la diagonal corresponden a las covarianzas:

$$V_{ij} = \mathrm{Cov}(R_i,R_j), \qquad i \neq j.$$

La interpretación básica es

$$\mathrm{Cov}(R_i,R_j) > 0$$

si los retornos tienden a moverse en la misma dirección,

$$\mathrm{Cov}(R_i,R_j) < 0$$

si tienden a moverse en direcciones opuestas, y

$$\mathrm{Cov}(R_i,R_j) \approx 0$$

si no presentan una relación lineal significativa.
Además, la matriz de covarianza es simétrica,

$$V = V^T,$$

y semidefinida positiva,

$$V \succeq 0.$$

En optimización de portafolios, si x es el vector de inversiones, la varianza del retorno del portafolio está dada por

DRAFT

$$\boxed{\text{Var}(R_p) = x^T V x}.$$

Por esta razón, la matriz de covarianza permite cuantificar el riesgo total del portafolio.

2.2.4 ¿Por qué se calcula la matriz de covarianza?

En optimización de portafolios no es suficiente conocer únicamente el retorno esperado de cada activo. También es necesario medir el **riesgo conjunto** de las inversiones.

Si R_i representa el retorno del activo i, la matriz de covarianza se define como

$$V = \begin{bmatrix} \text{Var}(R_1) & \text{Cov}(R_1,R_2) & \cdots \\ \text{Cov}(R_2,R_1) & \text{Var}(R_2) & \cdots \\ \vdots & \vdots & \ddots \end{bmatrix}.$$

Los elementos de la diagonal,

$$V_{ii} = \text{Var}(R_i),$$

miden la variabilidad individual de cada activo, mientras que los términos fuera de la diagonal,

$$V_{ij} = \text{Cov}(R_i,R_j),$$

miden la forma en que dos activos varían conjuntamente.

Sea

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}$$

el vector de cantidades invertidas en los activos. El retorno del portafolio es

$$R_p = \sum_{i=1}^{N} x_i R_i.$$

Su varianza está dada por

$$\boxed{\text{Var}(R_p) = x^T V x}$$

y esta cantidad se utiliza como medida del riesgo del portafolio.

DRAFT

Por ejemplo, para dos activos,

$$\text{Var}(R_p) = x_1^2\sigma_1^2 + x_2^2\sigma_2^2 + 2x_1x_2\,\text{Cov}(R_1, R_2).$$

El término

$$2x_1x_2\,\text{Cov}(R_1, R_2)$$

muestra que el riesgo total no depende solamente del riesgo individual de cada activo, sino también de la relación entre sus retornos.

Si la covarianza entre dos activos es pequeña o negativa, su combinación puede reducir el riesgo total del portafolio. Esta es la base matemática del principio de **diversificación**.

Por esta razón, en el problema de Markowitz se considera la función objetivo

$$\min_x x^T V x,$$

con el fin de encontrar una distribución del capital que minimice el riesgo del portafolio.

2.2.5 Matriz semidefinida positiva

Una matriz simétrica $A \in \mathbb{R}^{n\times n}$ se dice **semidefinida positiva** si

$$x^T A x \geq 0$$

para todo vector $x \in \mathbb{R}^n$.

En este caso se escribe

$$\boxed{A \succeq 0}.$$

¿Cómo determinar si una matriz es semidefinida positiva?

Existen varias formas equivalentes de verificar esta propiedad.

(a) Mediante la definición
Se calcula la forma cuadrática

$$x^T A x.$$

Si se cumple que

$$x^T A x \geq 0$$

DRAFT

para todo $x \in \mathbb{R}^n$, entonces

$$A \succeq 0.$$

Por ejemplo, si

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix},$$

entonces, para

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

se tiene

$$x^T A x = x_1^2 \geq 0.$$

Por tanto,

$$A \succeq 0.$$

(b) Mediante los valores propios
Si A es simétrica, entonces

$$\boxed{A \succeq 0 \iff \lambda_i \geq 0 \quad \text{para todo } i}$$

donde λ_i son los valores propios de A.
Por ejemplo, si

$$A = \begin{bmatrix} 2 & 0 \\ 0 & 0 \end{bmatrix},$$

sus valores propios son

$$\lambda_1 = 2, \qquad \lambda_2 = 0.$$

Como ambos son no negativos,

$$A \succeq 0.$$

(c) Mediante una factorización
Si existe una matriz B tal que

$$A = B^T B,$$

entonces

DRAFT

$$x^T Ax = x^T B^T Bx = (Bx)^T (Bx) = \|Bx\|_2^2 \geq 0.$$

Por tanto,

$$\boxed{A \succeq 0}.$$

Ejemplo 7. Diferencia con una matriz definida positiva
Si

$$x^T Ax > 0$$

para todo $x \neq 0$, entonces A es **definida positiva** y se escribe

$$A \succ 0.$$

En cambio, una matriz semidefinida positiva permite que

$$x^T Ax = 0$$

para algunos vectores no nulos.
Por ejemplo,

$$\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \succeq 0,$$

pero no es definida positiva, porque para

$$x = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

se obtiene

$$x^T Ax = 0.$$

2.2.6 Factorización de Cholesky

Sea

$$A \in \mathbb{R}^{n \times n}, \qquad A = A^T, \qquad A \succeq 0.$$

La condición

$$A \succeq 0$$

DRAFT

significa que

$$x^T Ax \geq 0, \qquad \forall x \in \mathbb{R}^n.$$

Para matrices definidas positivas, la factorización de Cholesky clásica permite escribir

$$A = LL^T,$$

donde L es una matriz triangular inferior con diagonal positiva.

En el caso semidefinido positivo, la matriz puede ser singular y algunos elementos diagonales de L pueden ser iguales a cero. En términos más generales, siempre es posible obtener una factorización de la forma

$$\boxed{A = B^T B}.$$

Para justificarlo, como A es simétrica, admite una descomposición espectral

$$A = Q\Lambda Q^T,$$

donde Q es ortogonal y

$$\Lambda = \operatorname{diag}(\lambda_1, \ldots, \lambda_n).$$

Como $A \succeq 0$,

$$\lambda_i \geq 0, \qquad i = 1, \ldots, n.$$

Definimos entonces

$$\Lambda^{1/2} = \operatorname{diag}\left(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_n}\right).$$

Así,

$$A = Q\Lambda Q^T = Q\Lambda^{1/2}\Lambda^{1/2}Q^T.$$

Si definimos

$$B = \Lambda^{1/2}Q^T,$$

obtenemos

$$\boxed{A = B^T B}.$$

DRAFT

Ejemplo 8. Considere la matriz

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.$$

Sus valores propios son

$$\lambda_1 = 2, \qquad \lambda_2 = 0.$$

Como

$$\lambda_1, \lambda_2 \geq 0,$$

se tiene

$$A \succeq 0.$$

Sin embargo, A no es definida positiva, ya que posee un valor propio igual a cero. Una posible factorización es

$$A = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \end{bmatrix}.$$

Por tanto,

$$A = B^T B, \qquad B = \begin{bmatrix} 1 & 1 \end{bmatrix}.$$

2.2.7 Factorización de Cholesky para matrices semidefinidas positivas

Si la matriz de covarianza V es semidefinida positiva y

$$V = B^T B,$$

entonces

$$x^T V x = x^T B^T B x.$$

Por asociatividad,

$$x^T V x = (Bx)^T (Bx).$$

Como

$$(Bx)^T (Bx) = \|Bx\|_2^2,$$

DRAFT

se obtiene

$$\boxed{x^T V x = \|Bx\|_2^2}.$$

Esta igualdad permite expresar el riesgo cuadrático del portafolio en términos de una norma euclidiana.

Por tanto, una restricción de la forma

$$x^T V x \leq t^2$$

puede escribirse como

$$\boxed{\|Bx\|_2 \leq t}.$$

Esta última expresión corresponde a una restricción de cono de segundo orden, lo cual permite formular el problema de optimización de portafolios como un problema SOCP.

Ejemplo 9. Consideremos un portafolio formado por tres activos financieros. Los precios observados durante 13 períodos consecutivos son

$$P = \begin{bmatrix} 93.043 & 51.826 & 1.063 \\ 84.585 & 52.823 & 0.938 \\ 111.453 & 56.477 & 1.000 \\ 99.525 & 49.805 & 0.938 \\ 95.819 & 50.287 & 1.438 \\ 114.708 & 51.521 & 1.700 \\ 111.515 & 51.531 & 2.540 \\ 113.211 & 48.664 & 2.390 \\ 104.942 & 55.744 & 3.120 \\ 99.827 & 47.916 & 2.980 \\ 91.607 & 49.438 & 1.900 \\ 107.937 & 51.336 & 1.750 \\ 115.590 & 55.081 & 1.800 \end{bmatrix}.$$

Cada columna corresponde a un activo y cada fila al precio observado en un período determinado.

Cálculo de los retornos

Si $P_{t,i}$ representa el precio del activo i en el período t, definimos el retorno simple mediante

$$R_{t,i} = \frac{P_{t+1,i} - P_{t,i}}{P_{t,i}}, \qquad t = 1, \ldots, 12.$$

DRAFT

Así, para cada activo se obtienen 12 retornos.
Por ejemplo, para el primer activo,

$$R_{1,1} = \frac{84.585 - 93.043}{93.043}.$$

En forma matricial, los retornos pueden organizarse como

$$R = \begin{bmatrix} R_{1,1} & R_{1,2} & R_{1,3} \\ R_{2,1} & R_{2,2} & R_{2,3} \\ \vdots & \vdots & \vdots \\ R_{12,1} & R_{12,2} & R_{12,3} \end{bmatrix}.$$

Retorno esperado

El retorno medio del activo i se define como

$$\bar{r}_i = \frac{1}{12} \sum_{t=1}^{12} R_{t,i}.$$

Para los datos anteriores se obtiene aproximadamente

$$\bar{r} = \begin{bmatrix} 0.0260 \\ 0.0081 \\ 0.0737 \end{bmatrix}.$$

Esto significa que los retornos medios observados son aproximadamente

$$2.60\%, \qquad 0.81\%, \qquad 7.37\%.$$

Matriz de covarianzas

La matriz de covarianzas de los retornos se define por

$$V = \begin{bmatrix} \mathrm{Var}(R_1) & \mathrm{Cov}(R_1,R_2) & \mathrm{Cov}(R_1,R_3) \\ \mathrm{Cov}(R_2,R_1) & \mathrm{Var}(R_2) & \mathrm{Cov}(R_2,R_3) \\ \mathrm{Cov}(R_3,R_1) & \mathrm{Cov}(R_3,R_2) & \mathrm{Var}(R_3) \end{bmatrix}.$$

Para estos datos,

$$V \approx \begin{bmatrix} 0.018641 & 0.003599 & 0.001310 \\ 0.003599 & 0.006437 & 0.004887 \\ 0.001310 & 0.004887 & 0.068683 \end{bmatrix}.$$

Esta matriz es simétrica, pues

DRAFT

$$V = V^T.$$

Además, sus valores propios son aproximadamente

$$\lambda_1 = 0.00515, \qquad \lambda_2 = 0.01949, \qquad \lambda_3 = 0.06911.$$

Como todos ellos son positivos,

$$V \succ 0.$$

En particular,

$$V \succeq 0,$$

por lo que la función

$$f(x) = x^T V x$$

es convexa.

Interpretación del riesgo

Sea

$$x = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

el vector que representa el capital invertido en cada activo.
El retorno aleatorio del portafolio está dado por

$$R_p = x_1 R_1 + x_2 R_2 + x_3 R_3.$$

Su retorno esperado es

$$\mathbb{E}[R_p] = \bar{r}^T x,$$

mientras que su varianza, que utilizamos como medida de riesgo, es

$$\mathrm{Var}(R_p) = x^T V x.$$

Por tanto, minimizar

$$x^T V x$$

equivale a buscar el portafolio de menor varianza.

DRAFT

Modelo de optimización

Supongamos que se dispone de un capital máximo de $K = 1000$ unidades monetarias. El problema de Markowitz puede escribirse como

$$\begin{aligned} \min_{x\in\mathbb{R}^3} \quad & x^T V x \\ \text{s.a.} \quad & x_1 + x_2 + x_3 \leq 1000, \\ & x_i \geq 0, \qquad i = 1,2,3, \\ & \bar{r}^T x \geq \mu. \end{aligned}$$

La primera restricción establece que no puede invertirse más de 1000. La segunda impide posiciones cortas, ya que cada inversión debe ser no negativa. La tercera exige un retorno esperado mínimo μ.

En forma explícita,

$$0.0260x_1 + 0.0081x_2 + 0.0737x_3 \geq \mu.$$

El problema consiste entonces en determinar cómo distribuir el capital entre los tres activos para obtener el menor riesgo posible, garantizando al mismo tiempo un nivel mínimo de retorno esperado.

Observación sobre el retorno mínimo

Si se impone

$$\bar{r}^T x \geq 1000,$$

junto con

$$x_1 + x_2 + x_3 \leq 1000, \qquad x_i \geq 0,$$

el problema no tiene solución factible.

En efecto, el mayor retorno medio de los tres activos es aproximadamente

$$\max_i \bar{r}_i = 0.0737.$$

Por tanto, aun invirtiendo todo el capital en el activo con mayor retorno,

$$\bar{r}^T x \leq 0.0737(1000) \approx 73.7.$$

Así,

$$\bar{r}^T x \geq 1000$$

DRAFT

no puede cumplirse.

Por esta razón, el valor μ debe elegirse de manera consistente con las unidades utilizadas. Por ejemplo, si se desea un retorno esperado mínimo del 5% sobre un capital de 1000, entonces debe imponerse

$$\bar{r}^T x \geq 50.$$

El modelo correspondiente sería

$$\begin{array}{ll} \min\limits_{x\in\mathbb{R}^3} & x^T V x \\ \text{s.a.} & x_1 + x_2 + x_3 \leq 1000, \\ & x_i \geq 0, \qquad i = 1,2,3, \\ & 0.0260x_1 + 0.0081x_2 + 0.0737x_3 \geq 50. \end{array}$$

Este es un problema de optimización convexa, puesto que la función objetivo es convexa y todas las restricciones son lineales.

2.3 Condiciones de Karush–Kuhn–Tucker (KKT)

En los problemas de optimización convexa, determinar una solución óptima requiere establecer condiciones que permitan identificar los puntos candidatos al mínimo global. Para problemas sin restricciones, estas condiciones se obtienen mediante el análisis del gradiente de la función objetivo. Sin embargo, cuando existen restricciones, es necesario incorporar la información geométrica asociada a la región factible.

Las condiciones de Karush–Kuhn–Tucker (KKT) constituyen una extensión del método clásico de multiplicadores de Lagrange para problemas de optimización con restricciones de igualdad y desigualdad. Estas condiciones establecen una relación entre las variables primales, asociadas al vector de decisión del problema, y las variables duales, asociadas a las restricciones.

Consideremos un problema general de optimización convexa donde se busca determinar el vector de variables de decisión

$$\boldsymbol{x} = (x_1, x_2, \ldots, x_n)^T \in \mathbb{R}^n, \tag{2.1}$$

que minimiza una función objetivo $f(\boldsymbol{x})$.

Las condiciones KKT se obtendrán a partir de tres conceptos fundamentales:

- la formulación del problema primal con restricciones;
- la construcción de la función Lagrangiana mediante multiplicadores asociados a las restricciones;

DRAFT

- la formulación del problema dual y las condiciones de optimalidad.

Bajo condiciones adecuadas de convexidad y regularidad de las restricciones, las condiciones KKT proporcionan una caracterización completa de la solución óptima. En particular, para problemas convexos, un punto que satisface estas condiciones corresponde a una solución global del problema de optimización.

2.3.1 La función Lagrangiana

En los problemas de optimización restringida, las restricciones definen la región factible donde puede encontrarse la solución óptima. Para incorporar estas restricciones dentro del análisis de optimalidad se introduce una nueva función que combina la función objetivo con las restricciones mediante parámetros asociados a cada una de ellas.

Esta construcción corresponde a la función Lagrangiana, la cual permite transformar un problema restringido en una formulación donde las restricciones son incorporadas como términos adicionales dentro de la función objetivo.

Los parámetros asociados a las restricciones reciben el nombre de multiplicadores de Lagrange. Estos multiplicadores desempeñan un papel fundamental en la teoría de dualidad, ya que permiten construir un problema alternativo denominado problema dual.

Consideremos el problema primal de optimización:

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & f(\boldsymbol{x}) \\ \text{sujeto a} \quad & y_i(\boldsymbol{x}) \leq 0, \qquad i = 1, \ldots, m_1, \\ & h_j(\boldsymbol{x}) = 0, \qquad j = 1, \ldots, m_2. \end{aligned} \tag{2.2}$$

donde $\boldsymbol{x} \in \mathbb{R}^n$ representa el vector de variables de decisión. Las funciones $y_i(\boldsymbol{x})$ y $h_j(\boldsymbol{x})$ representan las restricciones de desigualdad e igualdad, respectivamente.

Para cada restricción de desigualdad se introduce un multiplicador λ_i, mientras que para cada restricción de igualdad se introduce un multiplicador ν_j. Estos multiplicadores serán las variables duales del problema y permitirán establecer una relación entre la formulación primal y su correspondiente formulación dual.

La función Lagrangiana asociada a este problema será definida formalmente en la siguiente sección, donde se estudiará su estructura matemática y la interpretación de sus variables asociadas.

2.3.2 Formulación del problema primal

La teoría de dualidad y las condiciones de optimalidad KKT se construyen a partir de una formulación general del problema de optimización restringida. Consideremos el problema de minimización:

DRAFT

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & f(\boldsymbol{x}) \\ \text{sujeto a} \quad & y_i(\boldsymbol{x}) \leq 0, \qquad i = 1, \ldots, m_1, \\ & h_j(\boldsymbol{x}) = 0, \qquad j = 1, \ldots, m_2. \end{aligned} \tag{2.3}$$

donde $\boldsymbol{x} \in \mathbb{R}^n$ es el vector de variables de decisión, $f(\boldsymbol{x})$ es la función objetivo, $y_i(\boldsymbol{x})$ representa la i-ésima restricción de desigualdad y $h_j(\boldsymbol{x})$ representa la j-ésima restricción de igualdad.

De manera compacta, las restricciones pueden expresarse mediante los vectores:

$$\boldsymbol{y}(\boldsymbol{x}) = \begin{bmatrix} y_1(\boldsymbol{x}) \\ y_2(\boldsymbol{x}) \\ \vdots \\ y_{m_1}(\boldsymbol{x}) \end{bmatrix} \in \mathbb{R}^{m_1}, \tag{2.4}$$

y

$$\boldsymbol{h}(\boldsymbol{x}) = \begin{bmatrix} h_1(\boldsymbol{x}) \\ h_2(\boldsymbol{x}) \\ \vdots \\ h_{m_2}(\boldsymbol{x}) \end{bmatrix} \in \mathbb{R}^{m_2}. \tag{2.5}$$

La forma estándar para las restricciones de desigualdad se establece como:

$$y_i(\boldsymbol{x}) \leq 0. \tag{2.6}$$

Esta convención es fundamental, ya que determina la condición que deben satisfacer los multiplicadores duales asociados a dichas restricciones.

Si una restricción se encuentra expresada como:

$$k_i(\boldsymbol{x}) \geq 0, \tag{2.7}$$

puede transformarse a la forma estándar mediante:

$$-k_i(\boldsymbol{x}) \leq 0. \tag{2.8}$$

Finalmente, un problema de maximización puede expresarse como un problema equivalente de minimización mediante:

$$\max_{\boldsymbol{x}} f(\boldsymbol{x}) \equiv \min_{\boldsymbol{x}} -f(\boldsymbol{x}). \tag{2.9}$$

Esta formulación constituye la base para introducir la función Lagrangiana y la relación entre las variables primales y duales.

DRAFT

2.3.3 Función Lagrangiana y variables duales

La función Lagrangiana permite incorporar las restricciones del problema primal definido en (2.3) dentro de una única función mediante la introducción de variables auxiliares asociadas a cada restricción.

Los parámetros asociados a las restricciones reciben el nombre de multiplicadores de Lagrange y constituyen las variables duales del problema de optimización.

Para cada restricción de desigualdad se introduce un multiplicador λ_i, mientras que para cada restricción de igualdad se introduce un multiplicador ν_j. La función Lagrangiana se define como:

$$L(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\boldsymbol{x}) + \sum_{i=1}^{m_1} \lambda_i y_i(\boldsymbol{x}) + \sum_{j=1}^{m_2} \nu_j h_j(\boldsymbol{x}). \tag{2.10}$$

Utilizando la representación vectorial de las restricciones, la ecuación (2.10) puede escribirse de forma compacta como:

$$L(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}) = f(\boldsymbol{x}) + \boldsymbol{\lambda}^T \boldsymbol{y}(\boldsymbol{x}) + \boldsymbol{\nu}^T \boldsymbol{h}(\boldsymbol{x}). \tag{2.11}$$

donde los vectores de variables duales están dados por:

$$\boldsymbol{\lambda} = (\lambda_1, \lambda_2, \ldots, \lambda_{m_1})^T \in \mathbb{R}^{m_1}, \tag{2.12}$$

y

$$\boldsymbol{\nu} = (\nu_1, \nu_2, \ldots, \nu_{m_2})^T \in \mathbb{R}^{m_2}. \tag{2.13}$$

Las variables λ_i están asociadas a las restricciones de desigualdad, mientras que las variables ν_j corresponden a las restricciones de igualdad. La función definida en (2.10) se denomina también relajación de Lagrange, debido a que incorpora las restricciones dentro de la función objetivo mediante términos ponderados.

Esta representación permitirá construir el problema dual y establecer las condiciones de optimalidad de Karush–Kuhn–Tucker.

2.3.4 Interpretación de la función Lagrangiana y función dual

La función Lagrangiana definida en (2.10) permite transformar el problema de optimización restringido en una formulación equivalente donde las restricciones se incorporan dentro de una única función. Esta representación se interpreta como una función de costo regularizada, en la cual los términos asociados a las restricciones actúan como penalizaciones ponderadas por las variables duales.

La idea fundamental consiste en combinar la función objetivo $f(\boldsymbol{x})$ con la información proporcionada por las restricciones del problema primal definido en (2.3). Los multiplicadores de Lagrange determinan la influencia de cada restricción dentro de

DRAFT

la función Lagrangiana y permiten establecer una relación entre las variables primas y duales.

Para las restricciones de desigualdad, las variables duales deben satisfacer la condición de no negatividad:

$$\lambda_i \geq 0, \qquad i = 1, \ldots, m_1. \tag{2.14}$$

Esta condición garantiza la consistencia entre la formulación primal y la interpretación de los multiplicadores como parámetros asociados a las restricciones de desigualdad. Por otro lado, los multiplicadores asociados a restricciones de igualdad no presentan una restricción de signo.

Desde esta perspectiva, la función Lagrangiana actúa como una relajación del problema primal, ya que incorpora las restricciones dentro de la función objetivo mediante términos ponderados. Por tanto, en lugar de optimizar directamente bajo restricciones, se analiza una función dependiente de las variables primales y duales:

$$L : \mathbb{R}^n \times \mathbb{R}^{m_1} \times \mathbb{R}^{m_2} \to \mathbb{R}. \tag{2.15}$$

Para un conjunto fijo de variables duales $(\boldsymbol{\lambda}, \boldsymbol{\nu})$, se busca el menor valor que puede alcanzar la función Lagrangiana respecto a la variable primal. Esto conduce a la definición de la función dual de Lagrange:

$$g(\boldsymbol{\lambda}, \boldsymbol{\nu}) = \inf_{\boldsymbol{x} \in D} L(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}). \tag{2.16}$$

Equivalentemente,

$$g(\boldsymbol{\lambda}, \boldsymbol{\nu}) = \inf_{\boldsymbol{x} \in D} \left(f(\boldsymbol{x}) + \boldsymbol{\lambda}^T \boldsymbol{y}(\boldsymbol{x}) + \boldsymbol{\nu}^T \boldsymbol{h}(\boldsymbol{x}) \right). \tag{2.17}$$

La función dual proporciona una cota inferior del valor óptimo del problema primal de minimización. En consecuencia, las variables duales se seleccionan buscando la mejor de estas cotas, lo cual conduce posteriormente a la formulación del problema dual.

Una propiedad importante en optimización convexa es que la función dual asociada a un problema de minimización es una función cóncava respecto a las variables duales. Por esta razón, mientras el problema primal busca minimizar la función objetivo respecto a $\boldsymbol{x}$, el problema dual buscará maximizar la función $g(\boldsymbol{\lambda}, \boldsymbol{\nu})$ respecto a sus variables duales.

La construcción de la función dual establece la conexión fundamental entre las formulaciones primal y dual, permitiendo introducir posteriormente los conceptos de factibilidad primal, factibilidad dual y dualidad fuerte.

DRAFT

2.3.5 Factibilidad primal y dual

En la formulación dual de un problema de optimización es necesario analizar dos tipos de condiciones de factibilidad. La primera está asociada con las variables de decisión del problema original y se denomina factibilidad primal. La segunda está relacionada con las variables introducidas mediante la función Lagrangiana y corresponde a la factibilidad dual.

Consideremos el problema primal definido en (2.3). Un punto $\boldsymbol{x}^*$ es una solución óptima del problema si, además de minimizar la función objetivo, satisface todas las restricciones impuestas.

El valor alcanzado por la función objetivo en este punto se denomina valor óptimo primal:

$$f^* = f(\boldsymbol{x}^*). \tag{2.18}$$

Debido a que $\boldsymbol{x}^*$ pertenece a la región factible, debe cumplir las restricciones de desigualdad:

$$y_i(\boldsymbol{x}^*) \leq 0, \qquad i = 1, \ldots, m_1, \tag{2.19}$$

y las restricciones de igualdad:

$$h_j(\boldsymbol{x}^*) = 0, \qquad j = 1, \ldots, m_2. \tag{2.20}$$

Estas condiciones reciben el nombre de *factibilidad primal* y establecen que toda solución óptima debe pertenecer al conjunto factible del problema original.

Por otra parte, la función dual de Lagrange definida en (2.16) se obtiene minimizando la función Lagrangiana respecto a la variable primal, manteniendo fijas las variables duales:

$$g(\boldsymbol{\lambda}, \boldsymbol{\nu}) = \inf_{\boldsymbol{x} \in D} L(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\nu}). \tag{2.21}$$

Para establecer la relación entre la función dual y el problema primal, consideremos un punto factible $\boldsymbol{x}_e$. Debido a la condición de factibilidad primal, se cumple:

$$y_i(\boldsymbol{x}_e) \leq 0, \qquad i = 1, \ldots, m_1. \tag{2.22}$$

Además, las variables duales asociadas a las restricciones de desigualdad deben satisfacer la condición de no negatividad:

$$\lambda_i \geq 0, \qquad i = 1, \ldots, m_1. \tag{2.23}$$

Por lo tanto, los productos asociados a las restricciones de desigualdad cumplen:

DRAFT

$$\lambda_i y_i(\boldsymbol{x}_e) \leq 0. \tag{2.24}$$

Para las restricciones de igualdad, debido a la factibilidad primal, se tiene:

$$h_j(\boldsymbol{x}_e) = 0, \qquad j = 1, \ldots, m_2. \tag{2.25}$$

Al sustituir estas propiedades en la función Lagrangiana (2.10), se obtiene:

$$L(\boldsymbol{x}_e, \boldsymbol{\lambda}, \boldsymbol{\nu}) \leq f(\boldsymbol{x}_e). \tag{2.26}$$

Como la función dual corresponde al mínimo de la función Lagrangiana respecto a $\boldsymbol{x}$, se cumple:

$$g(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq L(\boldsymbol{x}_e, \boldsymbol{\lambda}, \boldsymbol{\nu}), \tag{2.27}$$

por lo tanto:

$$g(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq f(\boldsymbol{x}_e). \tag{2.28}$$

En particular, evaluando en la solución óptima primal $\boldsymbol{x}^*$ se obtiene:

$$g(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq f^*. \tag{2.29}$$

Esta propiedad establece que la función dual proporciona una cota inferior del valor óptimo del problema primal de minimización.

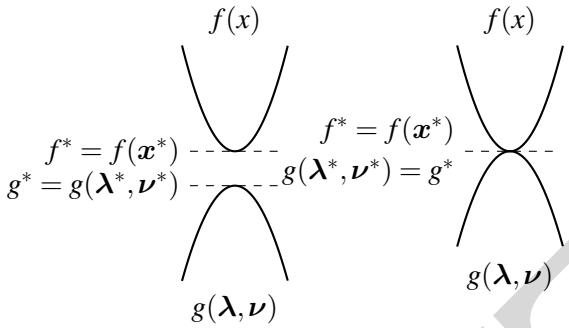
La condición

$$\boldsymbol{\lambda} \succeq 0 \tag{2.30}$$

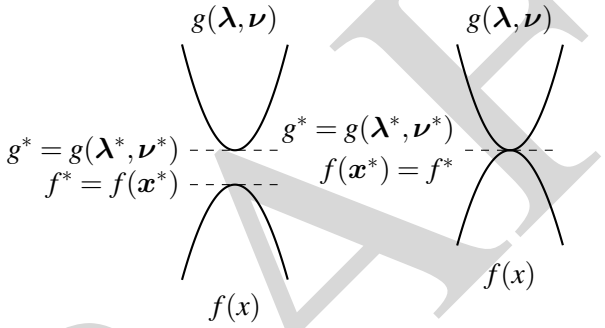
se denomina factibilidad dual y garantiza que las variables duales asociadas a las restricciones de desigualdad sean compatibles con la formulación del problema dual.

En consecuencia, mientras el problema primal busca minimizar la función objetivo respecto a las variables de decisión $\boldsymbol{x}$, el problema dual buscará maximizar la función $g(\boldsymbol{\lambda}, \boldsymbol{\nu})$ respecto a las variables duales, obteniendo la mejor cota inferior posible del problema original.

DRAFT



(a) Problema de minimización: $g(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq f^*$.



(b) Problema de maximización: $g(\boldsymbol{\lambda}, \boldsymbol{\nu}) \geq f^*$.

Figura 2.1: Comparativa gráfica de la dualidad débil y fuerte para problemas de minimización y maximización.

La relación entre las formulaciones primal y dual puede interpretarse gráficamente mediante la comparación entre el valor óptimo primal y el valor alcanzado por la función dual, tal como se ilustra en la Figura 2.1. En particular, la Figura 2.1a muestra la relación entre la función primal y dual para un problema de minimización, mientras que la Figura 2.1b presenta el caso correspondiente a un problema de maximización.

Para problemas de minimización, la función dual proporciona una cota inferior del valor óptimo primal, mientras que para problemas de maximización establece una cota superior. Esta relación constituye la propiedad conocida como dualidad débil.

Bajo condiciones adecuadas de convexidad y regularidad de las restricciones, la cota dual puede alcanzar el valor óptimo primal. En este caso se presenta la dualidad fuerte, caracterizada por la coincidencia entre los valores óptimos primal y dual.

DRAFT

2.3.6 Relación entre las formulaciones primal y dual

La formulación primal y la formulación dual representan dos perspectivas complementarias del mismo problema de optimización. El problema primal está definido en términos del vector de variables de decisión $\boldsymbol{x}$, mientras que el problema dual se construye a partir de los multiplicadores asociados a las restricciones del problema original.

La función Lagrangiana definida en (2.10) permite establecer esta conexión al incorporar las restricciones dentro de una única función dependiente de las variables primas y duales. En este contexto, las variables $\boldsymbol{\lambda}$ y $\boldsymbol{\nu}$ representan la influencia de las restricciones de desigualdad e igualdad, respectivamente.

Para un problema de minimización, la función dual proporciona una cota inferior del valor óptimo primal. En consecuencia, para cualquier punto factible primal $\boldsymbol{x}$ y cualquier variable dual factible $\boldsymbol{\lambda} \succeq 0$, se cumple la relación de dualidad débil:

$$g(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq f(\boldsymbol{x}). \tag{2.31}$$

Evaluando esta desigualdad en la solución óptima primal $\boldsymbol{x}^*$ se obtiene:

$$g(\boldsymbol{\lambda}, \boldsymbol{\nu}) \leq f^*, \tag{2.32}$$

lo cual muestra que el problema dual busca la mejor cota inferior posible del valor óptimo del problema primal.

Cuando existen condiciones adecuadas de convexidad y regularidad, ambas formulaciones alcanzan el mismo valor óptimo. Esta propiedad se conoce como dualidad fuerte y se expresa mediante:

$$f^* = g^* = g(\boldsymbol{\lambda}^*, \boldsymbol{\nu}^*). \tag{2.33}$$

Por tanto, la solución óptima de un problema convexo puede ser caracterizada mediante la interacción entre las variables primales y duales. Esta relación constituye la base para el desarrollo de las condiciones de Karush–Kuhn–Tucker, las cuales establecen las condiciones necesarias y suficientes de optimalidad bajo hipótesis adecuadas.

Ejemplo 10. Optimización cuadrática del consumo energético

Una vivienda inteligente debe distribuir su consumo energético entre dos fuentes: energía suministrada por la red eléctrica y energía generada mediante paneles solares. El objetivo es minimizar el costo total considerando que el incremento del consumo produce costos marginales crecientes.

Definimos las variables de decisión:

$$x_1 = \text{energía suministrada por la red eléctrica},$$
$$x_2 = \text{energía suministrada por paneles solares}.$$

DRAFT

El vector de variables primales está dado por:

$$\boldsymbol{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \in \mathbb{R}^2.$$

La función de costo se modela mediante una función cuadrática:

$$f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^T Q\boldsymbol{x} + \boldsymbol{c}^T \boldsymbol{x},$$

donde

$$Q = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}, \qquad \boldsymbol{c} = \begin{bmatrix} 4 \\ 2 \end{bmatrix}.$$

Por tanto, la función objetivo puede expresarse como:

$$f(x_1, x_2) = x_1^2 + 2x_2^2 + 4x_1 + 2x_2.$$

La vivienda debe satisfacer una demanda mínima de energía de 10 unidades y dispone de una capacidad máxima de generación solar de 6 unidades. El problema primal se formula como:

$$\begin{aligned} \min_{\boldsymbol{x}} \quad & x_1^2 + 2x_2^2 + 4x_1 + 2x_2 \\ \text{sujeto a} \quad & 10 - x_1 - x_2 \leq 0, \\ & x_2 - 6 \leq 0, \\ & x_1, x_2 \geq 0. \end{aligned}$$

La matriz Hessiana de la función objetivo es:

$$\nabla^2 f(\boldsymbol{x}) = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}.$$

Los valores propios de esta matriz son:

$$\lambda_1 = 2, \qquad \lambda_2 = 4.$$

Como ambos valores propios son positivos, se cumple:

$$\nabla^2 f(\boldsymbol{x}) \succ 0.$$

Por lo tanto, la función objetivo es estrictamente convexa. Además, las restricciones son lineales y definen una región factible convexa. En consecuencia, una solución que satisfaga las condiciones de Karush–Kuhn–Tucker corresponde a un óptimo global.

La función Lagrangiana asociada al problema es:

DRAFT

$$\begin{aligned} L(\boldsymbol{x},\boldsymbol{\lambda}) =& x_1^2 + 2x_2^2 + 4x_1 + 2x_2 \\ &+ \lambda_1(10 - x_1 - x_2) + \lambda_2(x_2 - 6). \end{aligned}$$

donde

$$\lambda_1, \lambda_2 \geq 0$$

son las variables duales asociadas a las restricciones del problema.
Las condiciones KKT están dadas por las siguientes relaciones.

Factibilidad primal

$$10 - x_1 - x_2 \leq 0, \qquad x_2 - 6 \leq 0, \qquad x_1, x_2 \geq 0.$$

Factibilidad dual

$$\lambda_1, \lambda_2 \geq 0.$$

Estacionariedad

$$\nabla_{\boldsymbol{x}} L(\boldsymbol{x},\boldsymbol{\lambda}) = 0.$$

Por lo tanto:

$$2x_1 + 4 - \lambda_1 = 0,$$

y

$$4x_2 + 2 - \lambda_1 + \lambda_2 = 0.$$

Complementariedad

$$\lambda_1(10 - x_1 - x_2) = 0,$$

$$\lambda_2(x_2 - 6) = 0.$$

$$\begin{bmatrix} 2 & 0 & -1 & 0 \\ 0 & 4 & -1 & 1 \\ 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \lambda_1 \\ \lambda_2 \end{bmatrix} = \begin{bmatrix} -4 \\ -2 \\ 10 \\ 6 \end{bmatrix}.$$

La solución óptima corresponde a utilizar completamente la capacidad solar disponible y cubrir la demanda restante mediante la red eléctrica:

DRAFT

$$x_2^* = 6, \qquad x_1^* = 4.$$

Por tanto, el vector óptimo de decisión es:

$$\boldsymbol{x}^* = \begin{bmatrix} 4 \\ 6 \end{bmatrix}.$$

El valor óptimo de la función objetivo es:

$$f^* = f(\boldsymbol{x}^*) = 4^2 + 2(6)^2 + 4(4) + 2(6) = 116.$$

Este ejemplo muestra cómo un problema cotidiano de asignación de recursos puede formularse como un problema de programación cuadrática convexa. La matriz Hessiana positiva definida garantiza la convexidad del problema, mientras que la función Lagrangiana y las variables duales permiten interpretar el efecto de las restricciones sobre la solución óptima.

Esta estructura constituye la base para la aplicación de las condiciones de Karush–Kuhn–Tucker en problemas convexos.

Ejemplo 11. Optimización de la producción en una cafetería

Una cafetería produce dos tipos de bebidas: café tradicional y café especial. Cada producto genera una ganancia diferente y utiliza una cantidad determinada de un recurso limitado, por ejemplo, leche disponible durante la jornada laboral.

Definimos las variables de decisión:

$$x_1 = \text{cantidad de cafés tradicionales producidos},$$
$$x_2 = \text{cantidad de cafés especiales producidos}.$$

El vector de variables primales está dado por:

$$\boldsymbol{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}.$$

La ganancia total de la cafetería se modela mediante la función objetivo:

$$f(\boldsymbol{x}) = 2x_1 + 5x_2.$$

El primer producto genera una ganancia de dos unidades monetarias, mientras que el segundo genera una ganancia de cinco unidades monetarias. La producción está limitada por la disponibilidad del recurso:

$$x_1 + 2x_2 \leq 40.$$

Además, las cantidades producidas deben ser no negativas:

DRAFT

$$x_1, x_2 \geq 0.$$

El problema de optimización primal se formula como:

$$\begin{aligned} \max_{\boldsymbol{x}} \quad & 2x_1 + 5x_2 \\ \text{sujeto a} \quad & x_1 + 2x_2 \leq 40, \\ & x_1, x_2 \geq 0. \end{aligned}$$

Este problema corresponde a un problema de programación lineal, el cual es un caso particular de la optimización convexa. La función objetivo es lineal y, por tanto, es simultáneamente convexa y cóncava.

La región factible está definida por:

$$D = \left\{ \boldsymbol{x} \in \mathbb{R}^2 : x_1 + 2x_2 \leq 40, \quad x_1, x_2 \geq 0 \right\}.$$

Este conjunto es convexo debido a que para dos puntos factibles

$$\boldsymbol{x}^{(1)}, \qquad \boldsymbol{x}^{(2)}$$

la combinación convexa

$$\boldsymbol{x} = t\boldsymbol{x}^{(1)} + (1-t)\boldsymbol{x}^{(2)}, \qquad 0 \leq t \leq 1,$$

también pertenece al conjunto factible.

Esta propiedad garantiza que cualquier solución óptima local del problema es también una solución óptima global.

La función Lagrangiana permite incorporar la restricción de recurso limitado mediante un multiplicador dual:

$$L(\boldsymbol{x}, \lambda) = 2x_1 + 5x_2 + \lambda(40 - x_1 - 2x_2).$$

El multiplicador

$$\lambda \geq 0$$

representa la variable dual asociada a la restricción del recurso disponible.

Desde una interpretación económica, las variables primales responden a la pregunta: ¿cuántos productos deben producirse? Mientras que la variable dual responde a: ¿cuál es el valor de disponer de una unidad adicional del recurso limitado? Este valor corresponde al precio sombra del recurso.

El problema primal busca determinar la mejor combinación de producción, mientras que el problema dual busca determinar la valoración óptima del recurso limitado. La función dual asociada proporciona una cota del problema primal.

DRAFT

Para problemas de minimización, la dualidad débil establece:

$$g(\lambda) \leq f^*.$$

En el caso de maximización, la relación se invierte:

$$g(\lambda) \geq f^*.$$

Cuando se cumplen las condiciones de convexidad y regularidad necesarias se obtiene la dualidad fuerte:

$$f^* = g^*.$$

En este ejemplo, la solución óptima corresponde a producir únicamente cafés especiales, debido a que presentan una mayor ganancia por unidad del recurso utilizado:

$$x_1^* = 0, \qquad x_2^* = 20.$$

El valor óptimo de la función objetivo es:

$$f^* = 2(0) + 5(20) = 100.$$

La solución óptima también puede interpretarse desde la formulación dual: el multiplicador asociado al recurso limitado representa el valor marginal de incrementar la disponibilidad de leche.

Finalmente, este ejemplo permite introducir las condiciones de Karush–Kuhn–Tucker. La solución óptima debe satisfacer:

Factibilidad primal

$$x_1 + 2x_2 \leq 40, \qquad x_1, x_2 \geq 0.$$

Factibilidad dual

$$\lambda \geq 0.$$

Complementariedad

$$\lambda(40 - x_1 - 2x_2) = 0.$$

Estacionariedad

$$\nabla_{\boldsymbol{x}} L(\boldsymbol{x}, \lambda) = 0.$$

Estas condiciones establecen el equilibrio entre la función objetivo y las restricciones del problema, constituyendo la estructura fundamental de las condiciones KKT para problemas convexos.

DRAFT

Este ejemplo muestra cómo un problema cotidiano de asignación de recursos puede formularse dentro del marco de la optimización convexa. La estructura convexa del conjunto factible garantiza que la solución obtenida corresponde a un óptimo global. La formulación primal describe directamente las decisiones del problema, mientras que la formulación dual interpreta el valor asociado a las restricciones mediante los multiplicadores de Lagrange.

Esta relación entre variables primales y duales constituye la base conceptual para la dualidad y las condiciones de optimalidad de Karush–Kuhn–Tucker, estableciendo la transición natural entre estructuras convexas, dualidad y condiciones de optimalidad.

DRAFT

3 Optimización de segundo orden

En los capítulos anteriores, la convexidad y las condiciones de optimalidad permitieron caracterizar los minimizadores de un problema de optimización. El siguiente paso consiste en construir procedimientos numéricos para aproximarlos. En este contexto, los métodos de segundo orden incorporan, además del gradiente, la información de curvatura proporcionada por la matriz Hessiana.

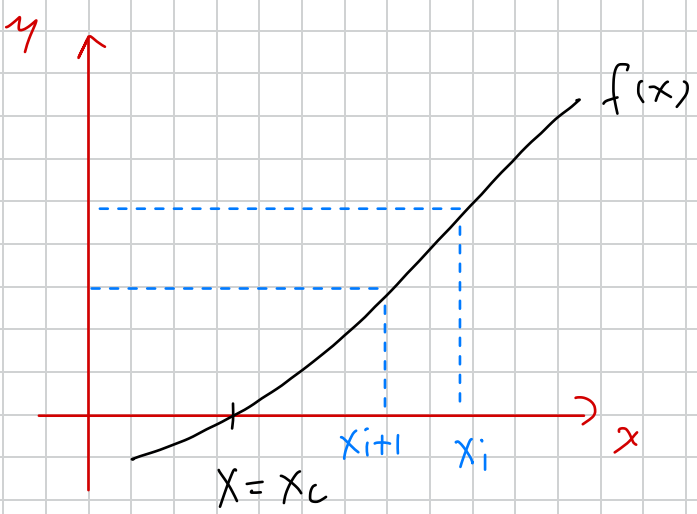
El capítulo comienza con la distinción entre optimización sin restricciones y con restricciones. A partir de esta formulación se obtiene el método de Newton, primero para problemas libres y después para problemas con igualdades. Las restricciones de desigualdad conducen a los métodos de barrera y de punto interior. Finalmente, los métodos cuasi-Newton permiten conservar parte de la información de curvatura sin calcular la Hessiana en cada iteración.

3.1 Optimización de segundo orden sin restricciones y con restricciones

En las secciones anteriores se estudiaron la convexidad, la dualidad y las condiciones de optimalidad como herramientas para caracterizar los minimizadores de un problema de optimización. Estas condiciones permiten determinar qué propiedades debe satisfacer una solución óptima, pero no establecen necesariamente un procedimiento para calcularla.

Para abordar esta dificultad, vamos a estudiar los métodos de optimización de segundo orden, los cuales utilizan la información del gradiente y de la matriz Hessiana de la función objetivo. Mientras que el gradiente describe la variación de primer

DRAFT



$f: \mathbb{R} \longrightarrow \mathbb{R}$

$x \longmapsto y = f(x)$

Taylor:

$$f(x) \approx f(a) + f'(a)(x-a)$$

$x = x_{i+1}$; $f(x_{i+1}) = 0$

$a = x_i$

$$f(x_{i+1}) = f(x_i) + f'(x_i)(x_{i+1} - x_i)$$

Despejamos x_{i+1} como las aproximaciones

$$-f(x_i) = f'(x_i)(x_{i+1} - x_i)$$

$$-\frac{f(x_i)}{f'(x_i)} = (x_{i+1} - x_i)$$

$$x_{i+1} = x_i - \alpha_i \frac{f(x_i)}{f'(x_i)} \qquad \alpha_i > 0$$

$$\alpha_i \to 0$$

$$f(x) = f(a) + f'(a)(x-a) + f''(a)\frac{(x-a)^2}{2} + \mathcal{O}$$

orden, la Hessiana proporciona información sobre la curvatura local de la función. Esta información permite construir aproximaciones cuadráticas que sirven como fundamento para determinar nuevas aproximaciones al minimizador.

Formulación del problema

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función dos veces continuamente diferenciable. El problema de optimización sin restricciones consiste en encontrar un punto $x^* \in \mathbb{R}^n$ tal que

$$f(x^*) \leq f(x), \qquad x \in \mathbb{R}^n.$$

Cuando las variables deben satisfacer determinadas condiciones, el problema puede expresarse mediante

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x), \\ \text{sujeto a} \quad & Ax = b, \\ & g_i(x) \leq 0, \qquad i = 1, \ldots, m, \end{aligned}$$

donde $A \in \mathbb{R}^{r \times n}$, $b \in \mathbb{R}^r$ y las funciones $g_i : \mathbb{R}^n \to \mathbb{R}$ representan las restricciones de desigualdad.

La diferencia fundamental entre ambos problemas se encuentra en las direcciones de desplazamiento permitidas. En ausencia de restricciones, las aproximaciones pueden modificarse en cualquier dirección de $\mathbb{R}^n$. En cambio, cuando existen restricciones, los desplazamientos deben ser compatibles con el conjunto factible.

Esta distinción determina la forma en que se utilizan las condiciones de optimalidad y, posteriormente, la construcción de los métodos iterativos.

Aproximación de segundo orden

Para comprender el fundamento de estos métodos, sea $x \in \mathbb{R}^n$ un punto dado y $p \in \mathbb{R}^n$ un desplazamiento.

Mediante la expansión de Taylor de segundo orden, obtenemos

$$f(x+p) = f(x) + \nabla f(x)^T p + \frac{1}{2} p^T \nabla^2 f(x) p + o(\|p\|^2), \qquad p \to 0. \tag{3.1}$$

En esta expresión, $\nabla f(x)$ representa el gradiente, mientras que $\nabla^2 f(x)$ es la matriz Hessiana, definida por

$$\nabla^2 f(x) = \left[\frac{\partial^2 f(x)}{\partial x_i \partial x_j} \right]_{i,j=1}^{n}.$$

La ecuación (3.1) muestra que el comportamiento local de una función suficientemente regular puede aproximarse mediante una función cuadrática.

En el problema sin restricciones x^* es el mínimo local

$\nabla f(x^*) = 0$; $\nabla^2 f(x^*) \geq 0$

DRAFT

En particular, el término lineal describe la variación determinada por el gradiente, mientras que la forma cuadrática asociada a la Hessiana permite distinguir las direcciones de curvatura de la función objetivo.

Esta observación constituye el fundamento matemático de los métodos de segundo orden.

Condiciones de optimalidad

Recordemos que, si x^* es un mínimo local de una función dos veces continuamente diferenciable en un problema sin restricciones, necesariamente

$$\nabla f(x^*) = 0$$

y

$$d^T \nabla^2 f(x^*) d \geq 0, \qquad d \in \mathbb{R}^n.$$

La primera condición expresa la estacionariedad, mientras que la segunda establece que la Hessiana es semidefinida positiva en el punto óptimo.

Si, además,

$$\nabla^2 f(x^*) \succ 0,$$

entonces x^* es un mínimo local estricto.

Cuando f es convexa, la condición de estacionariedad es suficiente para garantizar optimalidad global.

Por otra parte, en presencia de restricciones estas condiciones deben adaptarse a las direcciones admisibles. Por ejemplo, para una restricción afín $Ax = b$, los desplazamientos que preservan la igualdad satisfacen

$$Ad = 0.$$

En consecuencia, la estacionariedad de un mínimo restringido se estudia sobre el espacio de direcciones factibles $\ker(A)$.

Ejemplo 12 (Optimización con y sin restricciones)**.** Vamos a estudiar la función

$$f(x_1, x_2) = (x_1 - 2)^2 + 2(x_2 - 1)^2.$$

En primer lugar, determinaremos su minimizador sin restricciones y, posteriormente, analizaremos cómo cambia la solución cuando incorporamos una condición de igualdad.

Caso 1. Optimización sin restricciones.

Calculamos el gradiente y la matriz Hessiana:

DRAFT

$$\nabla f(x_1,x_2) = \begin{pmatrix} 2(x_1-2) \\ 4(x_2-1) \end{pmatrix}, \qquad \nabla^2 f(x_1,x_2) = \begin{pmatrix} 2 & 0 \\ 0 & 4 \end{pmatrix}.$$

La condición de estacionariedad conduce al sistema

$$2(x_1-2) = 0, \qquad 4(x_2-1) = 0.$$

Por tanto,

$$x^* = \begin{pmatrix} 2 \\ 1 \end{pmatrix}, \qquad f(x^*) = 0.$$

Los valores propios de la Hessiana son $\lambda_1 = 2$ y $\lambda_2 = 4$. Como ambos son positivos, la función es estrictamente convexa y el punto encontrado es su único minimizador global.

Caso 2. Optimización con restricciones.

Ahora vamos a minimizar la misma función, pero incorporando la condición

$$x_1 + x_2 = 1.$$

El minimizador anterior no satisface esta igualdad, por lo que debemos buscar una nueva solución dentro del conjunto factible.

Despejando $x_2 = 1 - x_1$ y sustituyendo en la función objetivo, obtenemos

$$\begin{aligned} \varphi(x_1) &= f(x_1, 1-x_1) \\ &= (x_1-2)^2 + 2x_1^2. \end{aligned}$$

Derivando,

$$\varphi'(x_1) = 6x_1 - 4, \qquad \varphi''(x_1) = 6 > 0.$$

La condición de estacionariedad implica

$$6x_1 - 4 = 0,$$

de donde se obtiene

$$x_1^* = \frac{2}{3}, \qquad x_2^* = \frac{1}{3}.$$

Por tanto, el único minimizador restringido es

$$x_c^* = \begin{pmatrix} \frac{2}{3} \\ \frac{1}{3} \end{pmatrix}, \qquad f(x_c^*) = \frac{8}{3}.$$

DRAFT

Observemos que, en este caso,

$$\nabla f(x_c^*) = \begin{pmatrix} -\frac{8}{3} \\ -\frac{8}{3} \end{pmatrix} \neq 0.$$

Esto no contradice la optimalidad, puesto que el mínimo se busca sobre la recta $x_1 + x_2 = 1$ y no sobre todo $\mathbb{R}^2$.

En efecto, cualquier dirección tangente a dicha recta tiene la forma

$$d = \begin{pmatrix} t \\ -t \end{pmatrix}, \qquad t \in \mathbb{R}.$$

Por consiguiente,

$$\nabla f(x_c^*)^T d = -\frac{8}{3}t + \frac{8}{3}t = 0.$$

Así, aunque el gradiente no se anula, su componente en toda dirección factible es nula.

Este resultado ilustra la diferencia entre las condiciones de estacionariedad de los problemas libres y restringidos.

El ejemplo anterior permite identificar dos aspectos fundamentales. Por una parte, la matriz Hessiana proporciona información sobre la curvatura de la función objetivo y permite estudiar la naturaleza de sus puntos estacionarios. Por otra, la presencia de restricciones modifica las direcciones en las que puede buscarse el minimizador.

Estas observaciones motivan el desarrollo de procedimientos iterativos basados en aproximaciones cuadráticas. Comenzaremos con el caso sin restricciones, en el cual la dirección de actualización puede determinarse directamente a partir del gradiente y de la Hessiana. Esta construcción conduce al método de Newton, que estudiaremos en la siguiente sección.

3.2 Método de Newton sin restricciones

En la sección anterior se estableció que la aproximación de Taylor de segundo orden permite describir localmente una función diferenciable mediante un modelo cuadrático. Esta propiedad proporciona el fundamento para construir métodos iterativos que utilizan simultáneamente el gradiente y la matriz Hessiana de la función objetivo.

El método de Newton aprovecha esta aproximación para determinar una dirección de búsqueda que incorpora la curvatura local de la función. A diferencia de los procedimientos que utilizan únicamente información de primer orden, la dirección de Newton se obtiene minimizando un modelo cuadrático construido alrededor de la aproximación actual.

DRAFT

Nuestro objetivo es deducir esta dirección y estudiar cómo puede utilizarse para aproximar el minimizador de una función convexa sin restricciones.

Construcción de la dirección de Newton

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función dos veces continuamente diferenciable y supongamos que queremos resolver el problema

$$\min_{x \in \mathbb{R}^n} f(x).$$

Partimos de una aproximación inicial $x^{(0)} \in \mathbb{R}^n$ y construimos una sucesión $\{x^{(k)}\}_{k \geq 0}$ que permita aproximar un minimizador de la función objetivo.

Sea $x^{(k)}$ la aproximación disponible en la iteración k. De acuerdo con la expansión de Taylor establecida en (3.1), podemos aproximar el comportamiento de f alrededor de $x^{(k)}$ mediante

$$m_k(p) = f(x^{(k)}) + \nabla f(x^{(k)})^T p + \frac{1}{2} p^T \nabla^2 f(x^{(k)}) p, \tag{3.2}$$

donde $p \in \mathbb{R}^n$ representa el desplazamiento que buscamos determinar.

Supongamos que la matriz Hessiana $\nabla^2 f(x^{(k)})$ es definida positiva. En consecuencia, m_k es una función cuadrática estrictamente convexa y admite un único minimizador.

Para encontrarlo, calculamos el gradiente del modelo respecto de p:

$$\nabla_p m_k(p) = \nabla f(x^{(k)}) + \nabla^2 f(x^{(k)}) p. \qquad \nabla_p m_k(p_k) = 0$$

Al imponer la condición de estacionariedad, obtenemos el sistema lineal

$$\nabla^2 f(x^{(k)}) p_k = -\nabla f(x^{(k)}). \tag{3.3}$$

El vector p_k obtenido al resolver (3.3) se denomina *dirección de Newton*.

Como la Hessiana es definida positiva, también es invertible. Por tanto, la dirección queda determinada de manera única.

Es importante observar que no es necesario calcular explícitamente la inversa de la Hessiana. Desde el punto de vista computacional, resulta preferible resolver directamente el sistema lineal (3.3).

Una vez calculada la dirección, actualizamos la aproximación mediante

$$x^{(k+1)} = x^{(k)} + \alpha_k p_k, \qquad 0 < \alpha_k \leq 1, \tag{3.4}$$

donde α_k representa la longitud del paso.

Cuando $\alpha_k = 1$, obtenemos el método de Newton con paso completo. Si $0 < \alpha_k < 1$, se utiliza una versión amortiguada, en la cual el desplazamiento se reduce para controlar el comportamiento de las iteraciones.

DRAFT

$$\nabla^2 f(x^{(k)}) p_k = -\nabla f(x^{(k)}). \tag{3.3}$$

Propiedades de la dirección de Newton

La construcción anterior permite establecer una propiedad fundamental del método. Supongamos que $\nabla^2 f(x^{(k)}) \succ 0$ y que $\nabla f(x^{(k)}) \neq 0$.
Multiplicando (3.3) por p_k^T, obtenemos

$$p_k^T \nabla^2 f(x^{(k)}) p_k = -p_k^T \nabla f(x^{(k)}).$$

Debido a que la Hessiana es definida positiva y $p_k \neq 0$, se cumple

$$\nabla f(x^{(k)})^T p_k = -p_k^T \nabla^2 f(x^{(k)}) p_k < 0.$$

Por consiguiente, p_k es una dirección de descenso estricto para la función objetivo.
Esto significa que, para valores suficientemente pequeños de $\alpha_k > 0$, el nuevo punto satisface

$$f(x^{(k)} + \alpha_k p_k) < f(x^{(k)}).$$

Sin embargo, esta propiedad no garantiza que el paso completo produzca siempre una disminución de la función. La elección de α_k debe tener en cuenta el comportamiento de la función objetivo.

Además, la existencia de una dirección de Newton no implica necesariamente que sea una dirección de descenso cuando la Hessiana es indefinida. Por esta razón, la estructura de la matriz Hessiana desempeña un papel central en el análisis del método.

Bajo condiciones apropiadas de regularidad, si la Hessiana en el minimizador es definida positiva y el punto inicial está suficientemente cerca de la solución, el método de Newton con paso completo presenta convergencia cuadrática local. En particular, si la Hessiana es localmente Lipschitz continua, el error satisface una estimación de la forma

$$\|x^{(k+1)} - x^*\| \leq C \|x^{(k)} - x^*\|^2,$$

para alguna constante $C > 0$ y para iteraciones suficientemente próximas al minimizador x^*.

Esta propiedad explica la rapidez de convergencia que puede alcanzar el método cuando las aproximaciones se encuentran en una vecindad adecuada de la solución.

Ejemplo 13 (Aplicación del método de Newton a una función no cuadrática)**.** Vamos a determinar el minimizador de la función

$$f(x) = \frac{1}{4}x^4 + \frac{1}{2}x^2, \qquad x \in \mathbb{R},$$

DRAFT

utilizando el método de Newton con paso completo y tomando como aproximación inicial

$$x^{(0)} = 1.$$

Análisis de la función objetivo.

En primer lugar, calculamos sus derivadas:

$$f'(x) = x^3 + x, \qquad f''(x) = 3x^2 + 1.$$

Como

$$f''(x) > 0, \qquad x \in \mathbb{R},$$

la función es estrictamente convexa.

Además, la condición de estacionariedad conduce a

$$x^3 + x = 0.$$

Factorizando,

$$x(x^2 + 1) = 0.$$

Por tanto, el único minimizador global es

$$x^* = 0, \qquad f(x^*) = 0.$$

Aunque en este ejemplo conocemos la solución exacta, utilizaremos el método de Newton para estudiar cómo se construye una sucesión que converge hacia ella.

Construcción de las iteraciones.

$$\nabla^2 f(x^{(k)}) p_k = -\nabla f(x^{(k)}). \tag{3.3}$$

En una dimensión, el sistema (3.3) se reduce a

$$f''(x^{(k)}) p_k = -f'(x^{(k)}).$$

Sustituyendo las derivadas de la función, obtenemos

$$p_k = -\frac{(x^{(k)})^3 + x^{(k)}}{3(x^{(k)})^2 + 1}.$$

Como hemos elegido $\alpha_k = 1$, la actualización (3.4) puede simplificarse a

$$x^{(k+1)} = x^{(k)} + \alpha_k p_k, \qquad 0 < \alpha_k \leq 1, \qquad x^{(k+1)} = \frac{2(x^{(k)})^3}{3(x^{(k)})^2 + 1}.$$

DRAFT

A continuación, calculamos las primeras iteraciones.
Para $k = 0$, tenemos

$$x^{(1)} = \frac{2(1)^3}{3(1)^2+1} = \frac{1}{2}.$$

Utilizando este resultado, encontramos

$$x^{(2)} = \frac{2(1/2)^3}{3(1/2)^2+1} = \frac{1}{7}.$$

De manera análoga,

$$x^{(3)} = \frac{2(1/7)^3}{3(1/7)^2+1} = \frac{1}{182}.$$

Por consiguiente, las primeras aproximaciones satisfacen

$$1 \longrightarrow \frac{1}{2} \longrightarrow \frac{1}{7} \longrightarrow \frac{1}{182} \longrightarrow \cdots.$$

Observemos que, después de tres iteraciones, el error absoluto es

$$|x^{(3)} - x^*| = \frac{1}{182} \approx 0.00549.$$

En este ejemplo podemos justificar también la convergencia de la sucesión.
En efecto, para $x^{(k)} > 0$,

$$0 < \frac{2(x^{(k)})^3}{3(x^{(k)})^2+1} < x^{(k)}.$$

De esta manera, la sucesión es positiva, decreciente y está acotada inferiormente. Por tanto, converge a un límite $\ell \geq 0$.
Pasando al límite en la relación de actualización, obtenemos

$$\ell = \frac{2\ell^3}{3\ell^2+1},$$

lo que implica

$$\ell(\ell^2+1) = 0.$$

Como $\ell^2 + 1 > 0$, necesariamente $\ell = 0$.
Así, las iteraciones convergen al único minimizador global de la función.

DRAFT

El ejemplo muestra cómo la información de segundo orden permite determinar una dirección de actualización a partir de un problema cuadrático auxiliar. En cada iteración, el gradiente identifica la variación local de la función, mientras que la Hessiana modifica el desplazamiento de acuerdo con su curvatura.

No obstante, la construcción desarrollada supone que las variables pueden actualizarse libremente en $\mathbb{R}^n$. Cuando el problema incorpora restricciones de igualdad, la dirección calculada mediante (3.3) puede dejar de ser admisible.

Esta dificultad conduce a modificar el modelo cuadrático para incorporar las restricciones del problema. En la siguiente sección estudiaremos el método de Newton con restricciones de igualdad, donde la dirección de búsqueda se determinará mediante un sistema que combina la aproximación de segundo orden con las condiciones KKT.

3.3 Método de Newton con restricciones de igualdad

En la sección anterior se construyó el método de Newton sin restricciones a partir de la aproximación cuadrática de la función objetivo. La dirección de búsqueda se obtuvo resolviendo el sistema lineal (3.3), bajo la hipótesis de que la matriz Hessiana es definida positiva.

Sin embargo, cuando las variables están sujetas a restricciones de igualdad, la dirección calculada mediante dicho sistema puede conducir a puntos que no pertenecen al conjunto factible. Por tanto, es necesario incorporar las restricciones directamente en la construcción de la dirección de Newton.

Esta modificación puede realizarse mediante las condiciones de Karush–Kuhn–Tucker (KKT), que permiten combinar la información de segundo orden de la función objetivo con las restricciones del problema.

Formulación del problema

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función dos veces continuamente diferenciable. Vamos a estudiar el problema de optimización

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x), \\ \text{sujeto a} \quad & Ax = b, \end{aligned} \tag{3.5}$$

donde $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$ y suponemos que el conjunto factible es no vacío.

Para simplificar el análisis, asumiremos que A tiene rango completo por filas.

El objetivo consiste en construir una sucesión $\{x^{(k)}\}_{k \geq 0}$ que aproxime una solución del problema (3.5), respetando las restricciones impuestas.

Sea $x^{(k)}$ una aproximación disponible. Si $p \in \mathbb{R}^n$ representa un desplazamiento, la nueva aproximación con paso completo será

DRAFT

$$x^{(k+1)} = x^{(k)} + p.$$

Para que este punto satisfaga la restricción, debe cumplirse

$$A(x^{(k)} + p) = b.$$

Reorganizando los términos, obtenemos

$$Ap = b - Ax^{(k)}. \tag{3.6}$$

Esta relación determina los desplazamientos que permiten alcanzar el conjunto factible.

En particular, si la aproximación actual satisface $Ax^{(k)} = b$, la condición anterior se reduce a

$$Ap = 0.$$

Por tanto, cuando partimos de un punto factible, la dirección de actualización debe pertenecer al espacio nulo de A.

Construcción del sistema de Newton

Al igual que en el caso sin restricciones, utilizamos el modelo cuadrático establecido en (3.2).

La diferencia consiste en que ahora debemos determinar el desplazamiento que minimiza dicho modelo, sujeto a la condición (3.6).

En consecuencia, el problema auxiliar es

$$\begin{aligned} \min_{p \in \mathbb{R}^n} \quad & m_k(p), \\ \text{sujeto a} \quad & Ap = b - Ax^{(k)}. \end{aligned}$$

Para resolverlo, introducimos un vector de multiplicadores de Lagrange $\nu \in \mathbb{R}^m$ y definimos

$$\mathscr{L}_k(p, \nu) = m_k(p) + \nu^T (Ap + Ax^{(k)} - b).$$

Las condiciones de estacionariedad respecto de p y ν conducen a

$$\begin{aligned} \nabla_p \mathscr{L}_k(p, \nu) &= \nabla f(x^{(k)}) + \nabla^2 f(x^{(k)}) p + A^T \nu = 0, \\ \nabla_\nu \mathscr{L}_k(p, \nu) &= Ap + Ax^{(k)} - b = 0. \end{aligned}$$

Estas expresiones constituyen las condiciones KKT del problema cuadrático auxiliar.

DRAFT

Reorganizando los términos, obtenemos el sistema lineal

$$\begin{pmatrix} \nabla^2 f(x^{(k)}) & A^T \\ A & 0 \end{pmatrix} \begin{pmatrix} p_k \\ \nu_k \end{pmatrix} = - \begin{pmatrix} \nabla f(x^{(k)}) \\ Ax^{(k)} - b \end{pmatrix}. \tag{3.7}$$

El sistema (3.7) se conoce como el sistema de Newton–KKT.

Su solución proporciona simultáneamente la dirección de búsqueda p_k y los multiplicadores asociados al problema cuadrático de cada iteración.

A diferencia del sistema de Newton sin restricciones, la matriz de coeficientes incorpora la Hessiana y la matriz de restricciones A.

Para garantizar la unicidad de la dirección, es suficiente suponer que A tiene rango completo por filas y que la Hessiana es definida positiva sobre $\ker(A)$, es decir,

$$d^T \nabla^2 f(x^{(k)}) d > 0, \qquad d \in \ker(A) \setminus \{0\}.$$

Bajo estas condiciones, el modelo cuadrático es estrictamente convexo sobre las direcciones factibles y el sistema (3.7) tiene solución única.

Actualización de las aproximaciones

Una vez calculada la dirección p_k, actualizamos la aproximación mediante la regla (3.4).

Cuando el punto inicial es factible, la relación (3.6) garantiza que $Ap_k = 0$. En consecuencia,

$$\begin{aligned} Ax^{(k+1)} &= A(x^{(k)} + \alpha_k p_k) \\ &= Ax^{(k)} + \alpha_k A p_k \\ &= b. \end{aligned}$$

Por tanto, cualquier longitud de paso $0 < \alpha_k \leq 1$ conserva la factibilidad de las iteraciones.

Además, si $p_k \neq 0$, podemos establecer una propiedad análoga a la obtenida para el método sin restricciones.

En efecto, de las condiciones KKT se tiene

$$\nabla^2 f(x^{(k)}) p_k + A^T \nu_k = -\nabla f(x^{(k)}).$$

Multiplicando por p_k^T y utilizando $Ap_k = 0$, resulta

$$\nabla f(x^{(k)})^T p_k = -p_k^T \nabla^2 f(x^{(k)}) p_k.$$

Como la Hessiana es definida positiva sobre $\ker(A)$, concluimos que

DRAFT

$$\nabla f(x^{(k)})^T p_k < 0.$$

Así, p_k constituye una dirección de descenso factible siempre que sea distinta del vector nulo.

Esta propiedad permite interpretar el método como un procedimiento que busca reducir la función objetivo sin abandonar el conjunto definido por las restricciones de igualdad.

Aproximaciones iniciales no factibles

Hasta ahora hemos considerado la posibilidad de partir de un punto que satisface las restricciones del problema. Sin embargo, el sistema (3.7) también puede utilizarse cuando la aproximación inicial no es factible.

En este caso,

$$Ax^{(0)} \neq b,$$

y la condición (3.6) permite determinar un desplazamiento que corrige el incumplimiento de la restricción.

Si utilizamos un paso completo $\alpha_0 = 1$, se obtiene

$$\begin{aligned} Ax^{(1)} &= A(x^{(0)} + p_0) \\ &= Ax^{(0)} + b - Ax^{(0)} \\ &= b. \end{aligned}$$

De esta manera, después de la primera actualización el nuevo punto pertenece al conjunto factible.

Es importante señalar que, si se utiliza un paso amortiguado $\alpha_0 < 1$, esta propiedad no se garantiza en una única iteración.

Por tanto, el sistema Newton–KKT permite tratar tanto aproximaciones iniciales factibles como no factibles, aunque el comportamiento de las actualizaciones depende de la longitud del paso utilizada.

Ejemplo 14 (Método de Newton para un problema no cuadrático con restricción de igualdad)**.** Vamos a determinar numéricamente el minimizador del problema

$$\begin{aligned} \min_{(x_1,x_2)\in\mathbb{R}^2} \quad & f(x_1,x_2) = \frac{1}{4}x_1^4 + \frac{1}{2}x_1^2 + \frac{1}{2}x_2^2, \\ \text{sujeto a} \quad & x_1 + x_2 = 1. \end{aligned}$$

Elegimos como aproximación inicial

DRAFT

$$x^{(0)} = \begin{pmatrix} 0 \\ 1 \end{pmatrix},$$

que satisface la restricción de igualdad.

Análisis de la función objetivo.

Calculamos el gradiente y la matriz Hessiana:

$$\nabla f(x_1, x_2) = \begin{pmatrix} x_1^3 + x_1 \\ x_2 \end{pmatrix}, \qquad \nabla^2 f(x_1, x_2) = \begin{pmatrix} 3x_1^2 + 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Observemos que la Hessiana es definida positiva para todo punto de $\mathbb{R}^2$.

Por tanto, la función objetivo es estrictamente convexa y el problema restringido admite a lo sumo un minimizador.

Además, como la función es coerciva y el conjunto factible es cerrado y no vacío, existe un único minimizador global.

En este problema, la matriz y el vector de restricciones están dados por

$$A = \begin{pmatrix} 1 & 1 \end{pmatrix}, \qquad b = 1.$$

Primera iteración.

En $x^{(0)} = (0,1)^T$, obtenemos

$$\nabla f(x^{(0)}) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}, \qquad \nabla^2 f(x^{(0)}) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}.$$

Sustituyendo estos resultados en (3.7), el sistema correspondiente es

$$\begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} p_{0,1} \\ p_{0,2} \\ \nu_0 \end{pmatrix} = \begin{pmatrix} 0 \\ -1 \\ 0 \end{pmatrix}.$$

La tercera ecuación establece que

$$p_{0,1} + p_{0,2} = 0.$$

De las dos primeras ecuaciones tenemos

$$p_{0,1} + \nu_0 = 0, \qquad p_{0,2} + \nu_0 = -1.$$

Resolviendo el sistema, obtenemos

$$p_0 = \begin{pmatrix} \frac{1}{2} \\ -\frac{1}{2} \end{pmatrix}, \qquad \nu_0 = -\frac{1}{2}.$$

DRAFT

Tomando $\alpha_0 = 1$, la nueva aproximación es

$$x^{(1)} = x^{(0)} + p_0 = \begin{pmatrix} \frac{1}{2} \\ \frac{1}{2} \end{pmatrix}.$$

Observemos que se conserva la restricción:

$$\frac{1}{2} + \frac{1}{2} = 1.$$

Segunda iteración.
En la nueva aproximación tenemos

$$\nabla f(x^{(1)}) = \begin{pmatrix} \frac{5}{8} \\ \frac{1}{2} \end{pmatrix}, \qquad \nabla^2 f(x^{(1)}) = \begin{pmatrix} \frac{7}{4} & 0 \\ 0 & 1 \end{pmatrix}.$$

El sistema Newton–KKT toma la forma

$$\begin{pmatrix} \frac{7}{4} & 0 & 1 \\ 0 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} p_{1,1} \\ p_{1,2} \\ \nu_1 \end{pmatrix} = - \begin{pmatrix} \frac{5}{8} \\ \frac{1}{2} \\ 0 \end{pmatrix}.$$

De la última ecuación,

$$p_{1,2} = -p_{1,1}.$$

Sustituyendo esta relación en las dos primeras ecuaciones y eliminando el multiplicador, encontramos

$$\frac{11}{4} p_{1,1} = -\frac{1}{8}.$$

Por consiguiente,

$$p_1 = \begin{pmatrix} -\frac{1}{22} \\ \frac{1}{22} \end{pmatrix}.$$

Utilizando nuevamente un paso completo,

$$x^{(2)} = \begin{pmatrix} \frac{1}{2} \\ \frac{1}{2} \end{pmatrix} + \begin{pmatrix} -\frac{1}{22} \\ \frac{1}{22} \end{pmatrix} = \begin{pmatrix} \frac{5}{11} \\ \frac{6}{11} \end{pmatrix}.$$

La aproximación obtenida continúa satisfaciendo la restricción del problema.

Análisis del resultado.

DRAFT

Para verificar la solución hacia la cual convergen las iteraciones, utilizamos la condición $x_2 = 1 - x_1$.

Sustituyendo en la función objetivo, obtenemos el problema equivalente

$$\min_{x_1 \in \mathbb{R}} \left\{ \frac{1}{4}x_1^4 + \frac{1}{2}x_1^2 + \frac{1}{2}(1-x_1)^2 \right\}.$$

La condición de estacionariedad conduce a

$$x_1^3 + 2x_1 - 1 = 0.$$

Como la derivada del lado izquierdo es $3x_1^2 + 2 > 0$, esta ecuación tiene una única raíz real.

Su solución numérica es aproximadamente

$$x^* \approx \begin{pmatrix} 0.45339765 \\ 0.54660235 \end{pmatrix}.$$

Por otra parte, la segunda iteración del método proporciona

$$x^{(2)} \approx \begin{pmatrix} 0.45454545 \\ 0.54545455 \end{pmatrix}.$$

Observamos que, después de dos iteraciones, se obtiene una aproximación cercana al único minimizador global.

Este ejemplo muestra que el sistema Newton–KKT permite incorporar las restricciones en la construcción de cada dirección de búsqueda, sin necesidad de eliminar previamente las variables restringidas.

El método desarrollado extiende la construcción de Newton al caso de restricciones afines de igualdad. La aproximación cuadrática continúa proporcionando información sobre la curvatura de la función objetivo, mientras que las condiciones KKT garantizan que las direcciones calculadas sean compatibles con las restricciones.

Sin embargo, cuando el problema incluye restricciones de desigualdad, no basta con imponer una condición lineal sobre los desplazamientos, puesto que las direcciones admisibles dependen también de las restricciones activas y de la posición de la aproximación actual.

Para abordar esta dificultad, en la siguiente sección estudiaremos los métodos de punto interior y de barrera. Estos procedimientos permiten incorporar las restricciones de desigualdad mediante funciones auxiliares, de manera que el problema resultante pueda tratarse utilizando los métodos de Newton desarrollados hasta ahora.

DRAFT

3.4 Método de Newton con restricciones de desigualdad: métodos de punto interior y de barrera

En la sección anterior se desarrolló el método de Newton para problemas con restricciones afines de igualdad. Mediante el sistema (3.7), se determinó una dirección de búsqueda compatible con las restricciones, incorporando simultáneamente la información del gradiente y de la matriz Hessiana de la función objetivo.

Cuando el problema incluye restricciones de desigualdad, aparece una dificultad adicional: las direcciones de búsqueda deben mantener las aproximaciones dentro de la región factible. Además, algunas restricciones pueden satisfacerse como igualdades en el punto óptimo, mientras que otras permanecen estrictamente inactivas.

Para abordar esta situación, estudiaremos los métodos de punto interior y de barrera, cuya idea fundamental consiste en incorporar las restricciones de desigualdad a la función objetivo mediante términos que penalizan la proximidad a la frontera del conjunto factible.

Esta transformación permite construir problemas auxiliares que pueden resolverse utilizando los métodos de Newton desarrollados en las secciones anteriores.

Formulación del problema

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función convexa y dos veces continuamente diferenciable. Vamos a estudiar el problema

$$\begin{aligned} \min_{x\in\mathbb{R}^n} \quad & f(x), \\ \text{sujeto a} \quad & g_i(x) \le 0, \qquad i = 1,\dots,m, \\ & Ax = b, \end{aligned} \tag{3.8}$$

donde las funciones $g_i : \mathbb{R}^n \to \mathbb{R}$ son convexas y dos veces continuamente diferenciables, $A \in \mathbb{R}^{r\times n}$ y $b \in \mathbb{R}^r$.

Supondremos que las restricciones admiten al menos un punto estrictamente factible, es decir, existe $\bar{x} \in \mathbb{R}^n$ tal que

$$A\bar{x} = b, \qquad g_i(\bar{x}) < 0, \quad i = 1,\dots,m.$$

Esta hipótesis permite trabajar con aproximaciones que satisfacen estrictamente las desigualdades durante el procedimiento iterativo.

Una manera de incorporar las restricciones a la función objetivo consiste en utilizar la función indicadora

$$I_i(x) = \begin{cases} 0, & g_i(x) \le 0, \\ +\infty, & g_i(x) > 0. \end{cases}$$

DRAFT

Con esta representación, las restricciones de desigualdad pueden incorporarse a la función objetivo mediante la suma de sus indicadoras.

Sin embargo, esta función no es diferenciable en la frontera del conjunto factible. Por tanto, no permite aplicar directamente el método de Newton.

Para superar esta dificultad, reemplazamos la función indicadora por una función diferenciable definida en la región estrictamente factible.

Función de barrera logarítmica

Una de las funciones más utilizadas para incorporar restricciones de desigualdad es la barrera logarítmica.

Para cada restricción $g_i(x) \leq 0$, introducimos el término

$$-\log(-g_i(x)), \qquad g_i(x) < 0.$$

Observemos que, cuando $g_i(x)$ se aproxima a cero desde valores negativos,

$$-\log(-g_i(x)) \longrightarrow +\infty.$$

Por tanto, la barrera impide que una aproximación alcance la frontera del conjunto factible mientras permanezca definida.

Incorporando estos términos a la función objetivo del problema (3.8), definimos

$$\Phi_t(x) = f(x) - \frac{1}{t}\sum_{i=1}^{m} \log(-g_i(x)), \qquad t > 0, \tag{3.9}$$

con dominio determinado por las condiciones

$$g_i(x) < 0, \qquad i = 1, \ldots, m.$$

El parámetro t controla la influencia de los términos de barrera sobre la función objetivo.

Para valores pequeños de t, estos términos tienen mayor peso y tienden a mantener las aproximaciones alejadas de la frontera. En cambio, cuando t aumenta, su influencia disminuye en los puntos estrictamente factibles.

De esta manera, el problema original se sustituye por una familia de problemas auxiliares de la forma

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & \Phi_t(x), \\ \text{sujeto a} \quad & Ax = b, \end{aligned} \tag{3.10}$$

donde se mantiene la condición de factibilidad estricta para las desigualdades.

La transformación es importante porque el problema (3.10) contiene únicamente restricciones explícitas de igualdad. En consecuencia, podemos utilizar el método de Newton desarrollado en la sección anterior.

DRAFT

Aplicación del método de Newton

Para construir las iteraciones de Newton necesitamos determinar el gradiente y la matriz Hessiana de la función Φ_t.

Derivando (3.9), obtenemos

$$\nabla \Phi_t(x) = \nabla f(x) - \frac{1}{t} \sum_{i=1}^{m} \frac{\nabla g_i(x)}{g_i(x)}.$$

De manera análoga, la matriz Hessiana está dada por

$$\nabla^2 \Phi_t(x) = \nabla^2 f(x) + \frac{1}{t} \sum_{i=1}^{m} \left[\frac{\nabla g_i(x) \nabla g_i(x)^T}{g_i(x)^2} - \frac{\nabla^2 g_i(x)}{g_i(x)} \right].$$

Estas expresiones muestran cómo las restricciones modifican tanto el gradiente como la curvatura del problema auxiliar.

En particular, debido a la convexidad de g_i y a que $g_i(x) < 0$, cada término de barrera aporta una matriz Hessiana semidefinida positiva.

Por tanto, si f y las restricciones de desigualdad son convexas, la función Φ_t también es convexa en su dominio.

Sea ahora $x^{(k)}$ una aproximación estrictamente factible que satisface $Ax^{(k)} = b$.

Aplicando el sistema Newton–KKT (3.7) a la función Φ_t, obtenemos

$$\begin{pmatrix} \nabla^2 \Phi_t(x^{(k)}) & A^T \\ A & 0 \end{pmatrix} \begin{pmatrix} p_k \\ \mu_k \end{pmatrix} = - \begin{pmatrix} \nabla \Phi_t(x^{(k)}) \\ 0 \end{pmatrix}. \tag{3.11}$$

La solución de este sistema determina la dirección de Newton p_k y los multiplicadores μ_k correspondientes a las igualdades del problema auxiliar.

Si no existen restricciones de igualdad, el sistema se reduce a

$$\nabla^2 \Phi_t(x^{(k)}) p_k = -\nabla \Phi_t(x^{(k)}).$$

Así, los métodos de barrera utilizan la misma estructura de Newton estudiada anteriormente, pero aplicada a una función objetivo que incorpora las restricciones de desigualdad.

Para garantizar la unicidad de la dirección, suponemos que la Hessiana de Φ_t es definida positiva sobre las direcciones que satisfacen $Ap = 0$ y que A tiene rango completo por filas.

DRAFT

Actualización y conservación de la factibilidad

Una vez determinada la dirección de Newton, actualizamos la aproximación mediante la regla (3.4).

Sin embargo, a diferencia del caso con únicamente restricciones de igualdad, la longitud del paso debe seleccionarse de manera que el nuevo punto permanezca en el dominio de la barrera.

Por tanto, exigimos

$$g_i(x^{(k)} + \alpha_k p_k) < 0, \qquad i = 1, \ldots, m.$$

La restricción de igualdad se conserva porque $Ap_k = 0$ cuando el punto actual es factible.

En consecuencia, el valor de α_k debe permitir dos condiciones: mantener la factibilidad estricta y producir una disminución adecuada de la función Φ_t.

Una estrategia consiste en iniciar con $\alpha_k = 1$ y reducirlo progresivamente cuando alguna de estas condiciones no se satisface.

De esta manera, la búsqueda lineal permite utilizar la dirección de Newton sin abandonar el dominio de la función de barrera.

El procedimiento se aplica para un valor fijo de t hasta aproximar el minimizador del problema auxiliar. Posteriormente, se aumenta el parámetro t y se repite la minimización, utilizando la solución anterior como aproximación inicial.

Así se construye una sucesión de soluciones interiores asociadas a valores crecientes del parámetro de barrera.

Precisión del método de barrera

La transformación anterior permite aproximar la solución del problema original mediante una familia de problemas diferenciables.

Sin embargo, es importante determinar cómo se relaciona la solución de cada problema auxiliar con el minimizador restringido.

Sea x_t un minimizador del problema (3.10) y supongamos que las condiciones de optimalidad correspondientes se satisfacen.

A partir de la condición de estacionariedad de Φ_t, podemos definir los multiplicadores asociados a las desigualdades mediante

$$\lambda_i(t) = -\frac{1}{t\, g_i(x_t)}, \qquad i = 1, \ldots, m.$$

Como $g_i(x_t) < 0$, necesariamente

$$\lambda_i(t) > 0.$$

DRAFT

Además, estos multiplicadores satisfacen

$$\lambda_i(t) g_i(x_t) = -\frac{1}{t}.$$

Esta expresión muestra que las condiciones de complementariedad de KKT no se satisfacen exactamente para un valor finito de t, pero sus productos tienden a cero cuando t aumenta.

Sumando las relaciones anteriores, obtenemos

$$\sum_{i=1}^{m} \lambda_i(t) g_i(x_t) = -\frac{m}{t}.$$

La interpretación de esta igualdad puede establecerse mediante la dualidad.

En efecto, la condición de estacionariedad del problema de barrera coincide con la estacionariedad de la Lagrangiana original para los multiplicadores $\lambda_i(t)$ y los correspondientes multiplicadores de igualdad.

Debido a la convexidad del problema, estos multiplicadores proporcionan una cota dual inferior igual a

$$f(x_t) - \frac{m}{t}.$$

Por dualidad débil y factibilidad de x_t, resulta

$$f(x_t) - \frac{m}{t} \leq f^* \leq f(x_t),$$

donde f^* representa el valor óptimo del problema original.

En consecuencia,

$$0 \leq f(x_t) - f^* \leq \frac{m}{t}. \tag{3.12}$$

La desigualdad (3.12) establece una cota del error de optimalidad medido con la función objetivo original.

Por tanto, bajo las hipótesis anteriores, el valor objetivo de la solución de barrera se aproxima al valor óptimo cuando $t \to +\infty$.

Es importante distinguir esta propiedad de la convergencia de los puntos x_t: la cota garantiza convergencia de valores óptimos, mientras que la convergencia de los minimizadores requiere condiciones adicionales.

También debemos observar que aumentar t puede producir problemas auxiliares más difíciles de resolver numéricamente, debido al comportamiento de la Hessiana cerca de la frontera del conjunto factible.

DRAFT

Ejemplo 15 (Método de Newton con barrera logarítmica)**.** Vamos a resolver el problema

$$\begin{aligned} \min_{x\in\mathbb{R}} \quad & f(x) = (x-2)^2, \\ \text{sujeto a} \quad & x \leq 1. \end{aligned}$$

Este ejemplo permitirá observar cómo la barrera mantiene las iteraciones en la región factible y cómo sus soluciones se aproximan al óptimo restringido.

Análisis del problema original.

La función objetivo es estrictamente convexa, puesto que

$$f''(x) = 2 > 0.$$

Sin restricciones, el minimizador es $x = 2$. Sin embargo, este punto no satisface la condición $x \leq 1$.

Por tanto, el minimizador restringido se encuentra en la frontera:

$$x^* = 1, \qquad f(x^*) = 1.$$

Construcción de la función de barrera.

La restricción puede escribirse como

$$g(x) = x - 1 \leq 0.$$

De acuerdo con (3.9), la función auxiliar es

$$\Phi_t(x) = (x-2)^2 - \frac{1}{t}\log(1-x), \qquad x < 1.$$

Calculamos sus derivadas:

$$\Phi_t'(x) = 2(x-2) + \frac{1}{t(1-x)}$$

y

$$\Phi_t''(x) = 2 + \frac{1}{t(1-x)^2}.$$

Observemos que

$$\Phi_t''(x) > 0, \qquad x < 1.$$

Por tanto, para cada $t > 0$, la función auxiliar es estrictamente convexa y posee un único minimizador en su dominio.

DRAFT

Aplicación del método de Newton.
Tomemos $t = 2$ y la aproximación inicial

$$x^{(0)} = 0.$$

La dirección de Newton se obtiene mediante

$$p_k = -\frac{\Phi_2'(x^{(k)})}{\Phi_2''(x^{(k)})}.$$

En la primera iteración,

$$\Phi_2'(0) = -\frac{7}{2}, \qquad \Phi_2''(0) = \frac{5}{2}.$$

Por consiguiente,

$$p_0 = -\frac{-7/2}{5/2} = \frac{7}{5}.$$

Si utilizáramos un paso completo, obtendríamos

$$x^{(0)} + p_0 = \frac{7}{5} > 1,$$

lo que viola la restricción del problema y queda fuera del dominio de la barrera.
Por esta razón, reducimos la longitud del paso. Tomando $\alpha_0 = 1/2$, obtenemos

$$x^{(1)} = 0 + \frac{1}{2}\left(\frac{7}{5}\right) = \frac{7}{10}.$$

La nueva aproximación satisface $x^{(1)} < 1$ y disminuye el valor de la función de barrera.
Para la segunda iteración, calculamos

$$\Phi_2'\left(\frac{7}{10}\right) = -\frac{14}{15}, \qquad \Phi_2''\left(\frac{7}{10}\right) = \frac{68}{9}.$$

De aquí,

$$p_1 = -\frac{-14/15}{68/9} = \frac{21}{170}.$$

Utilizando ahora un paso completo,

$$x^{(2)} = \frac{7}{10} + \frac{21}{170} = \frac{14}{17} \approx 0.823529.$$

DRAFT

Esta aproximación continúa dentro de la región estrictamente factible.

Repitiendo el procedimiento, obtenemos en las siguientes iteraciones

$$x^{(3)} \approx 0.796923, \qquad x^{(4)} \approx 0.792961.$$

Para identificar el valor al cual convergen estas aproximaciones, resolvemos la condición de estacionariedad

$$\Phi_t'(x_t) = 0.$$

Sustituyendo las derivadas, encontramos

$$2(x_t - 2) + \frac{1}{t(1-x_t)} = 0.$$

Multiplicando por $t(1-x_t)$ y reorganizando,

$$2(2-x_t)(1-x_t) = \frac{1}{t}.$$

La solución que pertenece al dominio $x_t < 1$ está dada por

$$x_t = \frac{3 - \sqrt{1+2/t}}{2}.$$

Para $t = 2$, obtenemos

$$x_2 = \frac{3-\sqrt{2}}{2} \approx 0.792893.$$

Este resultado confirma que las iteraciones calculadas se aproximan al minimizador del problema auxiliar.

Efecto del parámetro de barrera.

La expresión anterior permite estudiar el comportamiento de los minimizadores para distintos valores de t.

Por ejemplo,

$$\begin{aligned} t = 2 \quad &\Longrightarrow \quad x_t \approx 0.792893, \\ t = 10 \quad &\Longrightarrow \quad x_t \approx 0.952277, \\ t = 100 \quad &\Longrightarrow \quad x_t \approx 0.995025. \end{aligned}$$

Observemos que todos estos puntos satisfacen $x_t < 1$.

Además,

$$\lim_{t \to +\infty} x_t = \frac{3-1}{2} = 1 = x^*.$$

DRAFT

Por tanto, las soluciones interiores se aproximan al minimizador del problema original a medida que aumenta el parámetro de barrera.

En este ejemplo también podemos verificar la cota (3.12).

Como existe una única restricción de desigualdad, $m = 1$. Para $t = 2$, el error de optimalidad es

$$\begin{aligned} f(x_2) - f^* &= \left(\frac{3-\sqrt{2}}{2} - 2 \right)^2 - 1 \\ &\approx 0.457107 < \frac{1}{2}. \end{aligned}$$

Por consiguiente, el resultado es consistente con la cota teórica del método de barrera.

El ejemplo anterior muestra cómo los métodos de punto interior permiten aproximar soluciones ubicadas en la frontera del conjunto factible mediante una sucesión de puntos estrictamente factibles.

La barrera logarítmica incorpora las desigualdades a la función objetivo, mientras que el método de Newton proporciona las direcciones necesarias para resolver los problemas auxiliares.

De esta manera, los métodos de Newton sin restricciones, con igualdades y con desigualdades comparten una misma estructura matemática: la utilización de información de segundo orden para construir aproximaciones sucesivas.

No obstante, esta estrategia requiere calcular o utilizar la matriz Hessiana en cada iteración. Cuando la dimensión del problema es elevada, este procedimiento puede representar un costo computacional considerable.

Esta limitación motiva el estudio de los métodos cuasi-Newton, los cuales aproximan la información de segundo orden utilizando los cambios observados en el gradiente durante las iteraciones, sin necesidad de calcular explícitamente la Hessiana exacta en cada paso.

3.5 Métodos cuasi-Newton

En las secciones anteriores se desarrollaron los métodos de Newton para problemas de optimización sin restricciones y con restricciones de igualdad y desigualdad. En todos estos casos, la información de segundo orden desempeña un papel fundamental en la construcción de las direcciones de búsqueda.

En particular, el método de Newton utiliza la matriz Hessiana de la función objetivo para determinar, mediante un sistema lineal, el desplazamiento que permite obtener una nueva aproximación al minimizador.

Sin embargo, cuando la dimensión del problema es elevada, calcular y utilizar la Hessiana exacta en cada iteración puede representar un costo computacional considerable. Esta dificultad motiva el estudio de métodos que conservan la estructura de

DRAFT

Newton, pero sustituyen la información exacta de segundo orden por aproximaciones construidas a partir de las iteraciones anteriores.

Los métodos cuasi-Newton siguen precisamente esta estrategia. Su idea principal consiste en aproximar la matriz Hessiana, o su inversa, utilizando los desplazamientos realizados y los cambios observados en el gradiente de la función objetivo.

Aproximación de la matriz Hessiana

Sea $f : \mathbb{R}^n \to \mathbb{R}$ una función dos veces continuamente diferenciable. Vamos a estudiar nuevamente el problema de optimización sin restricciones

$$\min_{x \in \mathbb{R}^n} f(x).$$

Recordemos que la dirección de Newton se obtiene resolviendo el sistema (3.3), cuya construcción depende de la Hessiana exacta $\nabla^2 f(x^{(k)})$.

En los métodos cuasi-Newton, esta matriz se sustituye por una aproximación $B_k \in \mathbb{R}^{n \times n}$.

Cuando B_k es invertible, podemos definir

$$H_k = B_k^{-1},$$

donde H_k representa una aproximación de la inversa de la Hessiana.

De esta manera, la dirección de búsqueda se determina mediante

$$p_k = -H_k \nabla f(x^{(k)}). \tag{3.13}$$

Una vez calculada la dirección, la aproximación se actualiza utilizando (3.4).

La diferencia fundamental respecto al método de Newton clásico es que ahora H_k no se calcula invirtiendo la Hessiana exacta, sino que se actualiza utilizando información obtenida durante el proceso iterativo.

Para comprender cómo se construyen estas aproximaciones, debemos establecer una relación entre los desplazamientos y los cambios del gradiente.

Condición secante

Sea $x^{(k+1)}$ la aproximación obtenida después de una iteración.

Definimos los vectores

$$\begin{aligned} s_k &= x^{(k+1)} - x^{(k)}, \\ y_k &= \nabla f(x^{(k+1)}) - \nabla f(x^{(k)}). \end{aligned} \tag{3.14}$$

DRAFT

El vector s_k representa el desplazamiento realizado, mientras que y_k describe el cambio experimentado por el gradiente.

Para establecer la relación entre ambos vectores, utilizamos la aproximación de Taylor aplicada al gradiente:

$$\nabla f(x^{(k)} + s_k) \approx \nabla f(x^{(k)}) + \nabla^2 f(x^{(k)}) s_k.$$

Reorganizando los términos y utilizando las definiciones anteriores, obtenemos

$$y_k \approx \nabla^2 f(x^{(k)}) s_k.$$

Esta expresión muestra que la variación del gradiente contiene información sobre la curvatura de la función objetivo.

Por tanto, buscamos una matriz B_{k+1} que satisfaga exactamente la relación

$$B_{k+1} s_k = y_k. \tag{3.15}$$

La ecuación (3.15) se denomina *condición secante*.

Si trabajamos con una aproximación de la inversa de la Hessiana, la misma condición puede escribirse como

$$H_{k+1} y_k = s_k.$$

Es importante observar que la condición secante no determina de manera única una matriz de dimensión $n \times n$.

Por esta razón, los distintos métodos cuasi-Newton se diferencian principalmente en la forma como actualizan sus matrices, utilizando la condición secante y propiedades adicionales.

Entre estas propiedades se encuentran la simetría y, cuando corresponde, la conservación de la definición positiva.

En particular, si H_k es definida positiva y el gradiente no se anula, la dirección (3.13) satisface

$$\begin{aligned} \nabla f(x^{(k)})^T p_k &= -\nabla f(x^{(k)})^T H_k \nabla f(x^{(k)}) \\ &< 0. \end{aligned}$$

Por tanto, constituye una dirección de descenso estricto.

Esta propiedad explica la importancia de construir aproximaciones que conserven la definición positiva cuando se minimizan funciones convexas.

DRAFT

Método BFGS

Uno de los métodos cuasi-Newton más utilizados es el método Broyden–Fletcher–Goldfarb–Shanno (BFGS).

Este procedimiento actualiza la aproximación de la Hessiana, o de su inversa, utilizando los vectores s_k y y_k definidos en (3.14).

Supongamos que

$$y_k^T s_k > 0.$$

Definimos

$$\rho_k = \frac{1}{y_k^T s_k}, \qquad V_k = I - \rho_k s_k y_k^T.$$

La actualización BFGS de la inversa aproximada de la Hessiana está dada por

$$H_{k+1} = V_k H_k V_k^T + \rho_k s_k s_k^T. \tag{3.16}$$

Esta fórmula permite construir H_{k+1} a partir de la matriz anterior, sin calcular explícitamente la Hessiana exacta de la función.

Veamos que la actualización satisface la condición secante.

De la definición de V_k y de ρ_k, se obtiene

$$\begin{aligned} V_k^T y_k &= (I - \rho_k y_k s_k^T) y_k \\ &= y_k - \rho_k y_k (s_k^T y_k) \\ &= 0. \end{aligned}$$

Multiplicando (3.16) por y_k, encontramos

$$\begin{aligned} H_{k+1} y_k &= V_k H_k V_k^T y_k + \rho_k s_k (s_k^T y_k) \\ &= s_k. \end{aligned}$$

Por tanto, la actualización BFGS satisface la condición secante (3.15) en su formulación inversa.

Además, si H_k es simétrica y definida positiva, y se cumple $y_k^T s_k > 0$, la matriz H_{k+1} también es simétrica y definida positiva.

En efecto, para cualquier $z \in \mathbb{R}^n \setminus \{0\}$,

$$z^T H_{k+1} z = (V_k^T z)^T H_k (V_k^T z) + \rho_k (s_k^T z)^2.$$

Ambos términos son no negativos. Si su suma fuese cero, tendríamos $s_k^T z = 0$ y $V_k^T z = 0$. La primera igualdad implica que $V_k^T z = z$, de donde resultaría $z = 0$, una contradicción.

DRAFT

En consecuencia,

$$z^T H_{k+1} z > 0.$$

De esta manera, BFGS conserva una propiedad esencial para construir direcciones de descenso.

La condición de curvatura $y_k^T s_k > 0$ se cumple, por ejemplo, cuando la función es estrictamente convexa y los puntos consecutivos son diferentes.

En aplicaciones numéricas generales, la longitud del paso puede seleccionarse mediante una búsqueda lineal que favorezca el cumplimiento de esta condición, como ocurre con las condiciones de Wolfe.

Otros métodos cuasi-Newton

El método BFGS no es la única forma de actualizar las aproximaciones de segundo orden.

Existen otros procedimientos que utilizan la misma información s_k y y_k, pero construyen matrices diferentes.

Método DFP.

El método de Davidon–Fletcher–Powell (DFP) actualiza la aproximación de la inversa de la Hessiana mediante

$$H_{k+1} = H_k + \frac{s_k s_k^T}{s_k^T y_k} - \frac{H_k y_k y_k^T H_k}{y_k^T H_k y_k}.$$

Al igual que BFGS, este procedimiento satisface la condición secante y puede conservar la definición positiva cuando se cumplen las condiciones de curvatura correspondientes.

Ambos métodos están estrechamente relacionados, aunque emplean actualizaciones diferentes de la información de segundo orden.

Método de Broyden.

Una actualización de rango uno para la aproximación de la Hessiana está dada por

$$B_{k+1} = B_k + \frac{(y_k - B_k s_k) s_k^T}{s_k^T s_k}.$$

Esta expresión modifica la matriz anterior de manera que se satisfaga la condición secante.

Sin embargo, a diferencia de BFGS, esta actualización no garantiza que la matriz resultante sea simétrica.

Método SR1.

DRAFT

El método de actualización simétrica de rango uno, conocido como SR1, utiliza

$$B_{k+1} = B_k + \frac{(y_k - B_k s_k)(y_k - B_k s_k)^T}{(y_k - B_k s_k)^T s_k},$$

siempre que el denominador sea distinto de cero.

La corrección es simétrica, pero no necesariamente conserva la definición positiva de la aproximación.

Por esta razón, las condiciones bajo las cuales se aplican estas actualizaciones son importantes para garantizar un comportamiento numérico adecuado.

Método BFGS de memoria limitada

Aunque los métodos cuasi-Newton evitan calcular la Hessiana exacta, las implementaciones que almacenan una matriz completa $H_k \in \mathbb{R}^{n\times n}$ requieren una cantidad de memoria proporcional a n^2.

Cuando la dimensión del problema es elevada, este almacenamiento puede representar una limitación.

El método BFGS de memoria limitada, denominado L-BFGS, busca reducir este costo.

En lugar de almacenar explícitamente una matriz densa, conserva únicamente un número reducido de pares

$$(s_j, y_j)$$

correspondientes a las iteraciones más recientes.

A partir de esta información, calcula de manera recursiva la dirección de búsqueda.

Habitualmente, se utiliza una aproximación inicial de la forma

$$H_k^{(0)} = \gamma_k I, \qquad \gamma_k > 0,$$

que se combina con los pares almacenados para incorporar información de curvatura.

Si se conservan únicamente ℓ pares, con ℓ pequeño respecto de n, el almacenamiento requerido es proporcional a ℓn, en lugar de n^2.

Así, L-BFGS conserva la idea fundamental de BFGS, pero utiliza menos memoria, lo que resulta especialmente útil en problemas con un número elevado de variables.

Ejemplo 16 (Aplicación del método BFGS a una función cuadrática)**.** Vamos a estudiar el problema

$$\min_{(x_1,x_2)\in\mathbb{R}^2} f(x_1,x_2) = \frac{1}{2}x_1^2 + x_2^2.$$

DRAFT

Aunque la Hessiana puede calcularse explícitamente en este ejemplo, utilizaremos únicamente el gradiente para construir las aproximaciones de segundo orden mediante BFGS.

Análisis de la función objetivo.

El gradiente y la Hessiana son

$$\nabla f(x_1,x_2) = \begin{pmatrix} x_1 \\ 2x_2 \end{pmatrix}, \qquad \nabla^2 f(x_1,x_2) = \begin{pmatrix} 1 & 0 \\ 0 & 2 \end{pmatrix}.$$

Como la Hessiana es definida positiva, la función es estrictamente convexa.

La condición de estacionariedad permite identificar el único minimizador global:

$$x^* = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \qquad f(x^*) = 0.$$

Tomemos como punto inicial

$$x^{(0)} = \begin{pmatrix} 1 \\ \frac{1}{2} \end{pmatrix}$$

y seleccionemos la aproximación inicial de la inversa Hessiana

$$H_0 = I.$$

Primera iteración.

Calculamos el gradiente en la aproximación inicial:

$$\nabla f(x^{(0)}) = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Utilizando (3.13), obtenemos

$$p_0 = -H_0 \nabla f(x^{(0)}) = \begin{pmatrix} -1 \\ -1 \end{pmatrix}.$$

Tomemos una longitud de paso $\alpha_0 = 1/2$. La nueva aproximación es

$$x^{(1)} = \begin{pmatrix} 1 \\ \frac{1}{2} \end{pmatrix} + \frac{1}{2} \begin{pmatrix} -1 \\ -1 \end{pmatrix} = \begin{pmatrix} \frac{1}{2} \\ 0 \end{pmatrix}.$$

Ahora calculamos los vectores definidos en (3.14).

El desplazamiento es

DRAFT

$$s_0 = x^{(1)} - x^{(0)} = \begin{pmatrix} -\frac{1}{2} \\ -\frac{1}{2} \end{pmatrix}.$$

Como

$$\nabla f(x^{(1)}) = \begin{pmatrix} \frac{1}{2} \\ 0 \end{pmatrix},$$

el cambio del gradiente es

$$y_0 = \begin{pmatrix} -\frac{1}{2} \\ -1 \end{pmatrix}.$$

Verificamos la condición de curvatura:

$$y_0^T s_0 = \frac{1}{4} + \frac{1}{2} = \frac{3}{4} > 0.$$

Por tanto,

$$\rho_0 = \frac{4}{3}.$$

Sustituyendo estos resultados en la actualización BFGS (3.16), obtenemos

$$H_1 = \begin{pmatrix} \frac{11}{9} & -\frac{1}{9} \\ -\frac{1}{9} & \frac{5}{9} \end{pmatrix}.$$

Observemos que esta matriz es simétrica y definida positiva.
Además, satisface la condición secante, puesto que

$$H_1 y_0 = \begin{pmatrix} \frac{11}{9} & -\frac{1}{9} \\ -\frac{1}{9} & \frac{5}{9} \end{pmatrix} \begin{pmatrix} -\frac{1}{2} \\ -1 \end{pmatrix} = \begin{pmatrix} -\frac{1}{2} \\ -\frac{1}{2} \end{pmatrix} = s_0.$$

De esta manera, la nueva matriz incorpora la información del desplazamiento y del cambio del gradiente.

Segunda iteración.
Utilizando la matriz H_1, calculamos la nueva dirección:

$$\begin{aligned} p_1 &= -H_1 \nabla f(x^{(1)}) \\ &= -\begin{pmatrix} \frac{11}{9} & -\frac{1}{9} \\ -\frac{1}{9} & \frac{5}{9} \end{pmatrix} \begin{pmatrix} \frac{1}{2} \\ 0 \end{pmatrix} \\ &= \begin{pmatrix} -\frac{11}{18} \\ \frac{1}{18} \end{pmatrix}. \end{aligned}$$

DRAFT

Tomando ahora un paso completo $\alpha_1 = 1$, obtenemos

$$\begin{aligned} x^{(2)} &= x^{(1)} + p_1 \\ &= \begin{pmatrix} \frac{1}{2} \\ 0 \end{pmatrix} + \begin{pmatrix} -\frac{11}{18} \\ \frac{1}{18} \end{pmatrix} \\ &= \begin{pmatrix} -\frac{1}{9} \\ \frac{1}{18} \end{pmatrix}. \end{aligned}$$

Para analizar el comportamiento del procedimiento, evaluamos la función objetivo en las aproximaciones obtenidas:

$$\begin{aligned} f(x^{(0)}) &= \frac{3}{4}, \\ f(x^{(1)}) &= \frac{1}{8}, \\ f(x^{(2)}) &= \frac{1}{108}. \end{aligned}$$

Observamos que el valor de la función objetivo disminuye en las dos iteraciones realizadas.

Además, las aproximaciones se acercan al único minimizador global $x^* = (0,0)^T$.

La propiedad relevante de este ejemplo es que la matriz H_1 se construyó sin invertir ni utilizar explícitamente la Hessiana exacta.

En su lugar, el método empleó los vectores s_0 y y_0, que contienen información obtenida directamente del proceso iterativo.

Consideraciones finales

Los métodos cuasi-Newton representan una alternativa al método de Newton clásico cuando el cálculo o la utilización de la Hessiana exacta resulta computacionalmente costoso.

Su fundamento consiste en aproximar la información de segundo orden a partir de los desplazamientos y de los cambios del gradiente, imponiendo la condición secante (3.15).

Entre las diferentes estrategias, BFGS destaca por conservar la simetría y la definición positiva de las aproximaciones bajo condiciones apropiadas de curvatura. Por su parte, L-BFGS reduce los requerimientos de memoria al utilizar únicamente una cantidad limitada de información de iteraciones anteriores.

Es importante señalar que la aproximación de la Hessiana no garantiza, por sí sola, una convergencia más rápida en todos los problemas. El comportamiento del método también depende de las propiedades de la función objetivo, de la aproximación inicial y de la elección de las longitudes de paso.

DRAFT

Con esta construcción concluimos el estudio de los métodos de optimización de segundo orden. El método de Newton utiliza la curvatura exacta de la función objetivo, mientras que los métodos cuasi-Newton construyen aproximaciones de dicha curvatura a partir de la información generada durante las iteraciones.

Ambas estrategias se fundamentan en las condiciones de optimalidad y en las aproximaciones locales estudiadas a lo largo del capítulo.

DRAFT

Bibliografía

Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer nature link.

Burden, R. and Faires, J. (2002). *Análisis numérico*. International Thomson Editores.

Chapra, S., Canale, R., and Brito, J. (2006). *Métodos numéricos para ingenieros*. Elibro Cátedra. McGraw-Hill.

King, R. (1966). Runge-kutta methods with constrained minimum error bounds. *Mathematics of Computation*, 20(95):386–391.

Lawson, C. and Hanson, R. (1995). *Solving Least Squares Problems*. Classics in Applied Mathematics. Society for Industrial and Applied Mathematics.

Quarteroni, A., Sacco, R., and Saleri, F. (2017). *Numerical Mathematics*. Texts in Applied Mathematics. Springer New York.

Rodríguez, L. (2016). *Análisis numérico básico*. Facultad de ciencias naturales y matematicas sede Litoral.

Shampine, L. (1994). *Numerical Solution of Ordinary Differential Equations*. Chapman & Hall mathematics. Taylor & Francis.

Stewart, J. (2011). *Single Variable Calculus: Early Transcendentals*. Cengage Learning.

Walsh, G. (1975). *Methods of Optimization*. A Wiley-Interscience publication. Wiley.

DRAFT