Vamos a comparar los siguientes métodos estudiados en clase para resolver el problema de ajuste de curva. Determinar cómo los algoritmos propuestos minimizan la misma función objetivo y comparar la convergencia.

1. Formulación del problema:

Consideremos N observaciones que siguen un modelo lineal:

$$y_i = 4x_i + 1 + \varepsilon_i \quad (1)$$

donde:

ε_i representa un error aleatorio con una distribución normal de media cero y desviación estándar 0.5

Queremos ajustar (conocer, calcular, determinar) los parámetros de una línea recta:

$$\hat{y}_i = m x_i + b \quad (2)$$

donde:

m representa la pendiente

b el intercepto.

Para determinar los parámetros m, b vamos a minimizar la función de costo:

$$J(m,b) = \frac{1}{2a} \sum_{i=1}^{N} (\hat{y}_i - y_i)^2 \quad (3)$$

Reemplacemos las N observaciones en el modelo lineal de la ecuación (2):

$$y_1 = m x_1 + b$$
$$y_2 = m x_2 + b$$
$$y_3 = m x_3 + b$$
$$\vdots$$
$$y_N = m x_N + b$$

De forma matricial se puede reescribir:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix} = \underbrace{\begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_N & 1 \end{bmatrix}}_{A:\ N\times 2} \underbrace{\begin{bmatrix} m \\ b \end{bmatrix}}_{\theta:\ 2\times 1}$$

Donde:

$$A = \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ \vdots & \vdots \\ x_N & 1 \end{bmatrix} \quad ; \quad \theta = \begin{bmatrix} m \\ b \end{bmatrix}$$

En la ecuación (3):

$$J(\theta) = \frac{1}{2a}\sum (A\theta - y)^2 = \frac{1}{2a}\|A\theta - y\|^2$$

$$\underset{1\times n}{u^T}\ \underset{n\times 1}{u} = u \cdot u = \|u\|^2$$

$$\nabla J(\theta) = \frac{1}{a} A^T (A\theta - y)$$

$$\nabla^2 J(\theta) = \frac{1}{a} A^T A$$

2. Comparación de los métodos:

2.1 Gradiente descendente:

$$\theta^{(K+1)} = \theta^{(K)} - \alpha \nabla J(\theta^{(K)})$$

Donde α controla el paso del método.

$0 < \alpha \leq 1$.

Sus derivadas parciales:

$$\frac{\partial J}{\partial m} = \frac{1}{a} \sum_{i=1}^{N} (mx_i + b - y_i) x_i$$

$$\frac{\partial J}{\partial b} = \frac{1}{a} \sum_{i=1}^{N} (mx_i + b - y_i)$$

Para cada iteración:

$$m^{(K+1)} = m^{(K)} - \alpha \frac{\partial J}{\partial m}$$

$$b^{(K+1)} = b^{(K)} - \alpha \frac{\partial J}{\partial b}.$$

2.2 Método de Newton sin restricciones :

$$\nabla^2 J(\theta^{(k)})\, p_k = -\nabla J(\theta^{(k)})$$

$$\theta^{(k+1)} = \theta^{(k)} + p_k \quad (*)$$

$$p_k = (\nabla^2 J(\theta^{(k)}))^{-1} (-\nabla J(\theta^{(k)}))$$

$$H = \frac{1}{a} A^T A \quad ; \quad c = \frac{1}{a} A^T y$$

$$\nabla J(\theta) = \frac{1}{a} A^T (A\theta - y)$$

$$= \frac{1}{a} (A^T A \theta - A^T y)$$

$$\nabla J(\theta) = H\theta - c$$

En la ecuación de recurrencia (*) :

$$\theta^{(k+1)} = \theta^{(k)} - H^{-1}(H\theta^{(k)} - c)$$

$M^{-1} \cdot M = I$
$M \cdot M^{-1} = I$

$$\theta^{(k+1)} = \theta^{(k)} - \theta^{(k)} + H^{-1} c$$

$$\theta^{(k+1)} = \left(\frac{1}{a} A^T A\right)^{-1} \frac{1}{a} A^T y$$

$$\theta^{(k+1)} = a\,(A^T A)^{-1} \frac{1}{a} A^T y$$

$$\theta^{*} = (A^T A)^{-1} A^T y.$$

3. Propiedades de la matriz A.

¿El rango completo de una matriz implica matriz definida positiva o semidefinida positiva?

3.1 Matriz semidefinida positiva:

Sea $A \in \mathbb{R}^{m \times n}$, para cualquier $x \in \mathbb{R}^n$:

$$x^T A^T A x = (Ax)^T (Ax) = \|Ax\|^2 \geq 0$$

por lo tanto

$$A^T A \geq 0$$

Esto se cumple independientemente si A es de rango completo o no.

3.2 Matriz definida positiva:

Para que $A^T A$ sea definida positiva necesitamos que: $x^T A^T A x > 0$; para todo $x \neq 0$

Si $Ax = 0$ entonces $x = 0$.

Esto ocurre cuando las columnas de son linealmente independientes, así:

$$A^T A > 0 \longrightarrow Rank(A) = n.$$

Esto es, A debe tener rango completo por columnas.